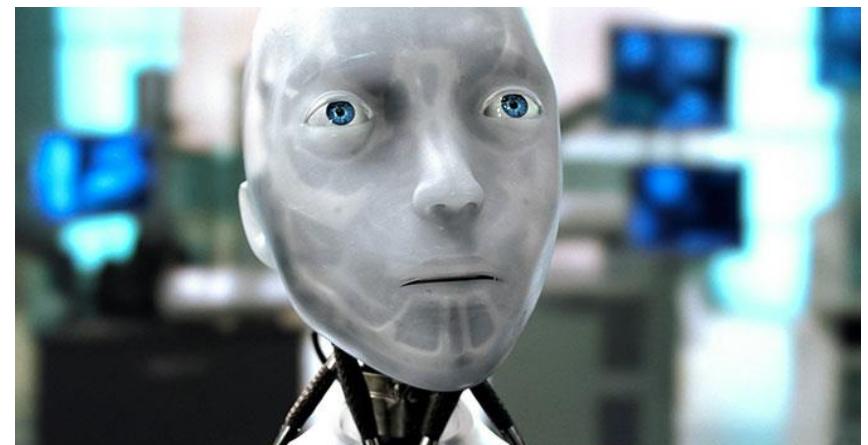
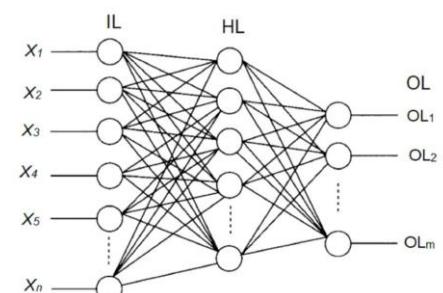
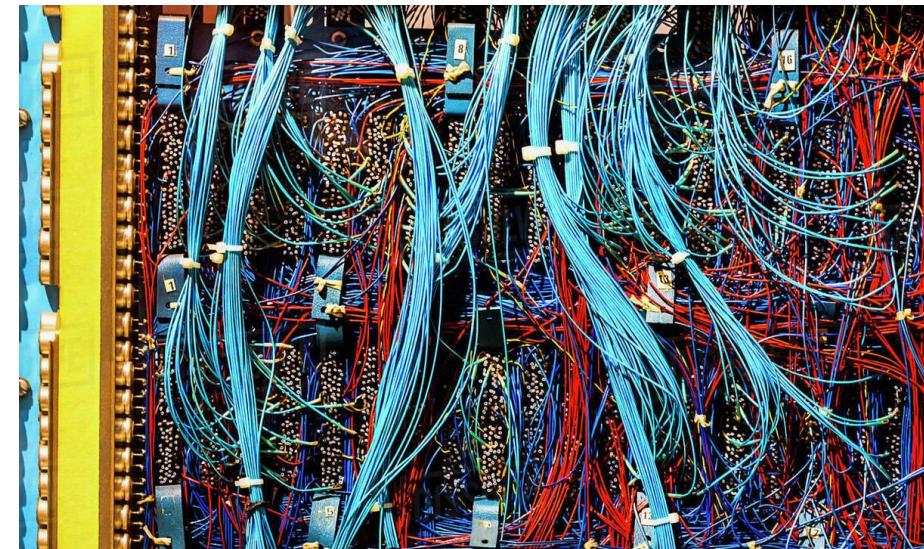
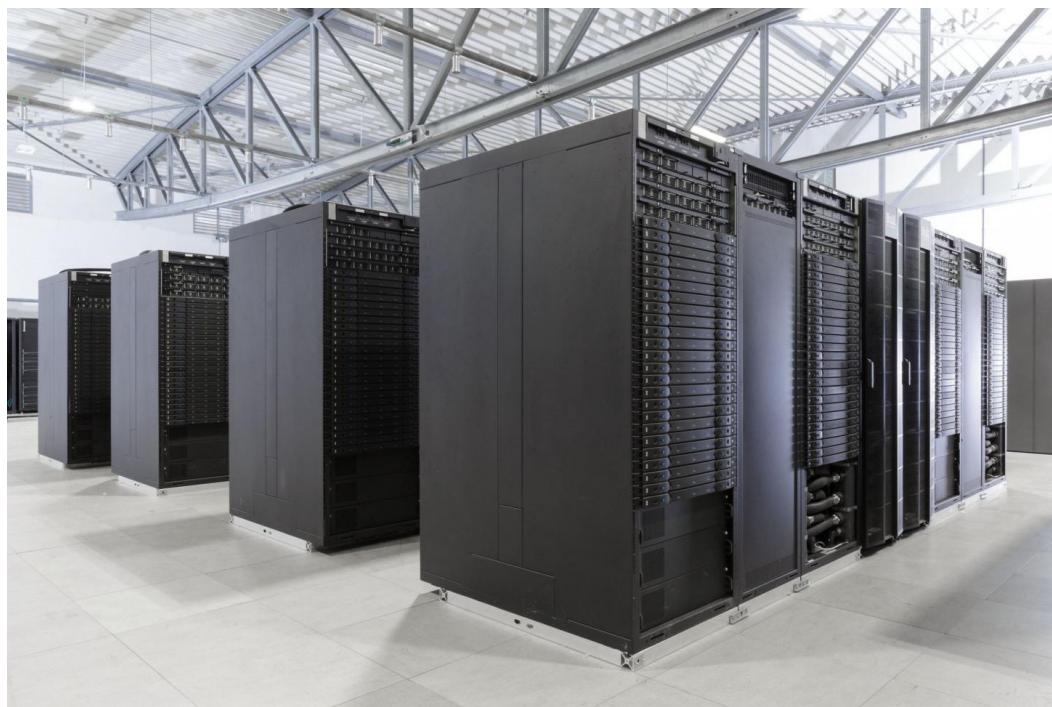


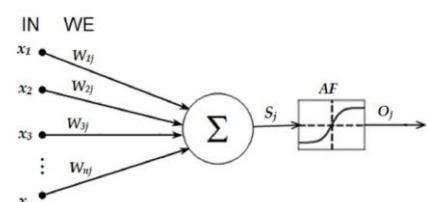
Yapay Zeka: Popüler Kültürde



Yapay Zeka: Gerçekte?



(a)



(b)

Bilgi Piramidi Üzerinden Bir Açıklama



Bilgi Piramidi Üzerinden Bir Açıklama



Veri Analitiği – İstatistik – Yapay Zeka



Elimizde bir büst olsun

Söz konusu büst, tarihteki ünlü bir şahsa dair olsun; ayrıca ünlü bir heykeltıraşın eseri olduğu düşünülüyor olsun

Veri Analitiği – İstatistik – Yapay Zeka



İstatistik, gerçeklere dayalı (*factual*) bir bilim dalıdır.

Elimizdeki büste dair ölçümlere (alın genişliği, göz küreleri arasındaki mesafe, vb.) dayalı olarak söz konusu şahsın genel popülasyon içerisindende hangi yüzdelik dilimde olduğunu, standart sapma içerisinde olup olmadığını, vb. söyler.

Veri Analitiği – İstatistik – Yapay Zeka



Veri Analitiği ise çıkarımcı (*inferential*) bir bilim dalıdır.

Büste dair ölçümlere (alın genişliği, göz küreleri arasındaki mesafe, vb.) dayalı olarak söz konusu şahsın boyu, kilosu, ayakkabı numarası gibi değerleri tahmin etmeye çalışır!...

Veri Analitiği – İstatistik – Yapay Zeka

Yapay Zekâ ise öğrenmelere veya deneyimlere dayalı sezgisel bir yaklaşımıdır.

Önceden yeterince veri ile eğitildiyse, elimizdeki büste dair ölçümlere (alın genişliği, göz küreleri arasındaki mesafe, vb.) dayalı olarak büstü yapılmış şahsa veya büste ilişkin olarak anomali tespiti yapabilir (örneğin şahsin alın genişliği aşırı derecede büyük; veya büst yanlış yapılmış vb.)



Veri Analitiği – İstatistik – Yapay Zeka

Veri Analitiği, çıkarımlar yaparken zaman zaman İstatistik Yöntemlerden ve Yapay Zekâ'dan yararlanabilir.

Büstün ölçümllerine, A ve B ırklarının antropometrik verilerine dayalı olarak büstü yapılmış olan şahsın A ırkından mı, B ırkından mı olmasının daha yüksek olasılıklı olduğunu tahmin etmeye çalışabilir.



Veri Analitiği – İstatistik – Yapay Zeka

Veri Analitiği, çıkarımlar yaparken zaman zaman İstatistik Yöntemlerden ve Yapay Zekâ'dan yararlanabilir.

Büstün ölçümllerine ve genel toplumun antropometrik verilerine dayalı olarak büstü yapılmış olan şahsın Akromegali hastası olup olmadığını belirlemeye çalışabilir.



Veri Analitiği – İstatistik – Yapay Zeka



Veri Analitiği, çıkarımlar yaparken zaman zaman İstatistik Yöntemlerden ve Yapay Zekâ'dan yararlanabilir.

Büstün ölçümlerine ve büstü yaptığı iddia edilen heykeltıraşın diğer eserlerinin özelliklerine dayalı olarak büstün gerçekten de ilgili şahsın eseri olup olmadığını belirlemeye çalışabilir.

Veri Analitiği – İstatistik – Yapay Zeka



Betimleyici Veri Analitiği (*Descriptive Data Analytics*): Mevcut durumun fotoğrafını çeker

Öngörücü Veri Analitiği (*Predictive Data Analytics*): Veri değişim eğilimlerini ırdeleyerek gelecekte ne olacağını tahmin eder

Reçete Yazıcı Veri Analitiği (*Prescriptive Data Analytics*):
What-If senaryoları koşturarak bunlara ilişkin sonuçlar bulur; önerilerde bulunur

Genel Sınıflandırma

- ▶ Dar Yapay Zeka / Zayıf Yapay Zeka
 - ▶ Belirli bir problemi çözmeye yönelik
 - ▶ İnsanlara yorucu ve sıkıcı gelebilecek rutin işleri yerine getirme amacını güden
- ▶ Genel Yapay Zeka / Kuvvetli Yapay Zeka
 - ▶ Birçok farklı problemi çözmekte insan kadar yetkin
- ▶ Süper Yapay Zeka
 - ▶ Bilinc sahibi

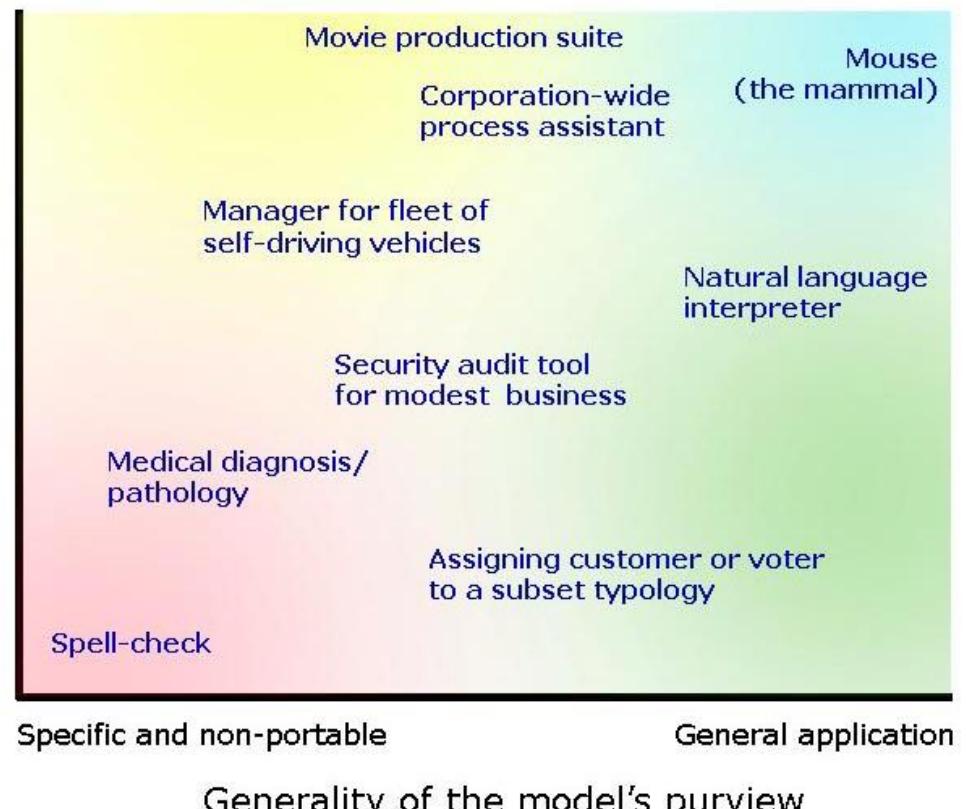
Genel Sınıflandırma

Specific task-oriented software
Generic tools to be used in larger systems
Multi-threaded highly sophisticated systems
True AI

A network of simulations,
communicating amongst
themselves by symbols
and tokens

Sophistication of the
model in play that
approximates 'under-
standing'.

A single level of mod-
eling, working to crude
error minimisation



Kaynak:

[http://www.chforum.org/
library/AI_taxonomy.shtml](http://www.chforum.org/library/AI_taxonomy.shtml)

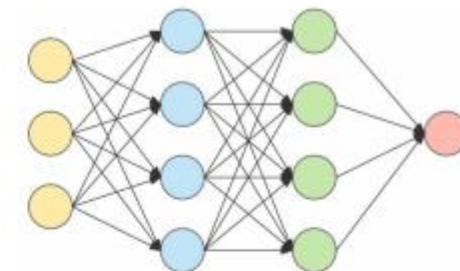
İnsan Öğrenmesi



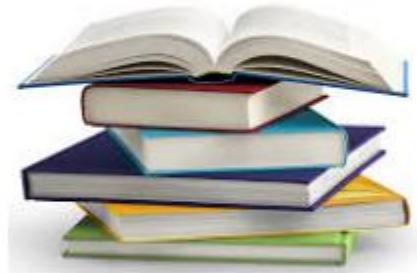
Zeka



Makine Öğrenmesi



Model



Öğrenme
Materiyalleri



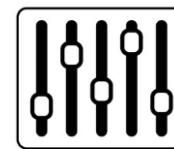
Veri
Seti



Öğrenme
Becerileri



Algoritma
Hiperparametreleri



shutterstock.com - 1500306722

İnsan Beyni - Bilgisayar Karşılaştırması

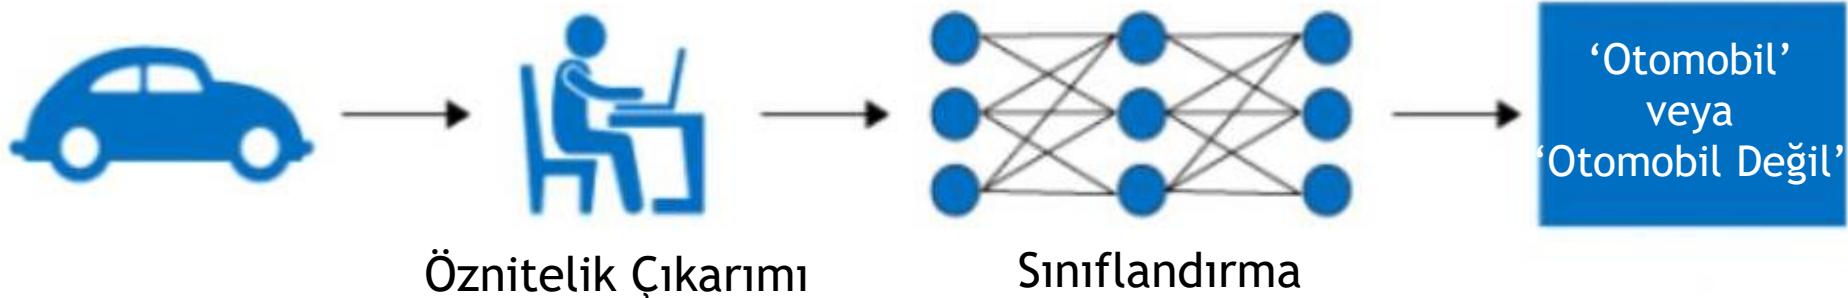
	Beyin	Bilgisayar
Genel Yapı	Nöronlar ve Sinapslar	Entegre devreler, transistörler, diyonlar, vb.
Bilgi Depolama	Elektrokimyasal ve elektriksel darbeler aracılığıyla 23 farklı şekilde	Yarı iletken birimlerde sinyal seviyeleri ile 2 farklı şekilde (0 ve 1)
Kapasite	86 milyar nöron, 125 trilyon sinaps, 1500cm^3 hacim, 1.4kg ağırlık 100 trilyon FLOP/saniye işlem kapasitesi 1 petabyte (1 katrilyon byte) bellek kapasitesi	Eldeki sisteme göre değişmekte
Enerji ve Kaynak Sarfiyatı	12-20 Watt Oksijenimizin %20'si; Kardiyak girdinin %15'i	GigaWatt mertebesinde

Yapay Zeka - Temel Kavramlar

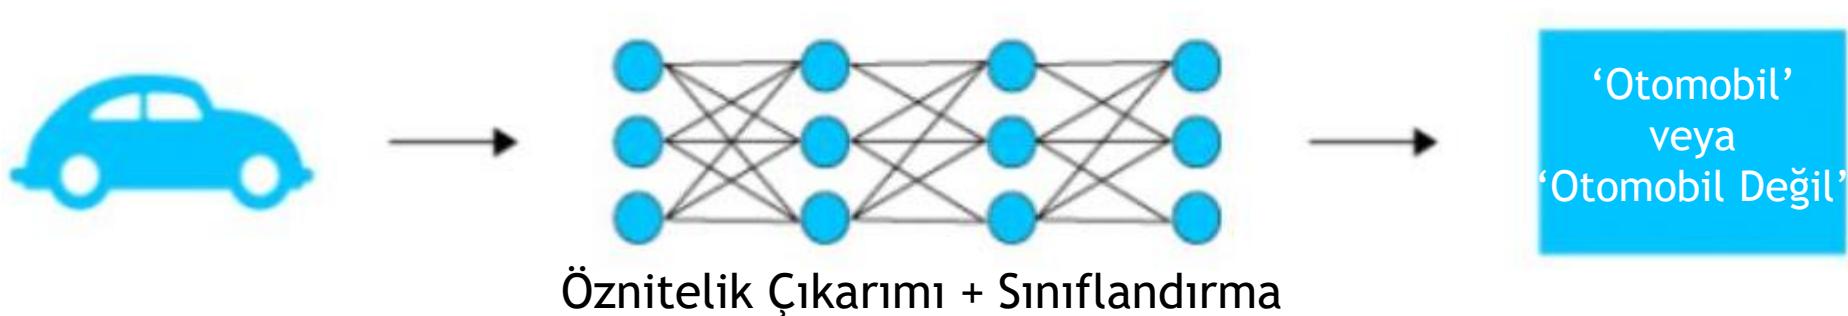


Klasik Makine Öğrenmesi - Derin Öğrenme

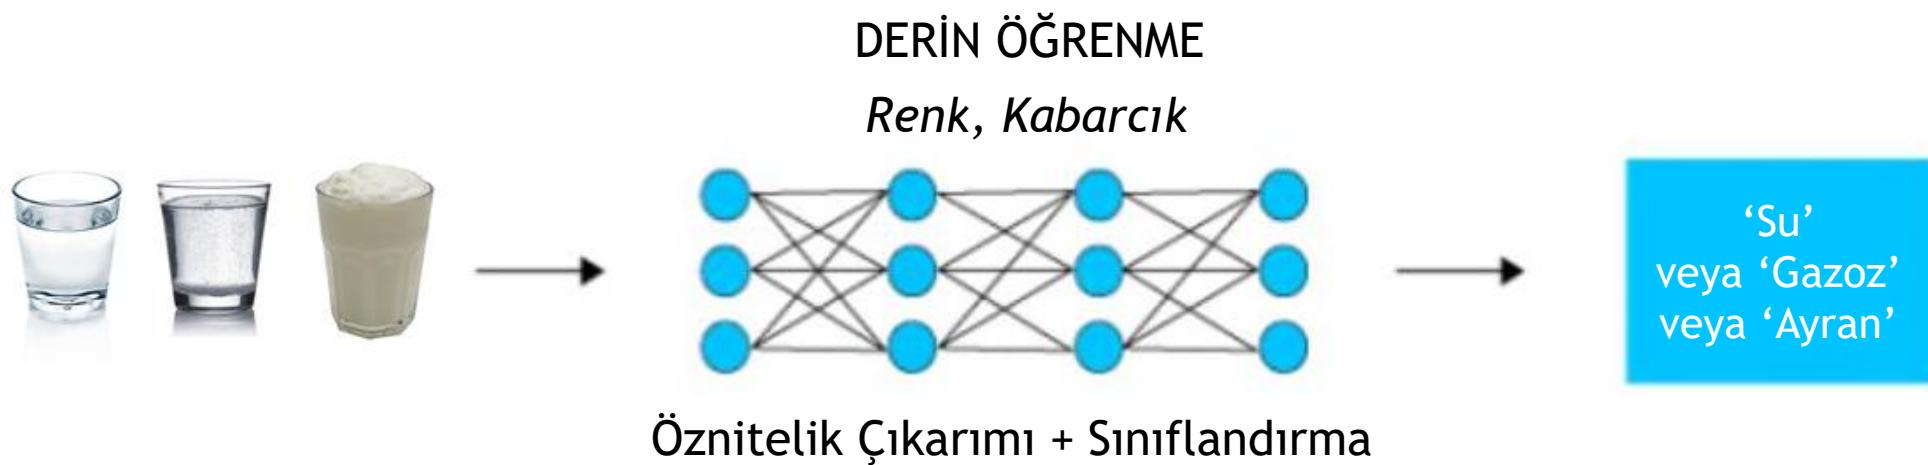
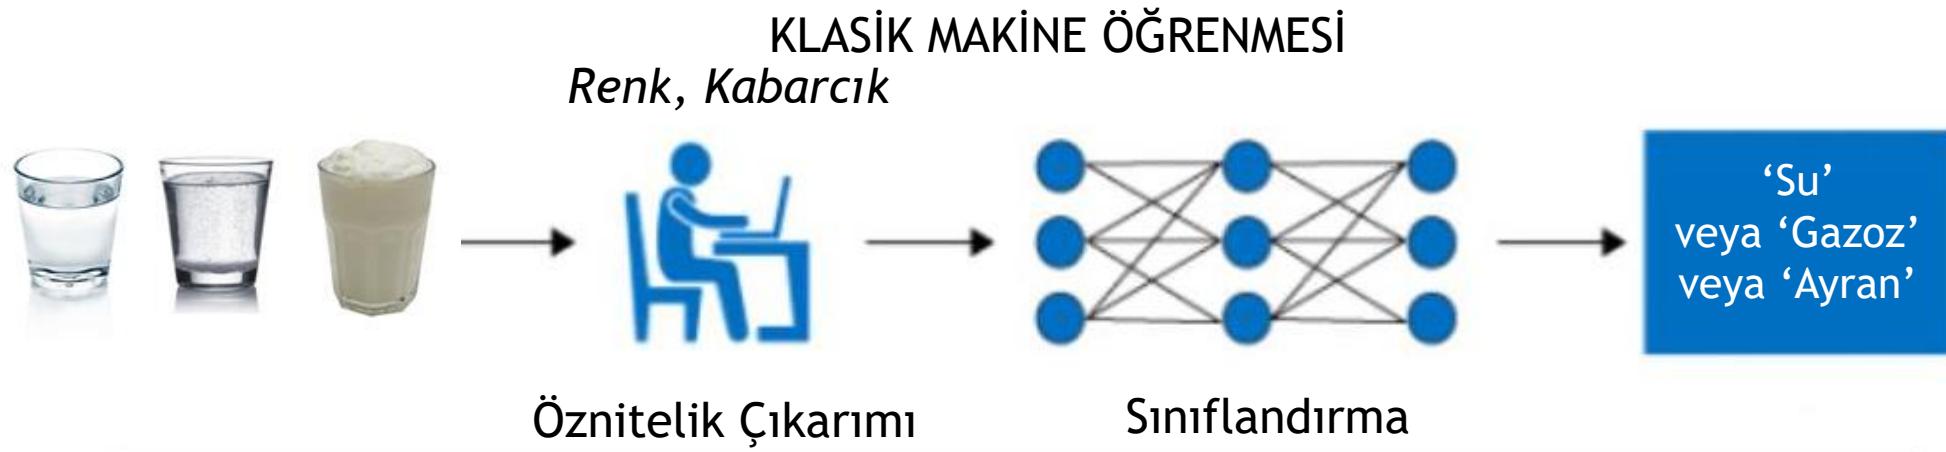
KLASİK MAKİNE ÖĞRENMESİ



DERİN ÖĞRENME



Klasik Makine Öğrenmesi - Derin Öğrenme



Yapay Zeka Tarihçesi: Tüm Aşamalar

- ▶ 1956-1974: Birinci Altın Dönem (*First Golden Era*) veya İlk Patlama (*First Burst*) veya Çıkarım Dönemi (*Inference Period*)
- ▶ 1974-1980: Birinci Yapay Zeka Kıştı (*First AI Winter*)
- ▶ 1980-1987: Gümbürtü Dönemi (*Boom*) veya İkinci Patlama (*Second Burst*) veya Bilgi Dönemi (*Knowledge Period*)
- ▶ 1987-1993: İkinci Yapay Zeka Kıştı (*Second AI Winter*)
- ▶ 1993-Günümüze: Üçüncü Patlama (*Third Burst*) veya Öğrenme Dönemi (*Learning Period*)

Erken Evre

- ▶ 1943: Warren McCulloch ve Walter Pitts tarafından insan beyni ve makineler arasındaki benzerlik ilişkisi fikirlerinin ilk olarak ortaya atılması
- ▶ 1949: Donald Hebb'in «*The Organization of Behavior*» isimli çalışmasında nöral güzergahların kullanıldıkça kuvvetlendiği fikrini ileri sürmesi
- ▶ 1955: John McCarthy tarafından «*Artificial Intelligence*» teriminin ilk kez kullanılması
- ▶ 1956: Konu ile ilgili *Dartmouth College Workshop*'nın düzenlenmesi
- ▶ 1958: Frank Rosenblatt tarafından «*Perceptron*» fikrinin ortaya atılması

Perceptron

- ▶ Rosenblatt tarafından 1958 yılında tanımlanmış

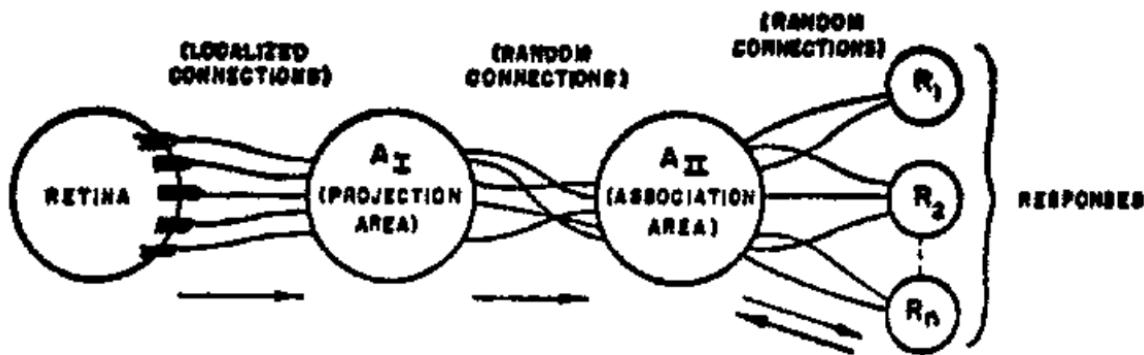


FIG. 1. Organization of a perceptron.

- ▶ Aslen, Office of Naval Research tarafından desteklenmiş olan ve Cornell Aeronautical Lab'da yapılan bir çalışmanın çıktısı

Rosenblatt, F. (1958). The perceptron: a probabilistic model for information storage and organization in the brain. *Psychological review*, 65(6), 386.

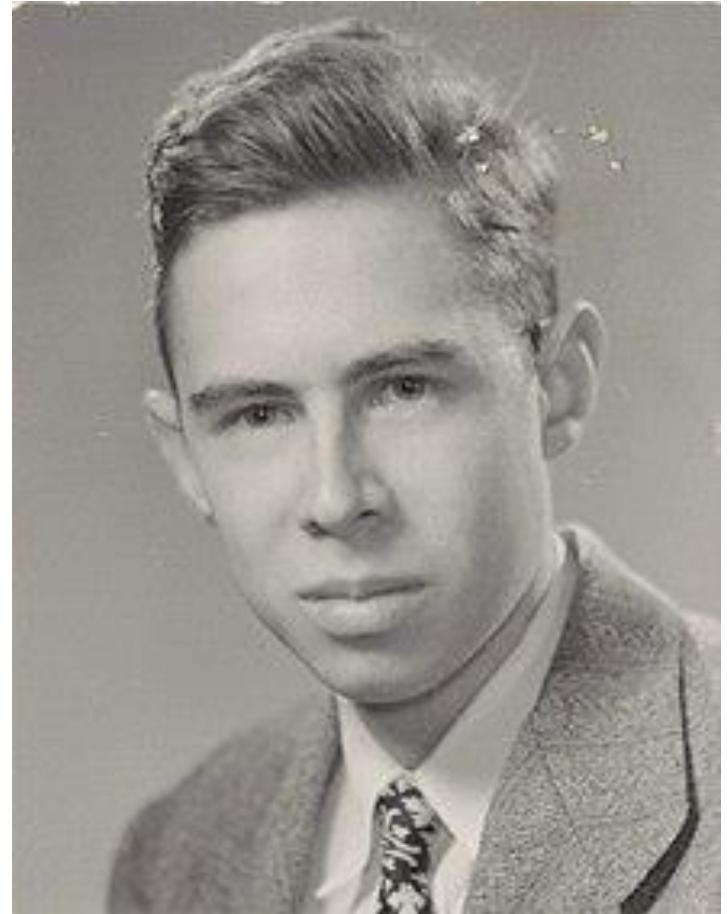
Perseptron

- ▶ 1962 yılında çalışmalarını 4 ciltlik bir kitapta toplamış:
F. Rosenblatt, Principles of Neurodynamics: Perceptrons and the Theory of Brain Mechanisms, Spartan Books, 1962.
- ▶ Cilt 3: Çok katmanlı perseptron; çapraz bağlaşımlı perseptron kavramları!...
- ▶ Bu kitap Haziran 2021 itibarı ile >8,155 atıf almış durumda idi
- ▶ Orijinal makale ise Haziran 2021 itibarı ile >12,785 atıf almış durumda idi



Frank Rosenblatt
(1928-1971)

- ▶ 1962 yılında çalışmalarını 4 ciltlik bir kitapta toplamış:
F. Rosenblatt, *Principles of Neurodynamics: Perceptrons and the Theory of Brain Mechanisms*, Spartan Books, 1962.
- ▶ Cilt 3: Çok katmanlı perceptron; çapraz bağlaşımlı perceptron kavramları!...
- ▶ Bu kitap Şubat 2022 itibarı ile >8,520 atıf almış durumda idi
- ▶ Orijinal makale ise Şubat 2022 itibarı ile >14,085 atıf almış durumda



Frank Rosenblatt
(1928-1971)

Biraz da Popülerite

- ▶ 1997: İlk başarılı ve ticari Konuşma Tanıma Uygulaması (Dragon Systems)
- ▶ 1997: IBM Deep Blue'nun Kasparov'u yenmesi
- ▶ 1998: MIT'de karşısındaki duygularını tespit eden KISmet'in geliştirilmesi
- ▶ 2002: Otonom elektrik süpürgesi Roomba'nın piyasaya çıkışı
- ▶ 2009: Google'ın Kendini Süren Aracı
- ▶ 2011: IBM Watson'un ABD'deki Jeopardy şampiyonlarını yenmesi
- ▶ 2011-2014: Kişisel Asistan Uygulamaları (Siri, Now, Cortana, Alexa)
- ▶ 2014: Turing Test'ten geçen ve birçok değerlendiriciyi insan olduğuna ikna eden «Eugene Goostman» chatbot'u
- ▶ 2016: Microsoft Tay'in sosyal medyada ırkçı yorumlarda bulunması
- ▶ 2016: AlphaGo'nun profesyonel Go oyuncusunu yenmesi

Yaygın Uygulamalar

Tablodakilerle sınırlı kalmamak kaydıyla:

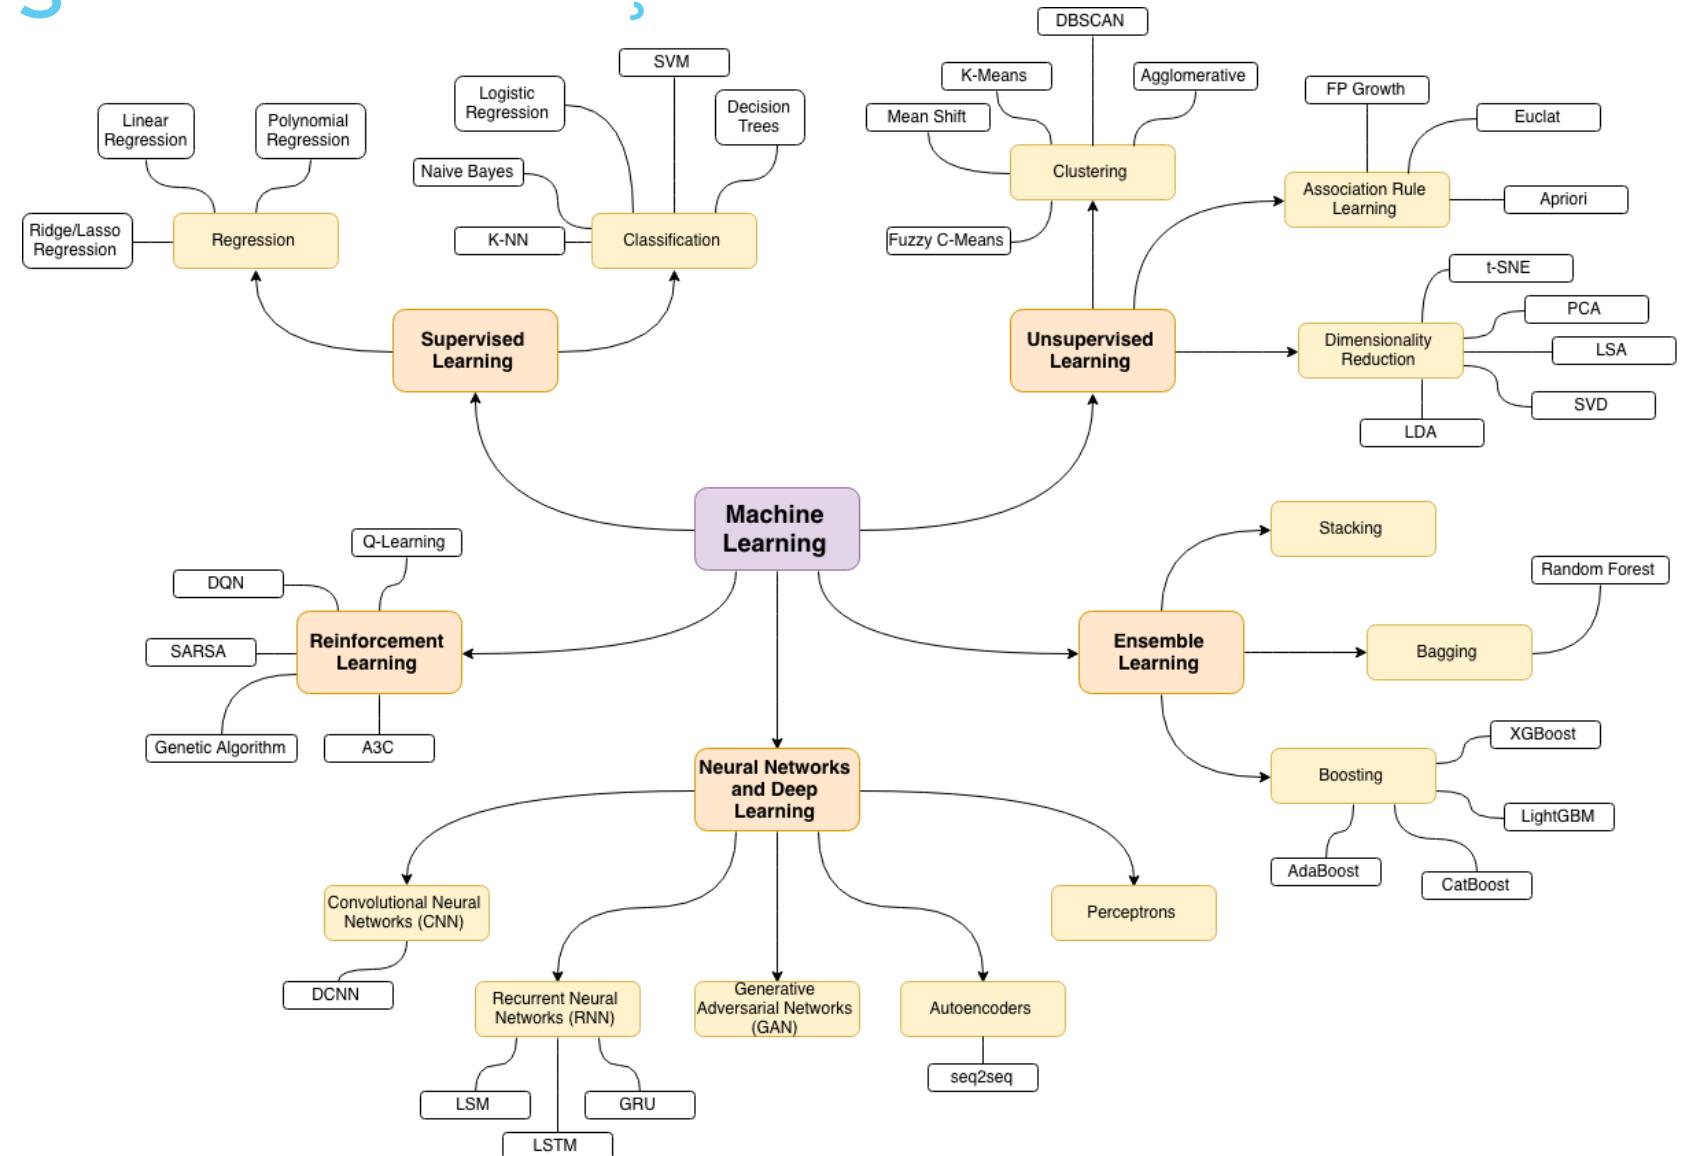
İşlev	Tür
Önceliklendirme	Genel Amaçlı Arama Motorları Özel Amaçlı Arama Motorları
	Meta Arama Motorları
	Soru/Cevap Motorları
	Sosyal Medya Zaman Akışları
Sınıflandırma	İtibar/Bilinirlik Sistemleri
	Haber Değerleme Sistemleri
	Kredi Değerleme Sistemleri
	Sosyal Değerleme Sistemleri
İlişkilendirme	Öngörüsel Politika Oluşturma Sistemleri
	Gelişim/Eğitim Öngörü Sistemleri
Filtreleme	Spam Filtreleme Sistemleri
	Çocuk Koruma Filtreleri
	Tavsiye Sistemleri
	Haber Derleme Sistemleri

Yapay Zeka Algoritmalarının Sınıflandırılması

Kaynak: J. Brownlee, 'Machine Learning Algorithm Taxonomy',
<https://www.deepmarketer.com/blog/2017/1/30/machine-learning-algorithm-taxonomy>



Yapay Zekada ‘Öğrenme’ Yaklaşımları

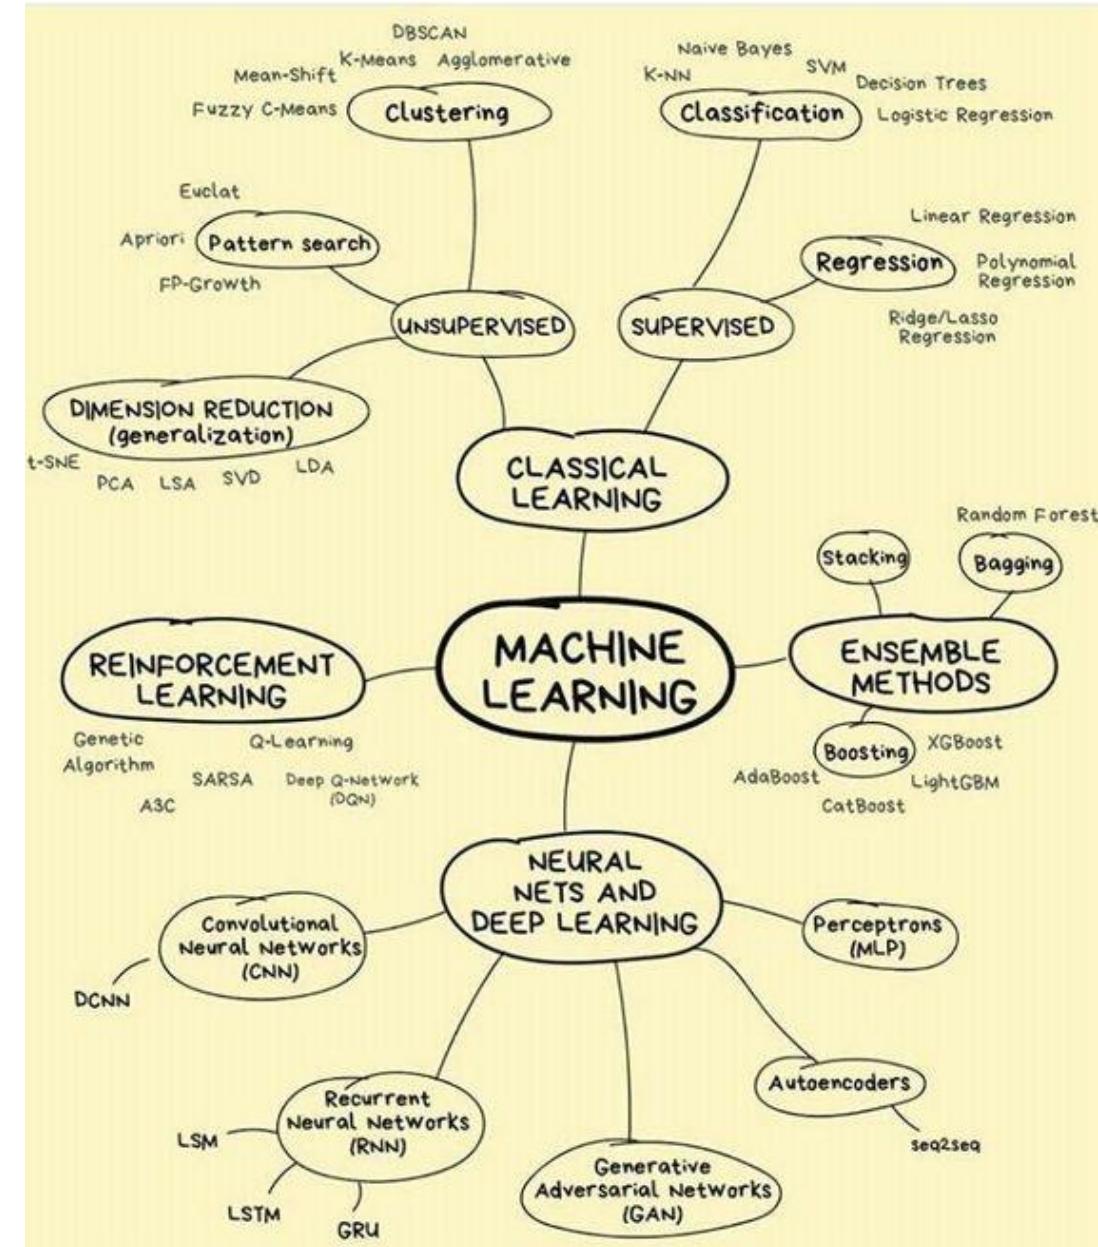


Kaynak: weixin_34019929,
https://blog.csdn.net/weixin_34019929/article/details/94166063

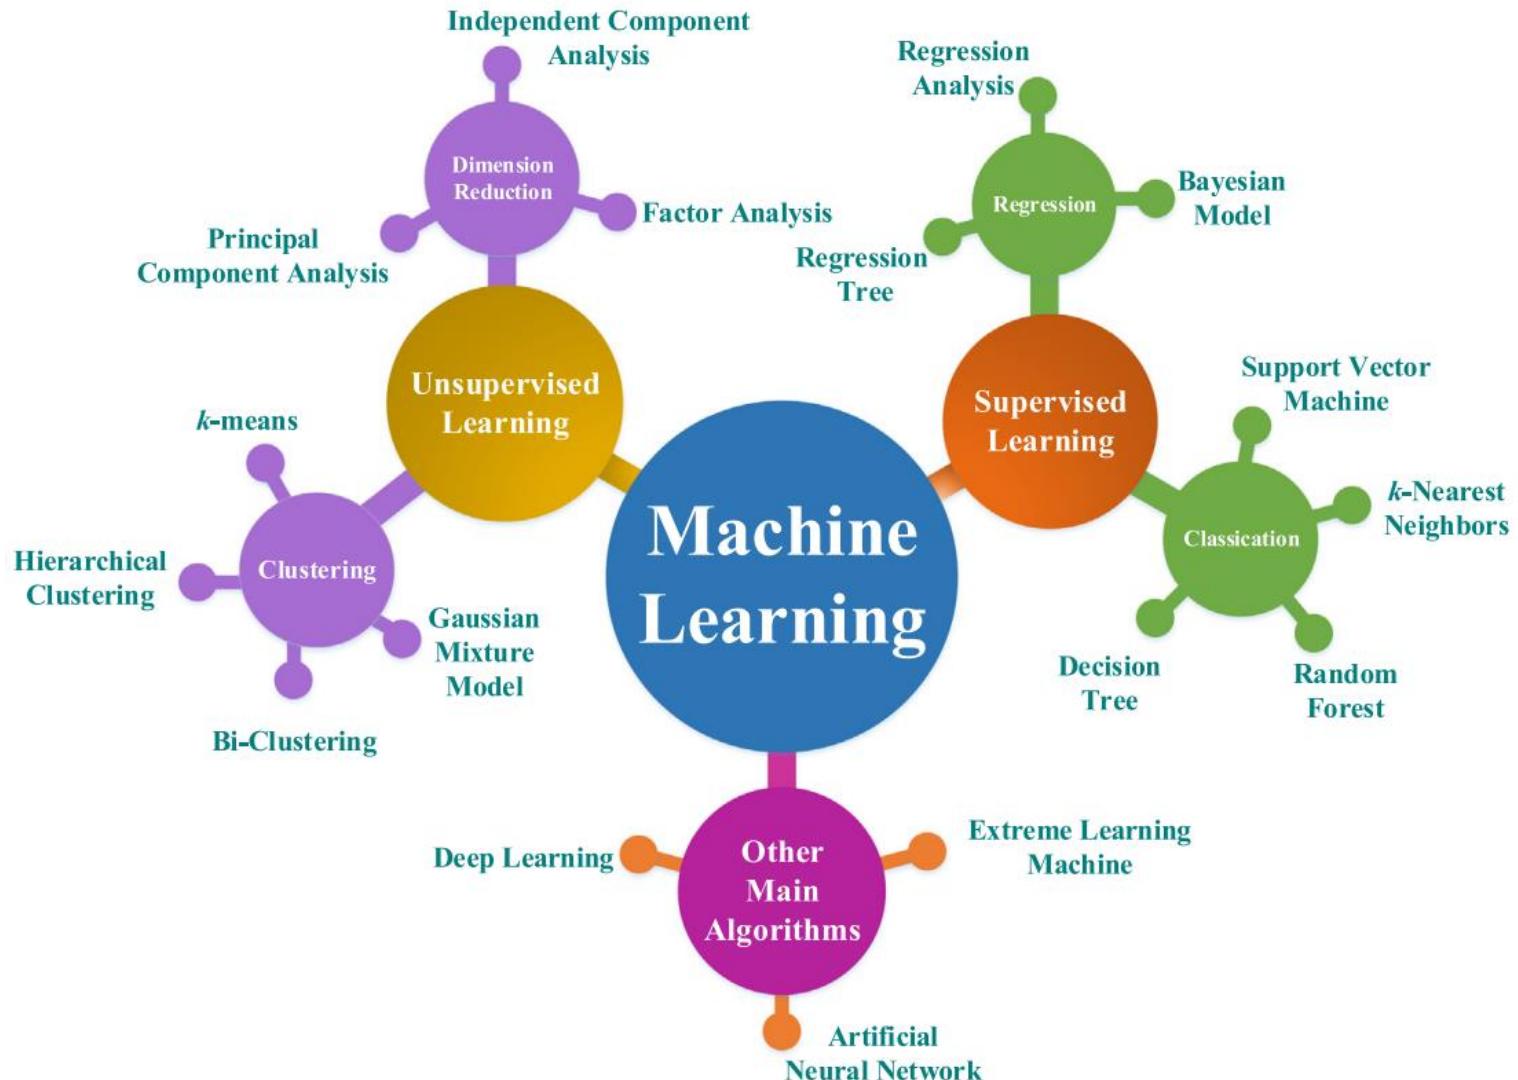
Yapay Zeka Algoritmalarının Sınıflandırılması

Kaynak:

<https://ro.pinterest.com/pin/828310556449732982/>



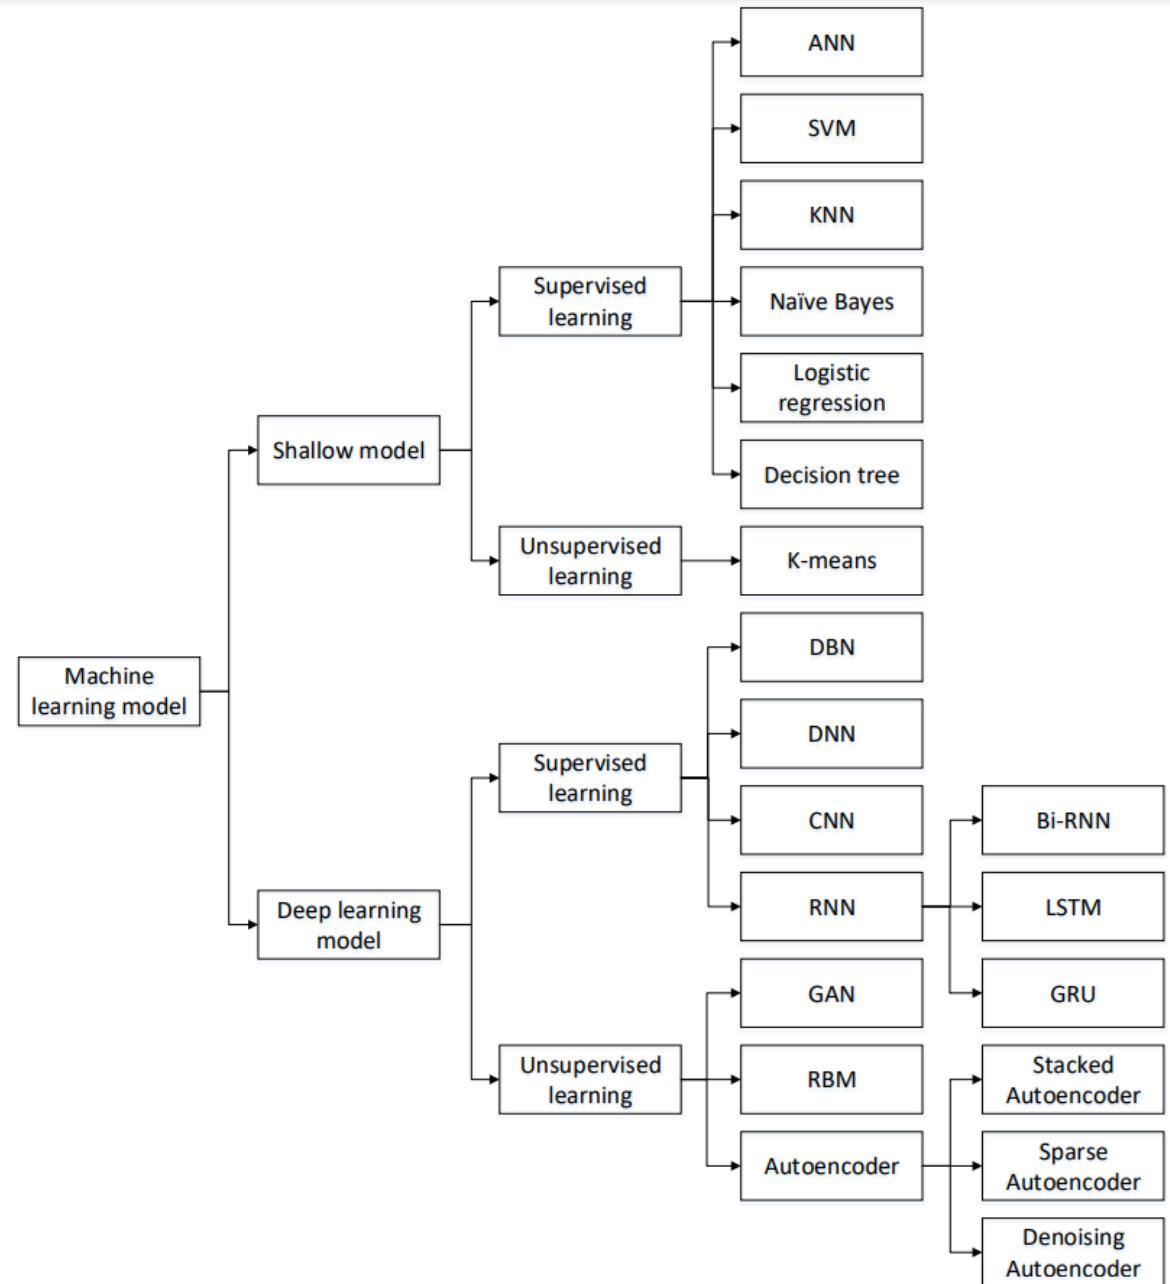
Yapay Zeka Algoritmalarının Sınıflandırılması



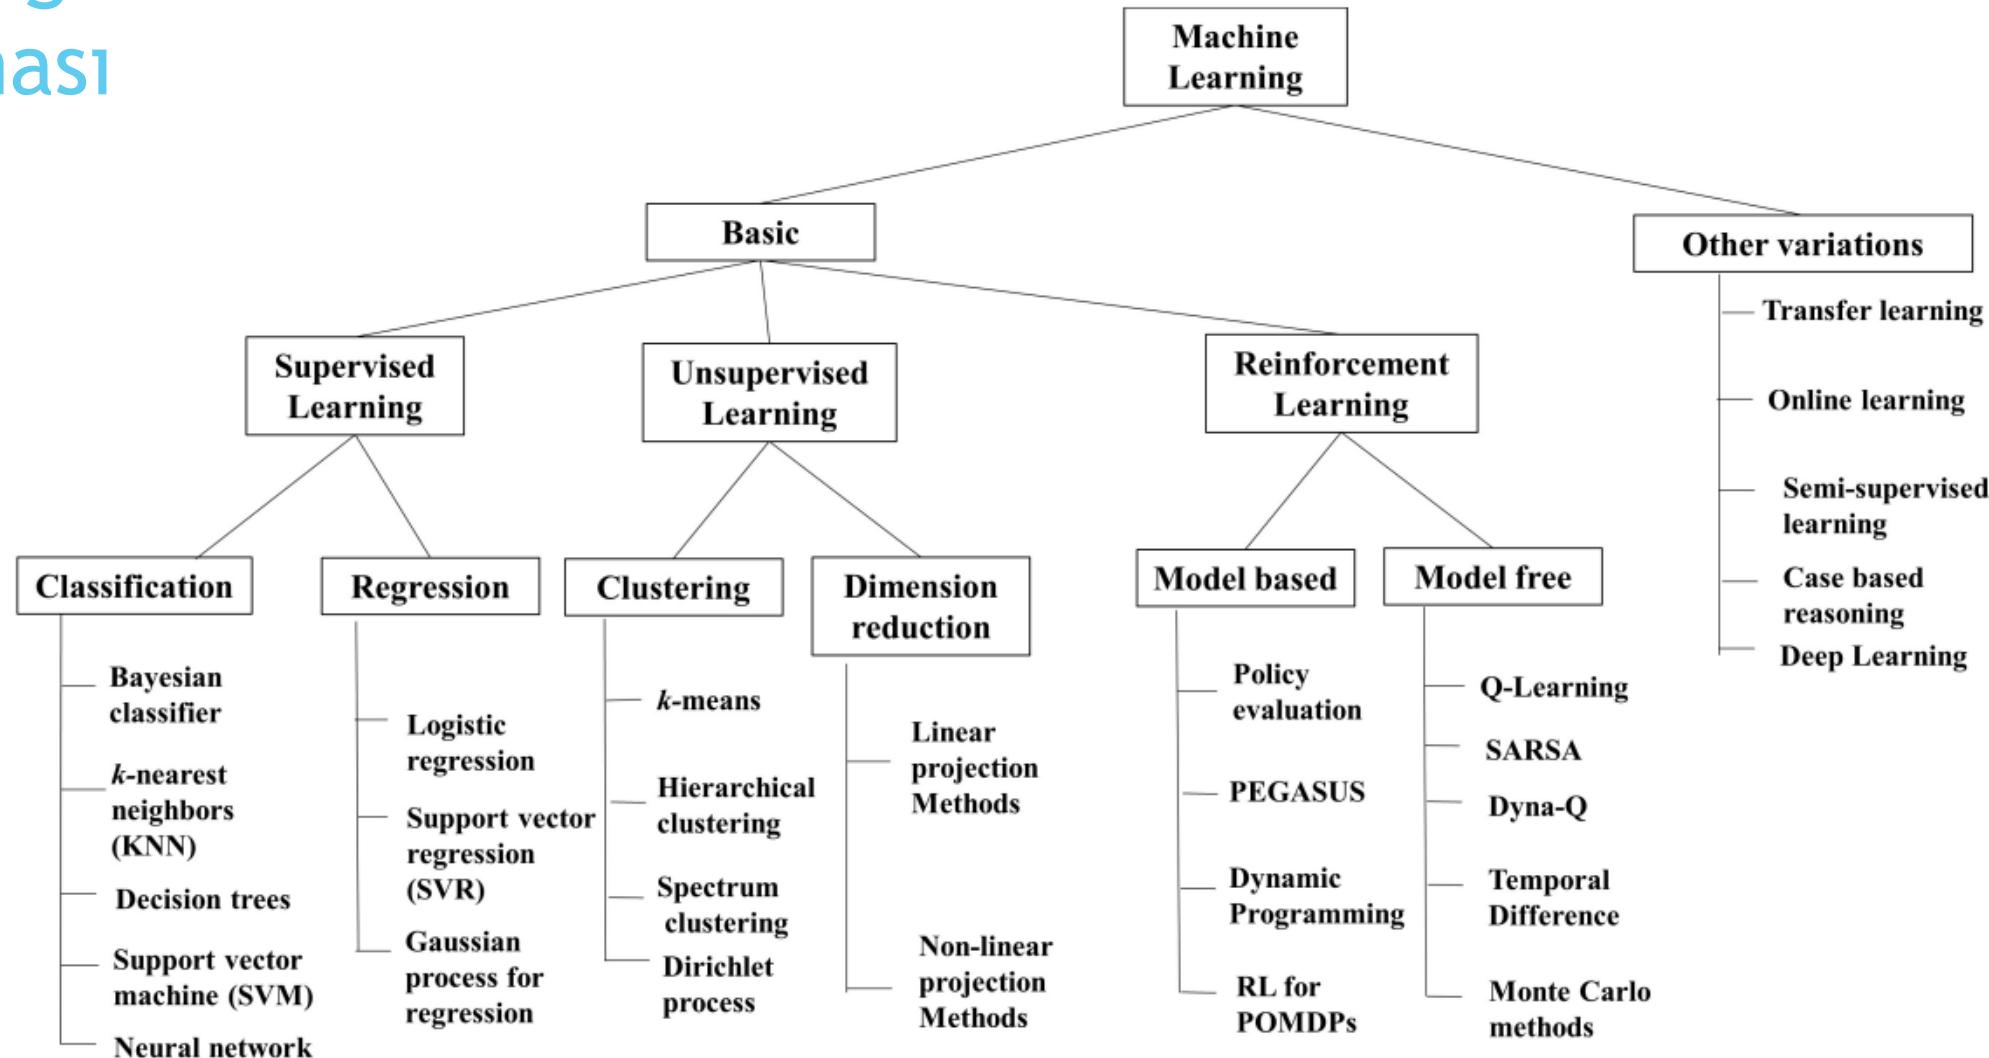
Kaynak: Gao, K., Mei, G., Piccialli, F., Cuomo, S., Tu, J., & Huo, Z. (2020). Julia language in machine learning: Algorithms, applications, and open issues. *Computer Science Review*, 37, 100254.

Yapay Zeka Algoritmalarının Sınıflandırılması

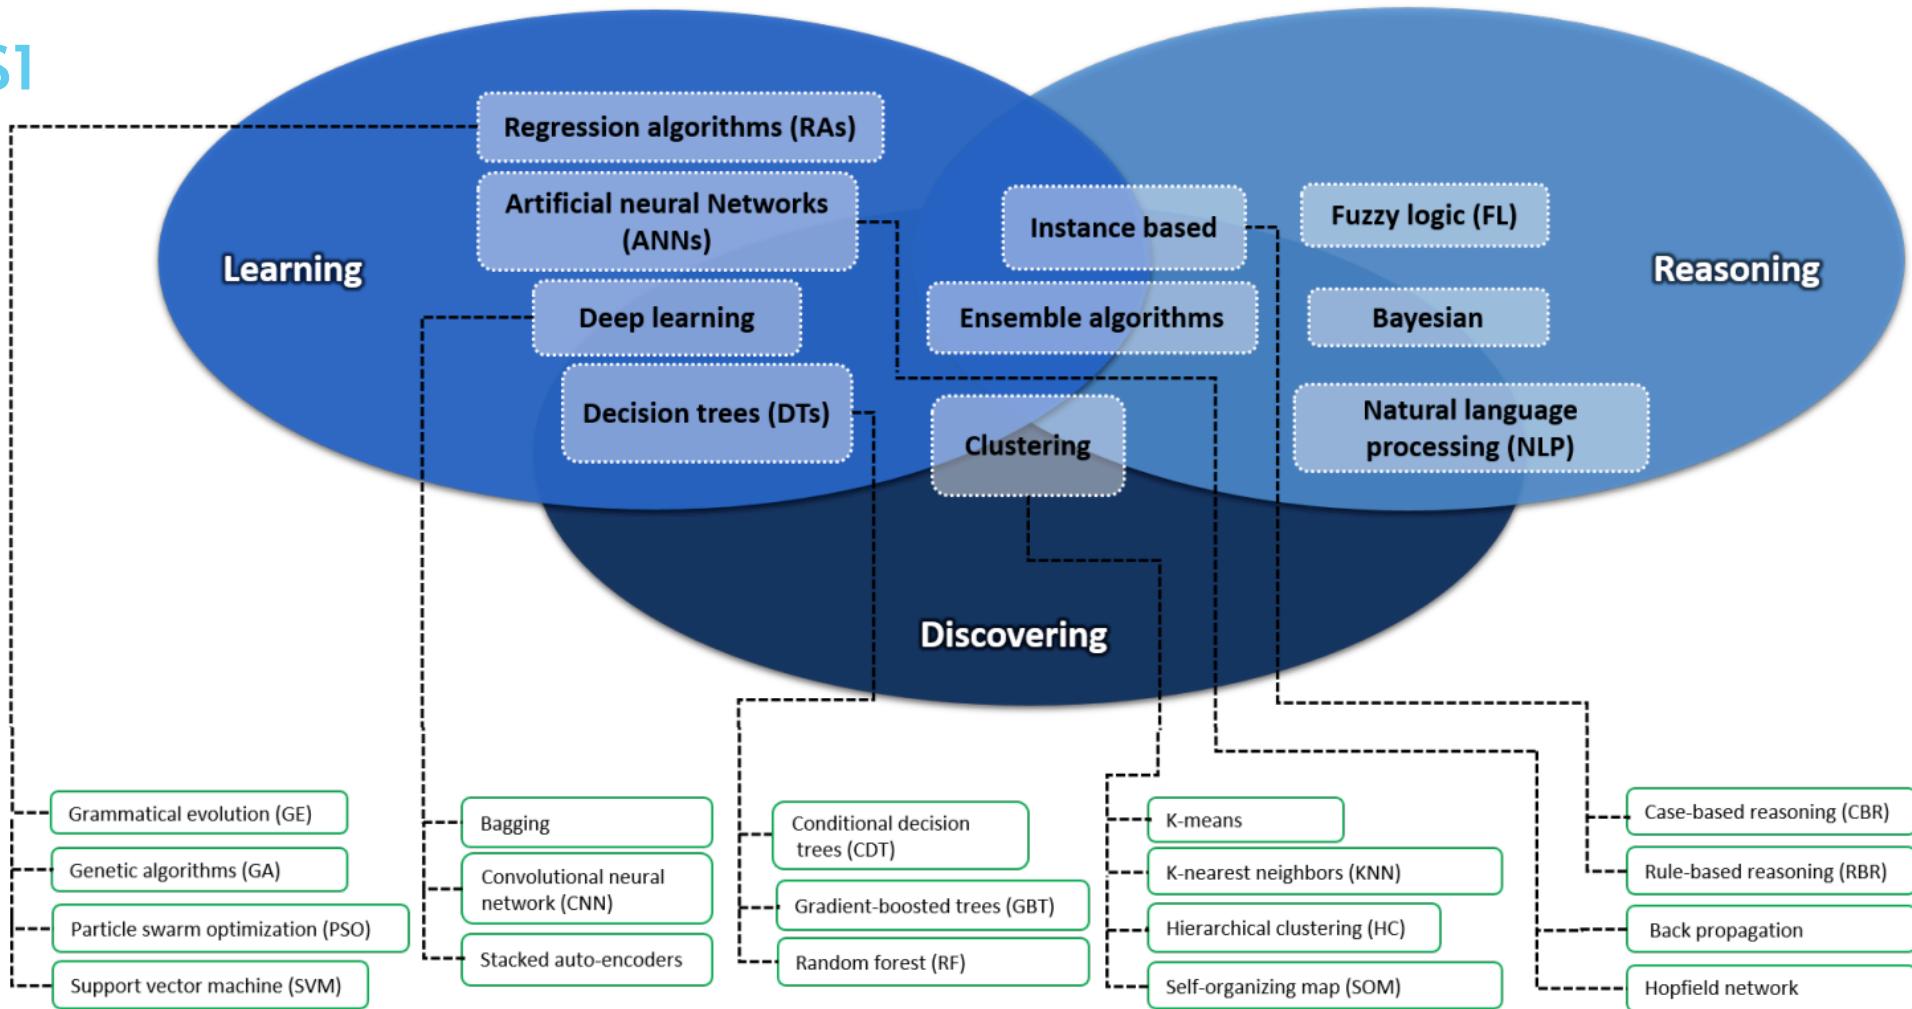
Kaynak: Liu, H., & Lang, B. (2019). Machine learning and deep learning methods for intrusion detection systems: A survey. *Applied Sciences*, 9(20), 4396.



Yapay Zeka Algoritmalarının Sınıflandırılması

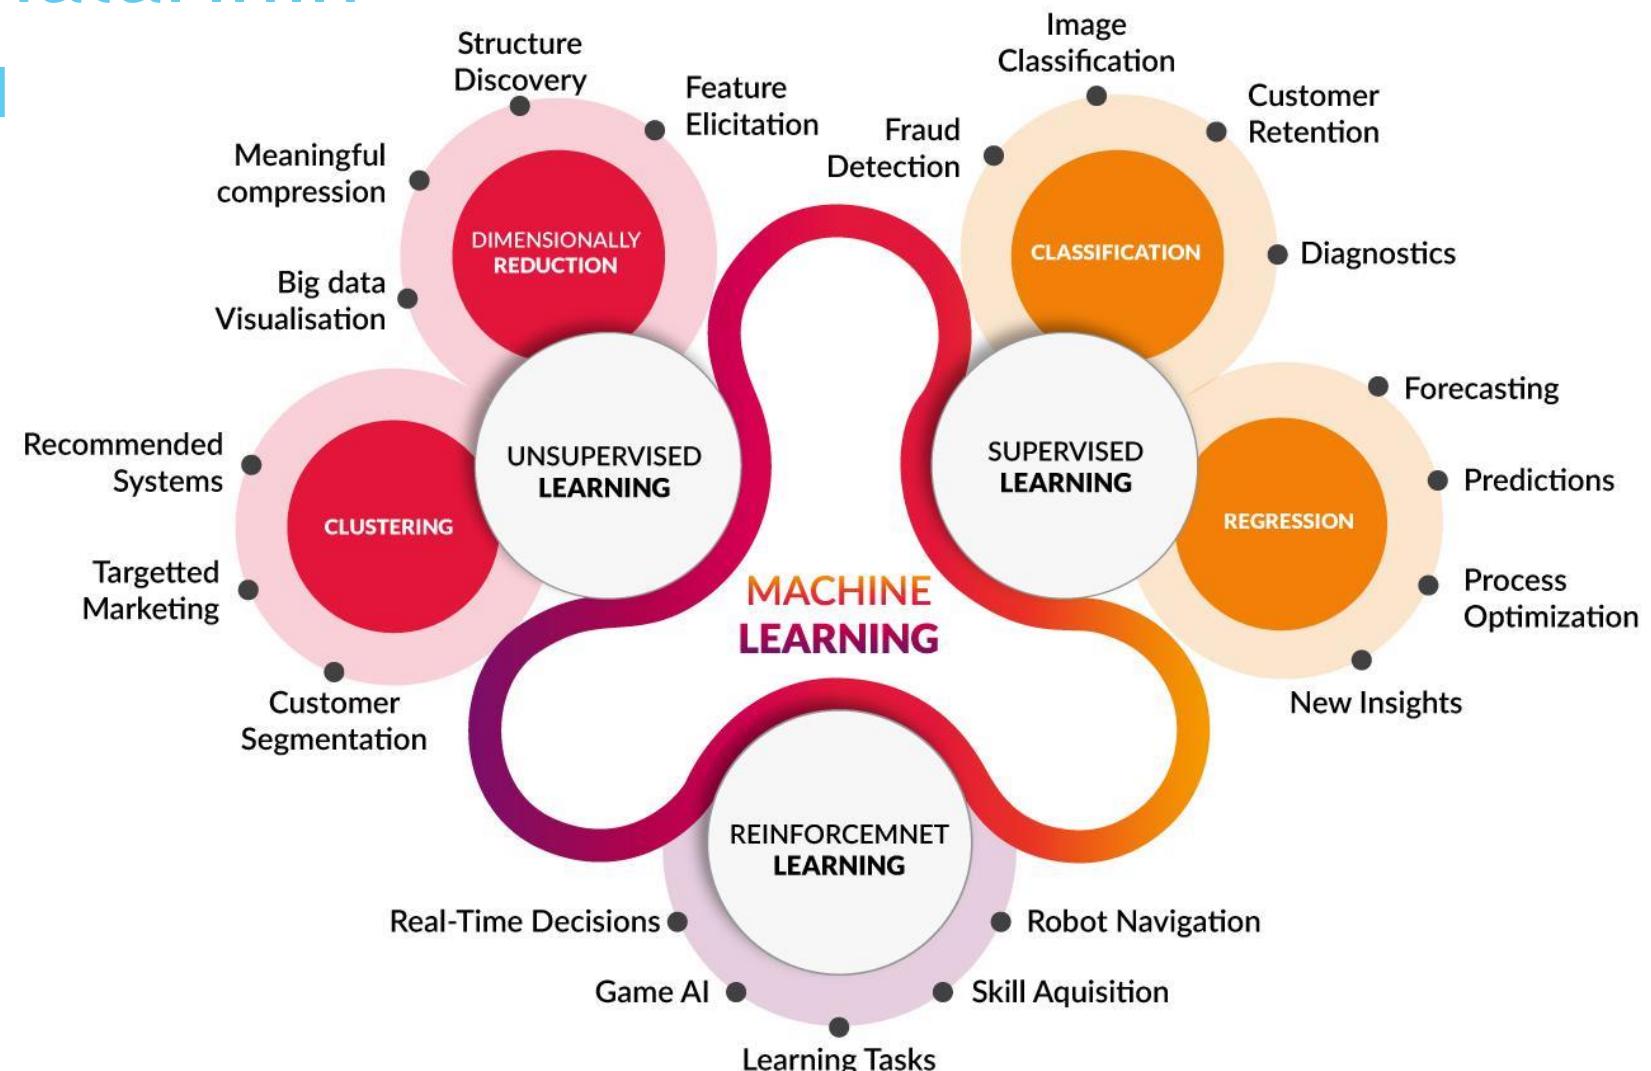


Yapay Zeka Algoritmalarının Sınıflandırılması



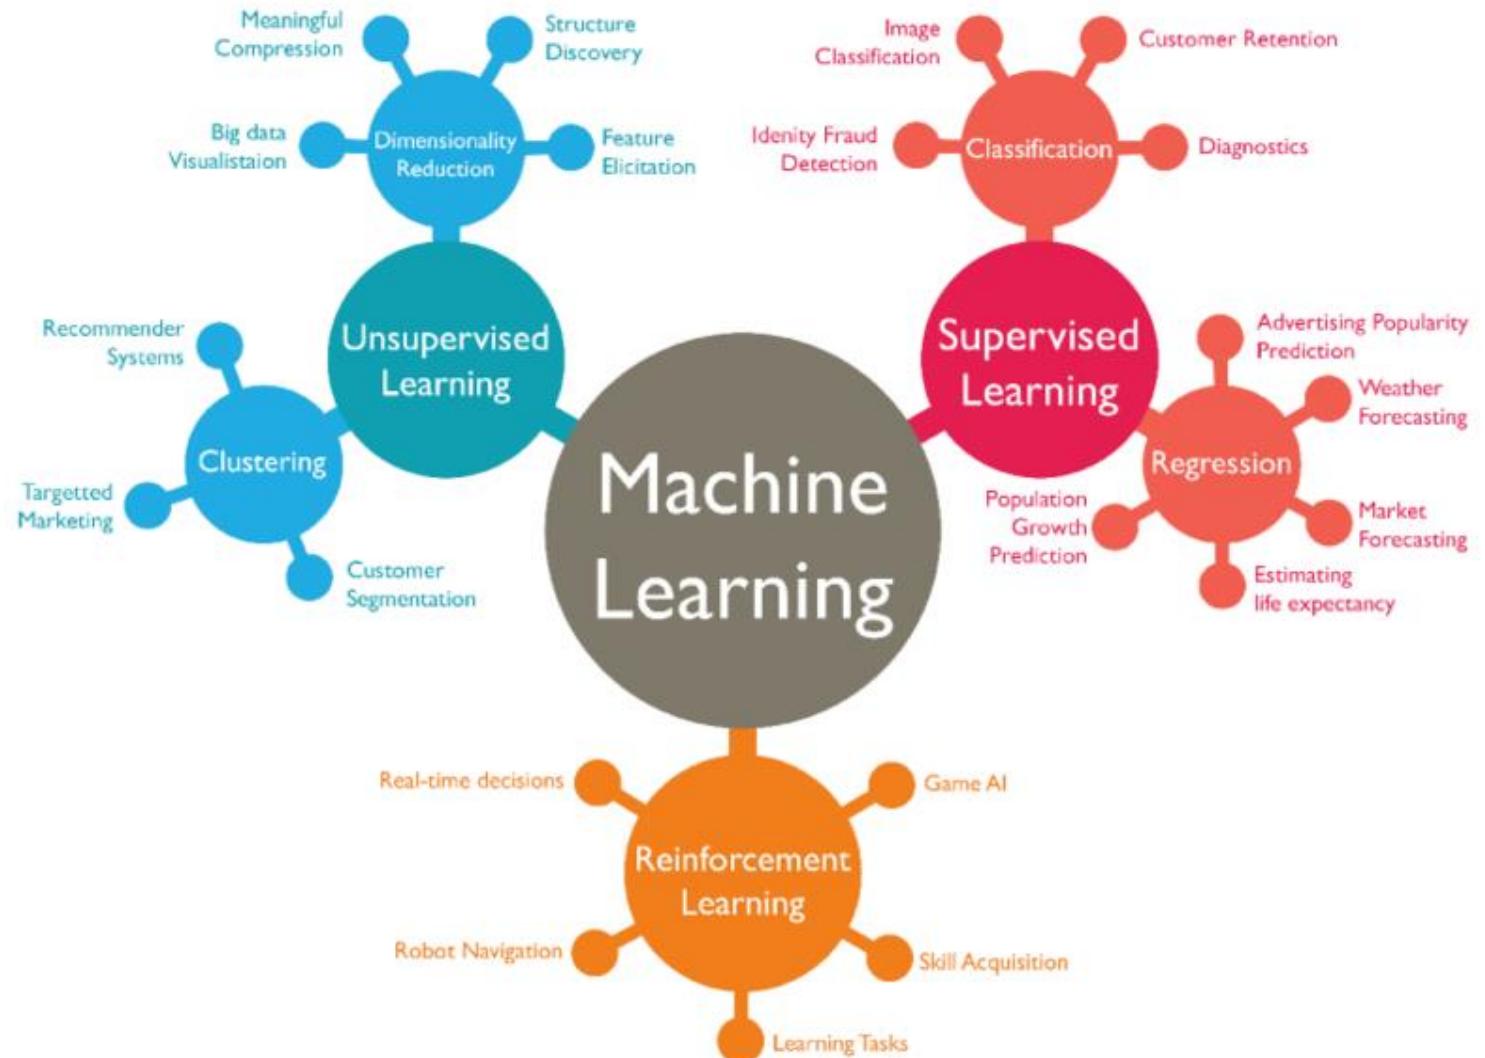
Kaynak: Contreras, I., & Vehi, J. (2018). Artificial intelligence for diabetes management and decision support: literature review. *Journal of Medical Internet Research*, 20(5), e10775.

Yapay Zeka Algoritmalarının Temel Uygulamaları



Kaynak: RPA Infotech Pvt. Ltd.,
<https://twitter.com/ltdrpa/status/1239446198131417096?lang=hi>

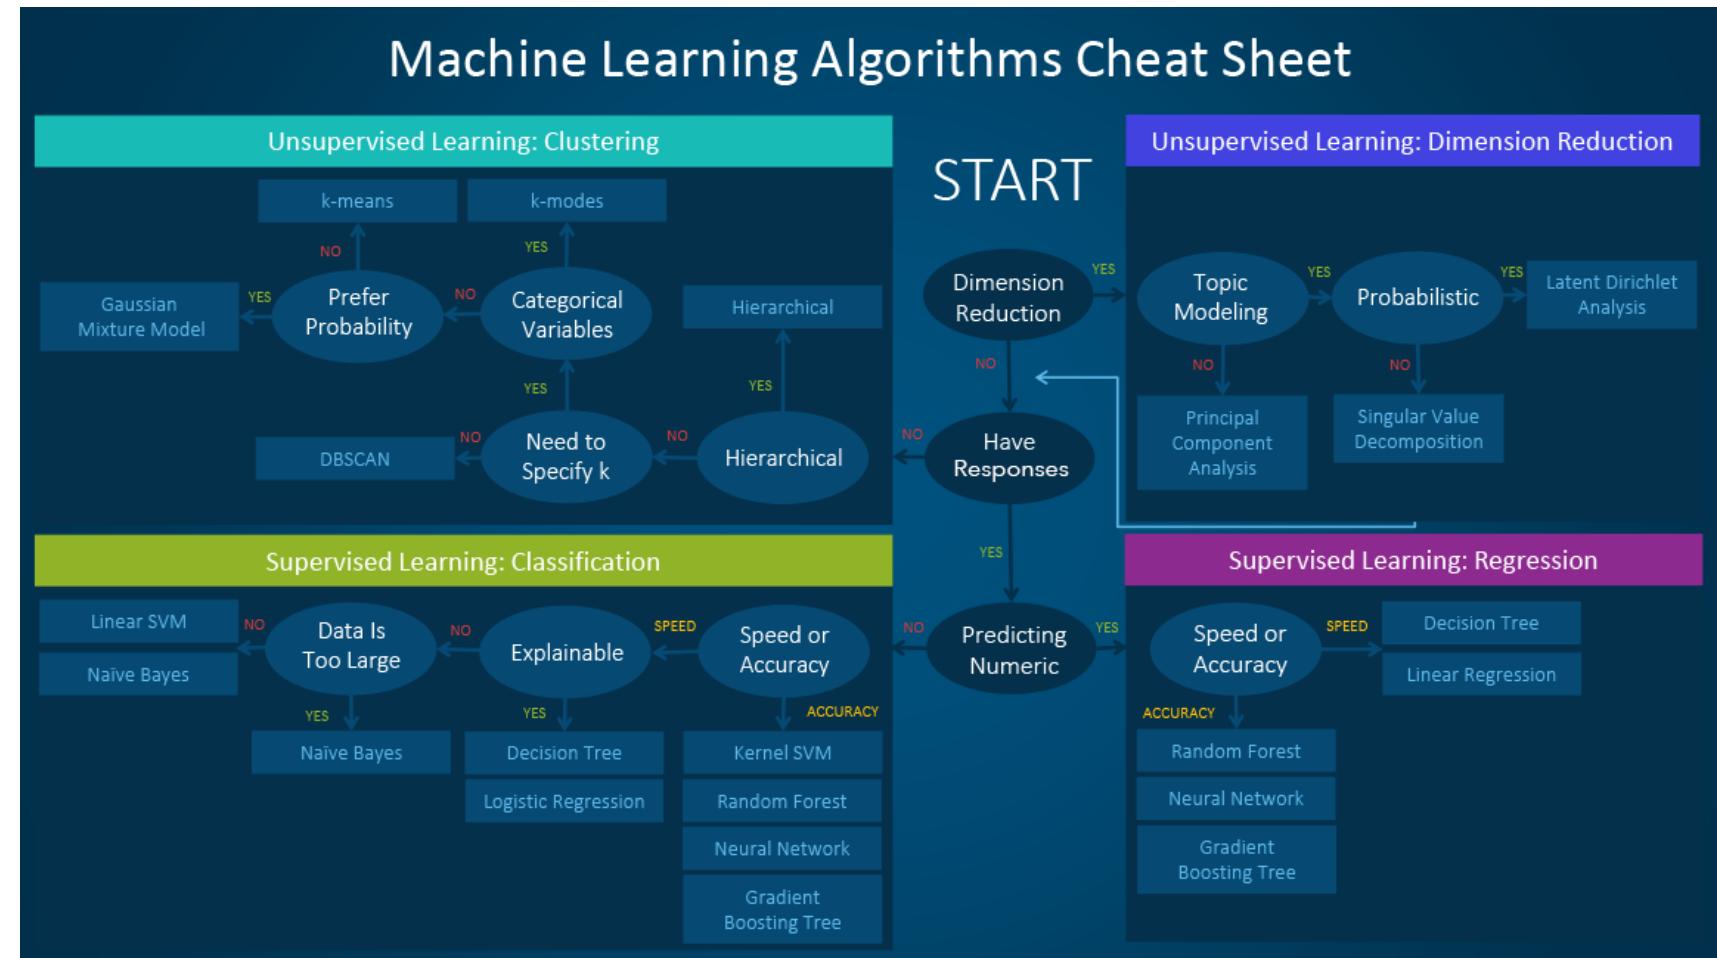
Yapay Zeka Algoritmalarının Temel Uygulamaları



Kaynak:

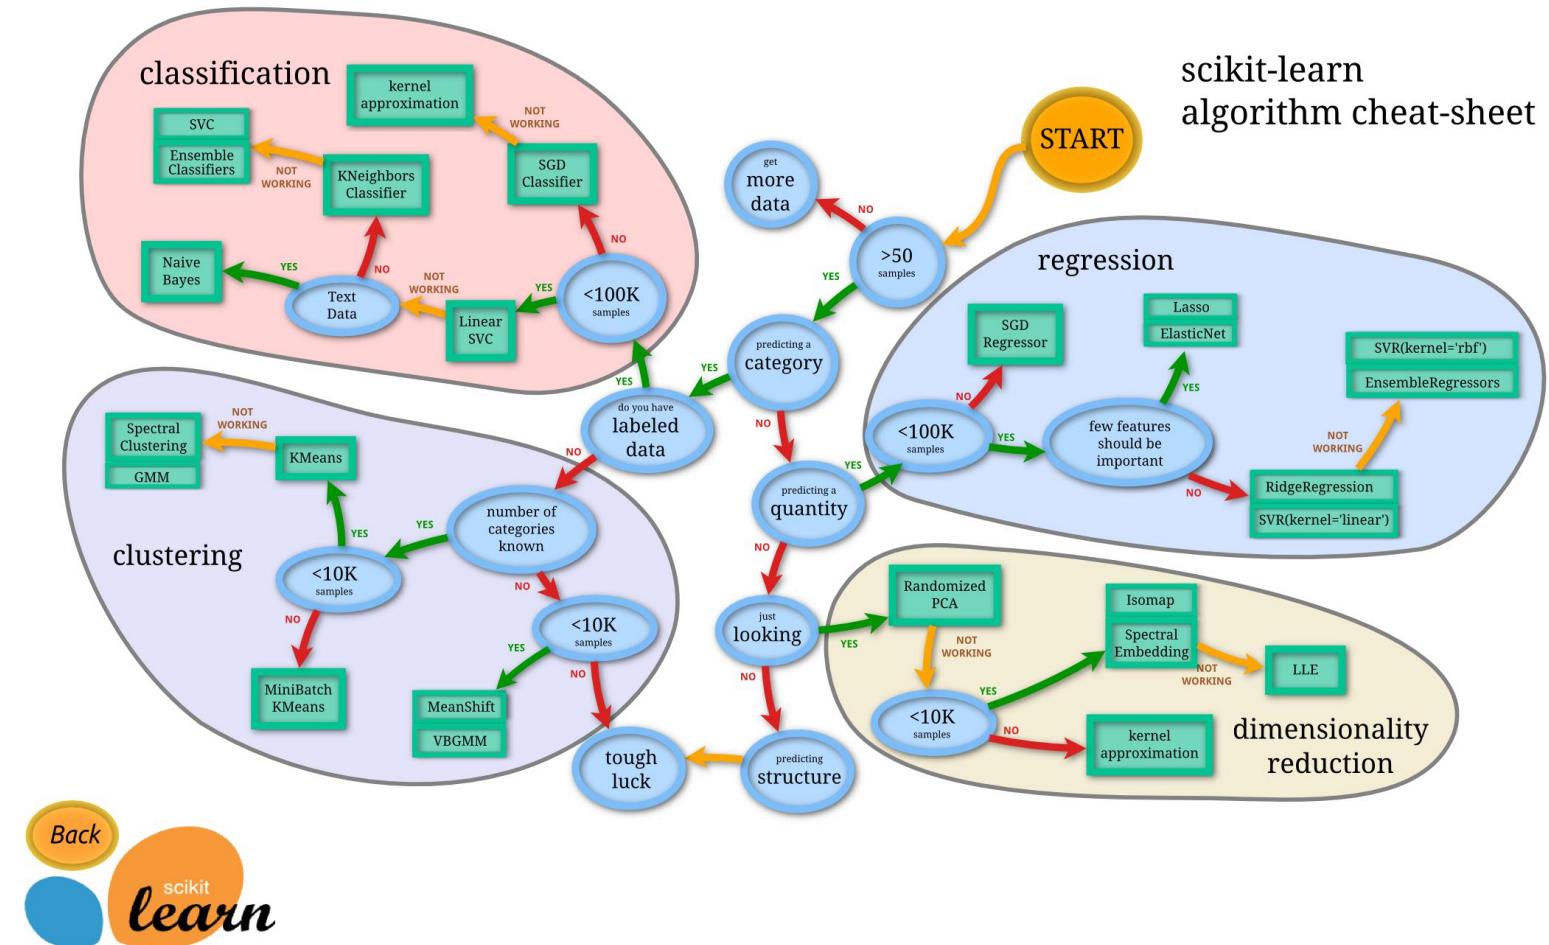
<https://www.sharper.ai/taxonomy-ai/>

Hangi Algoritmayı Kullanmalıyım?

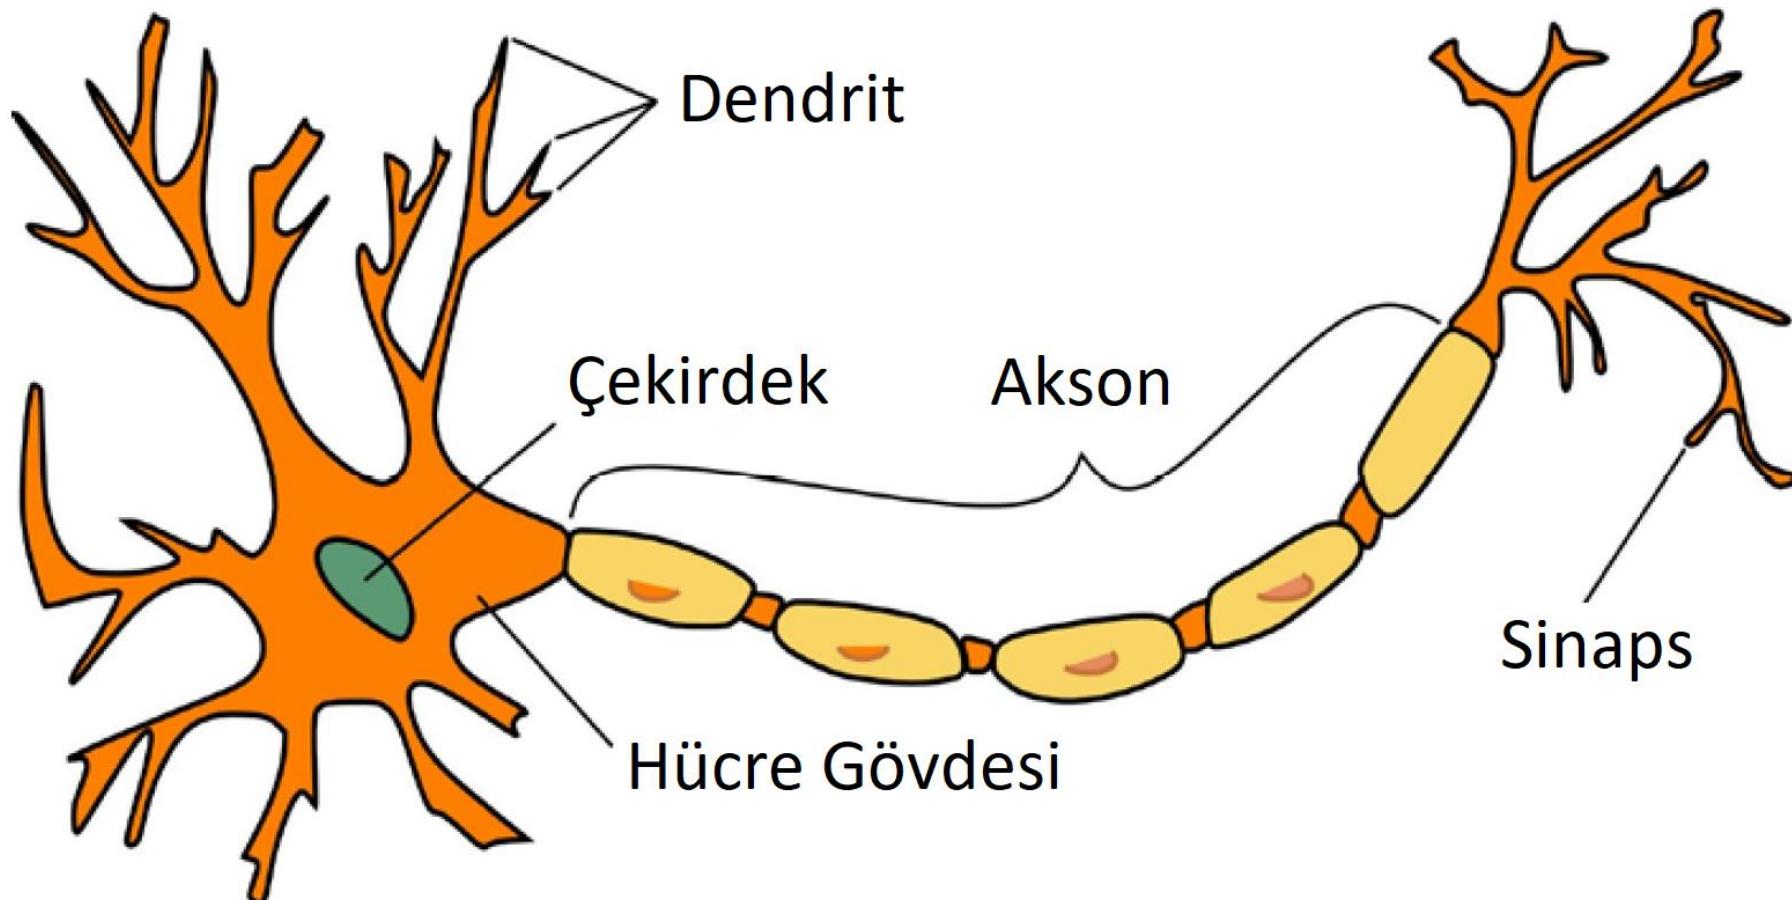


Kaynak: H. Li, ‘Which machine learning algorithm should I use?’,
<https://blogs.sas.com/content/subconsciousmusings/2020/12/09/machine-learning-algorithm-use/>

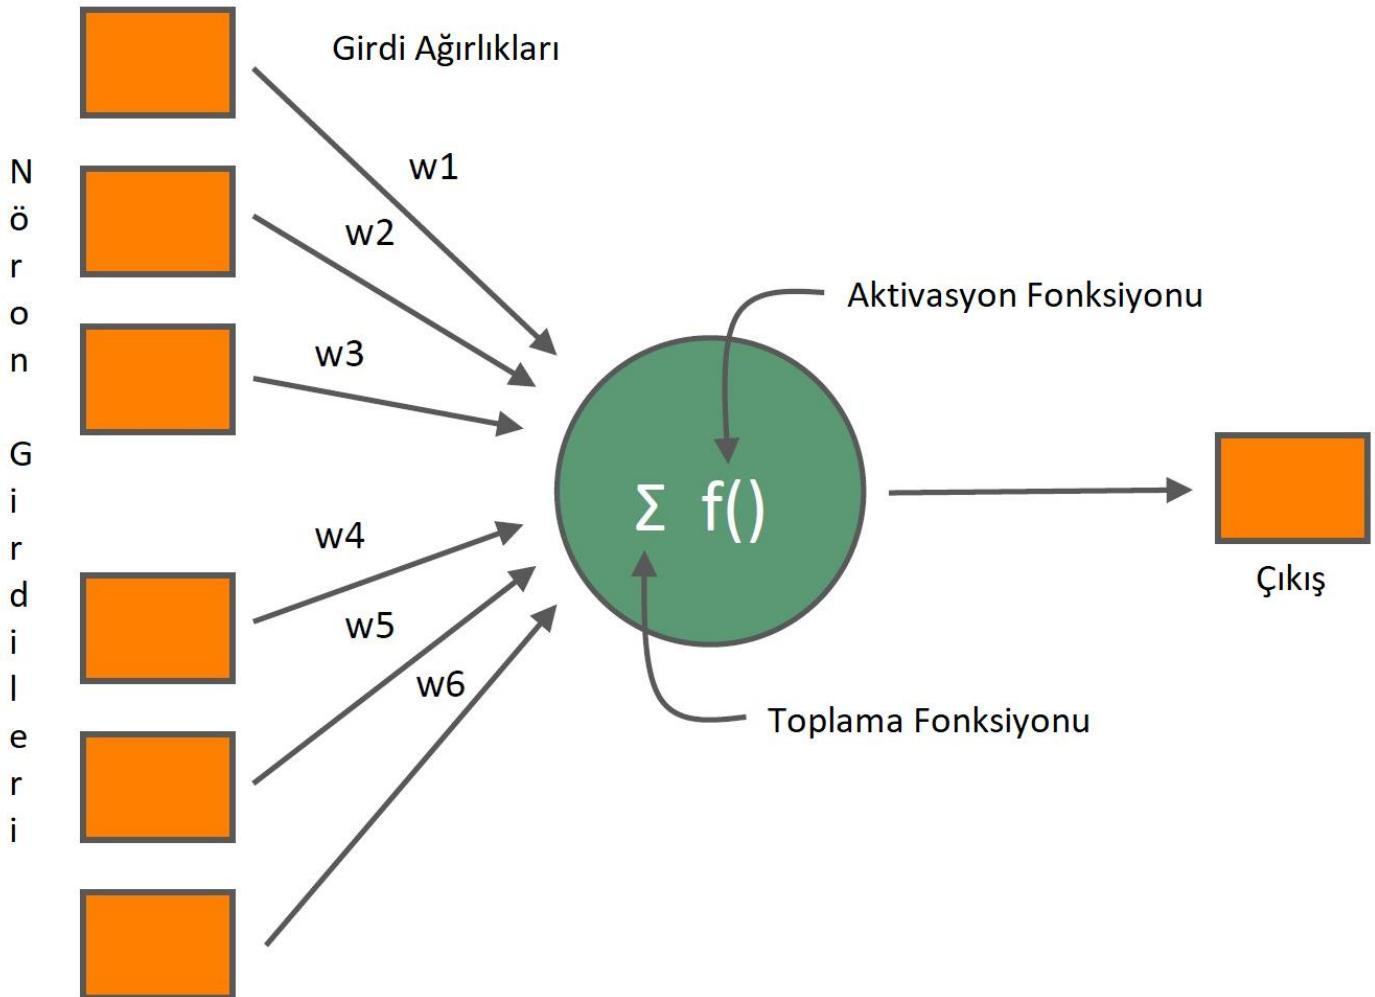
Hangi Algoritmayı Kullanmalıyım?



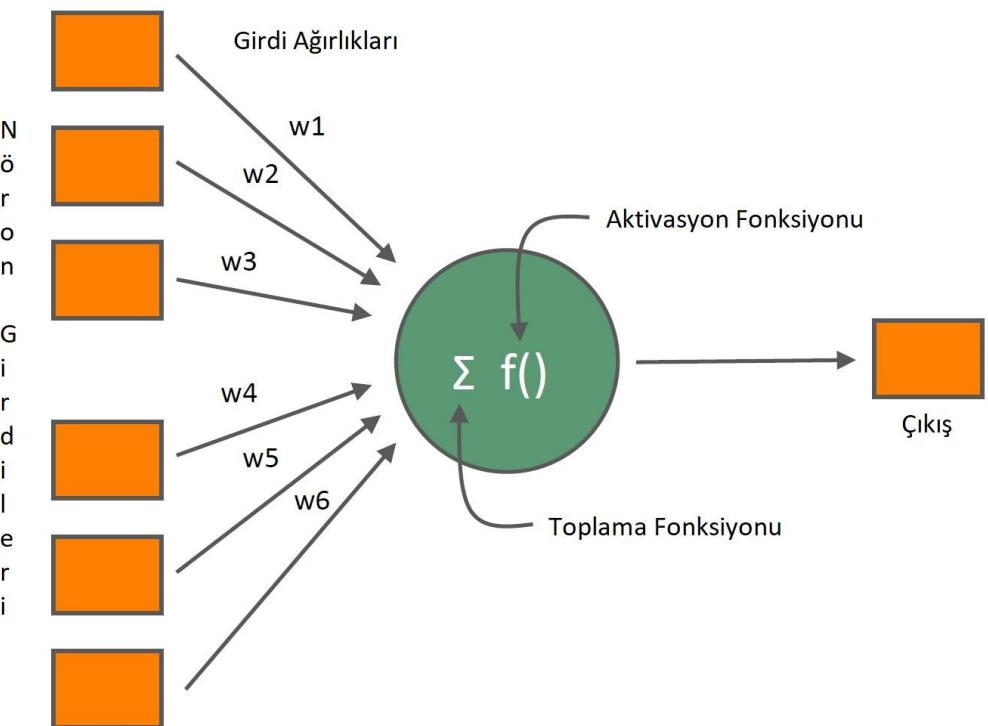
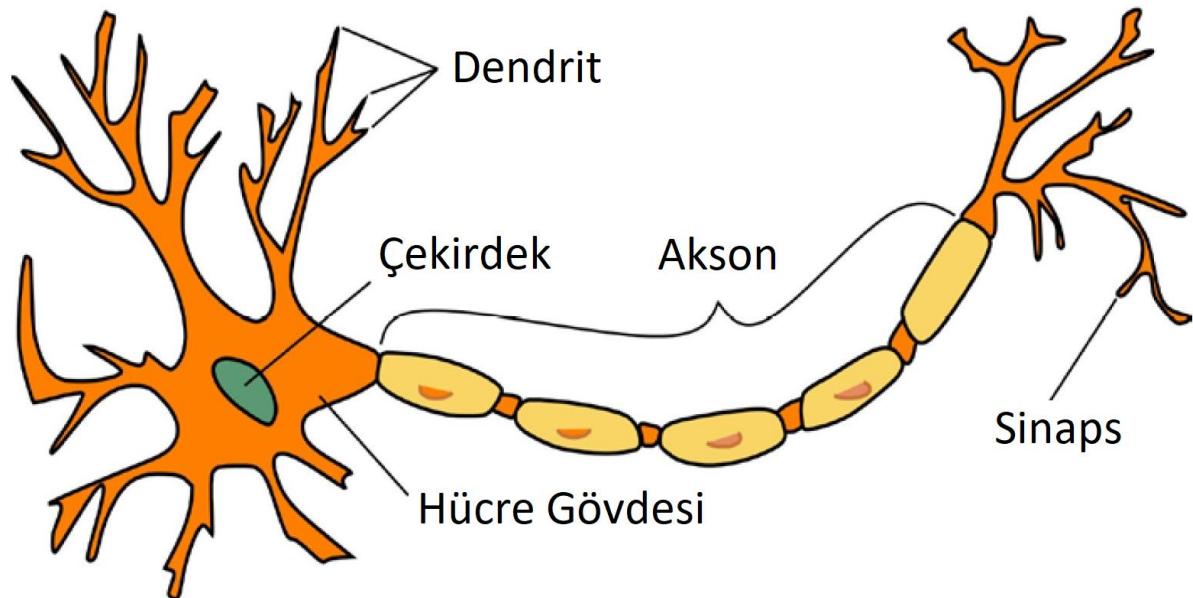
Doğal Sinir Hücresi



Perseptron Fikrine Dayalı Yapay Sinir Hücresi

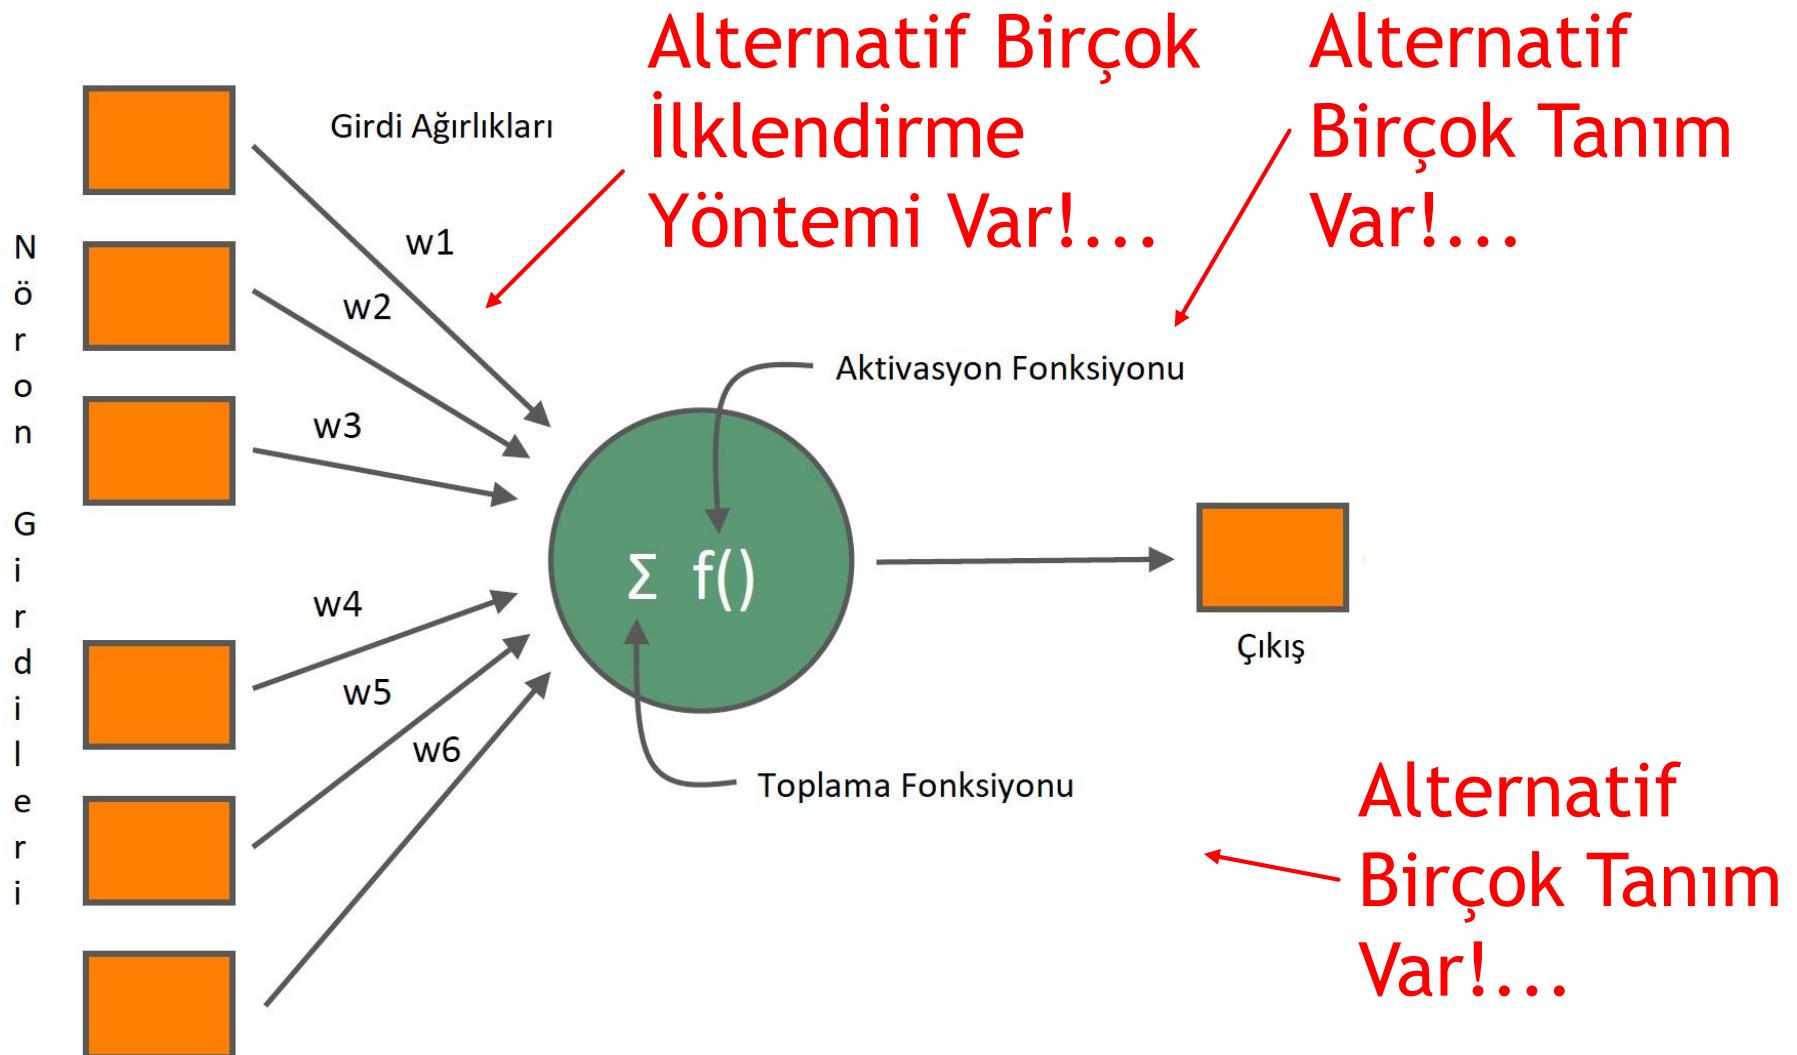


Doğal ve Yapay Sinir Hücresi Karşılaştırma

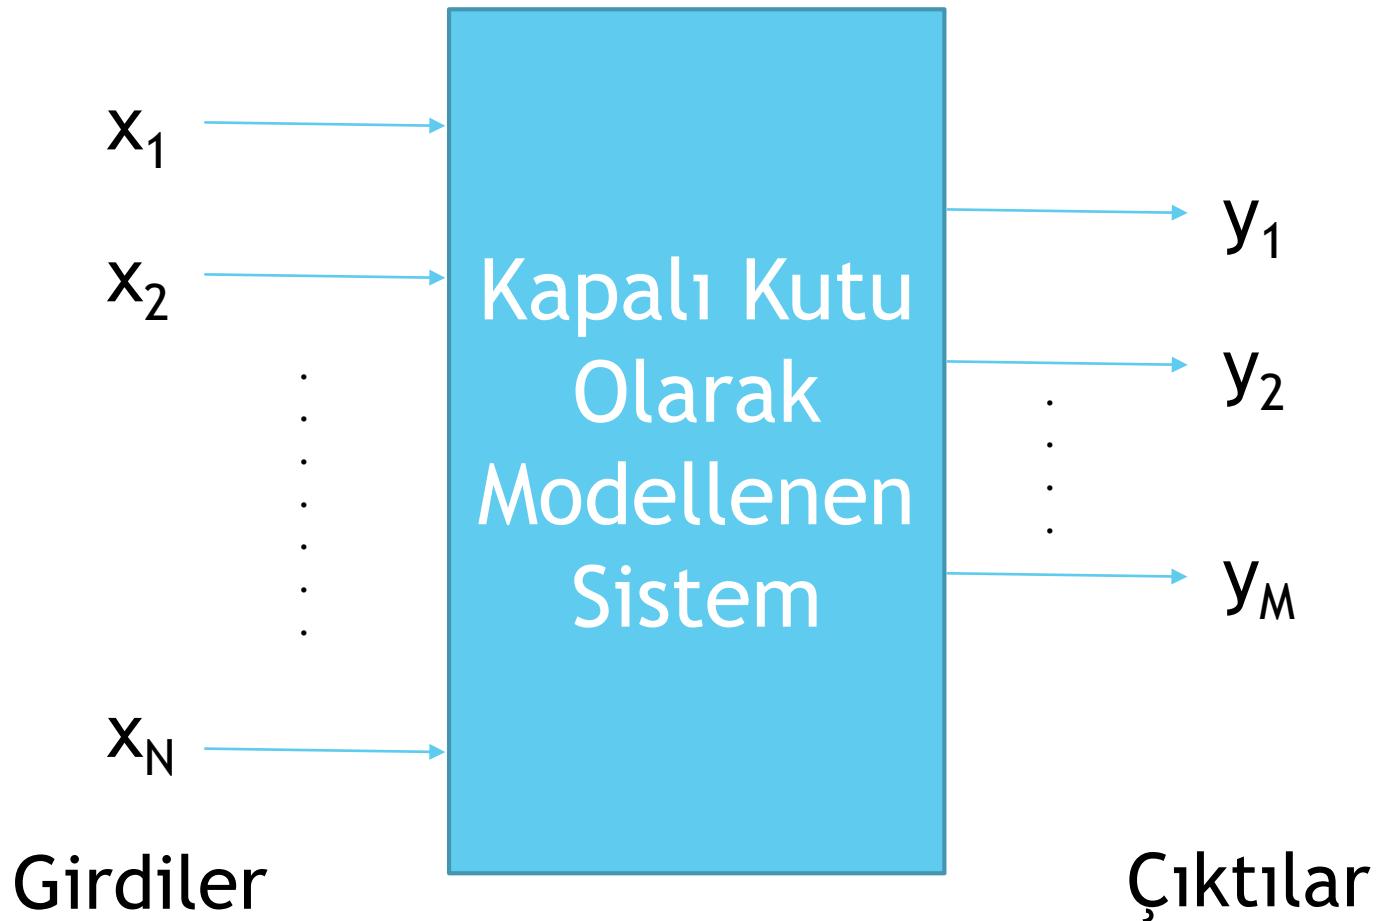


Biyolojik Sinir Hücresi	Yapay Sinir Hücresi
Akson	Çıkış
Dendrit	Toplama Fonksiyonu
Çekirdek	Aktivasyon Fonksiyonu
Sinaps	Girdi Ağırlıkları

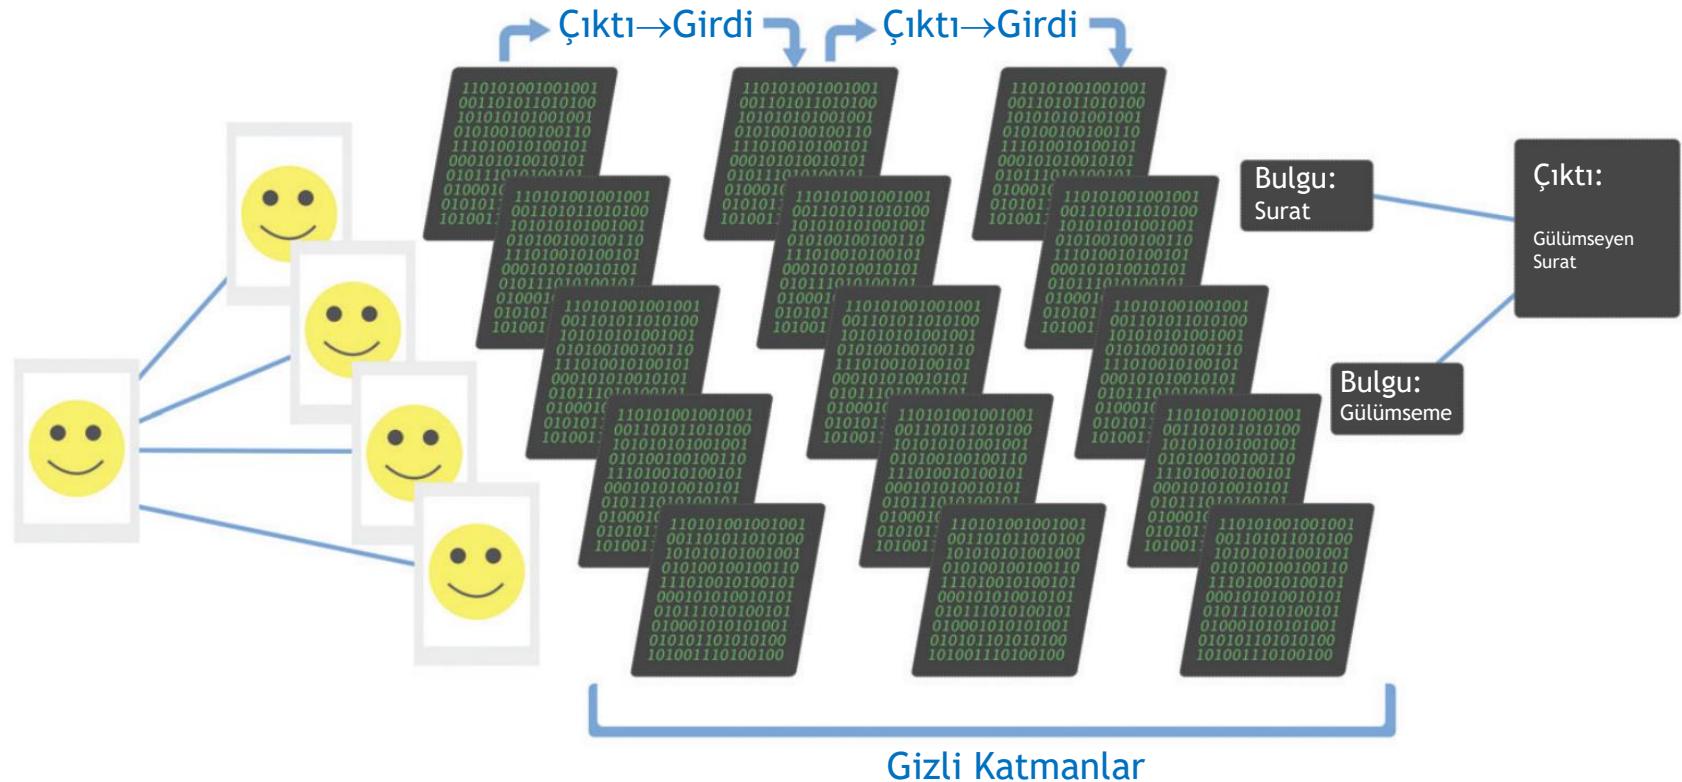
Perseptron Fikrine Dayalı Yapay Sinir Hücresi



Yapay Sinir Ağları - 1

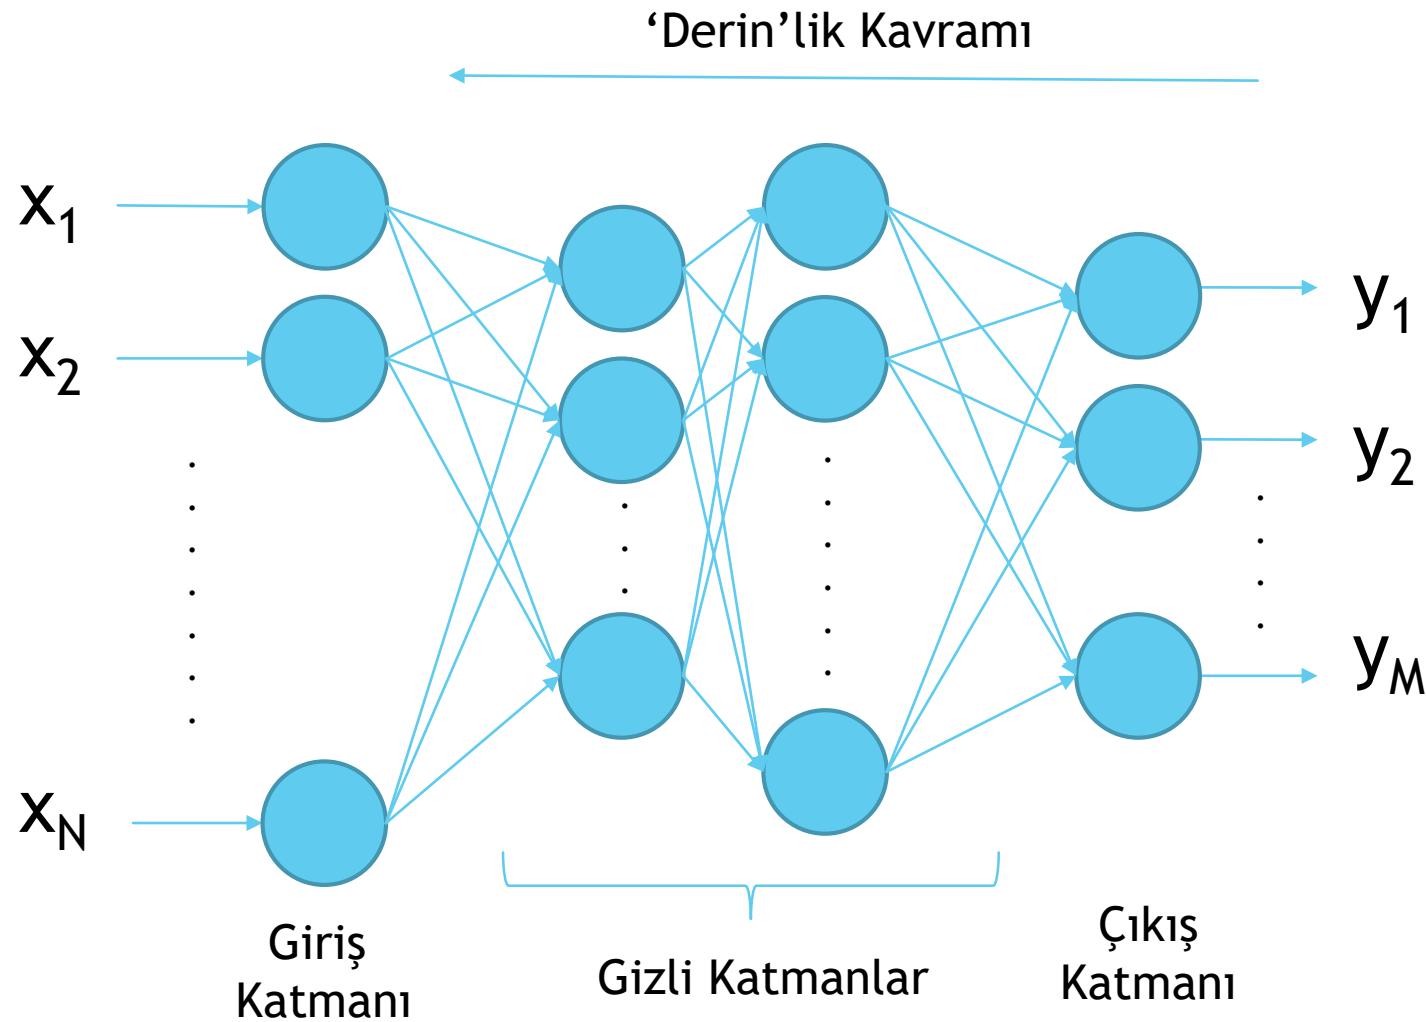


Genel Yapay Zeka Mimarisi



Kaynak: Mintz, Y., & Brodie, R. (2019). Introduction to artificial intelligence in medicine. *Minimally Invasive Therapy & Allied Technologies*, 28(2), 73-81.

Yapay Sinir Ağları - 2



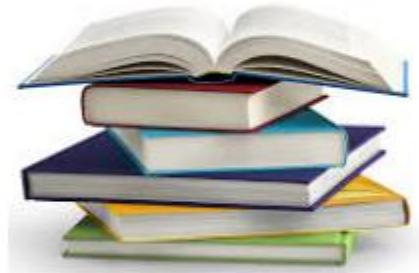
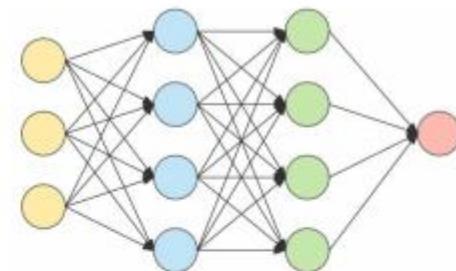
İnsan Öğrenmesi - Makine Öğrenmesi



Zeka



Model



Öğrenme
Materiyalleri



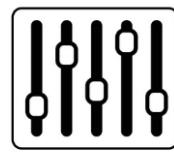
Veri
Seti



Öğrenme
Becerileri



Algoritma
Hiperparametreleri



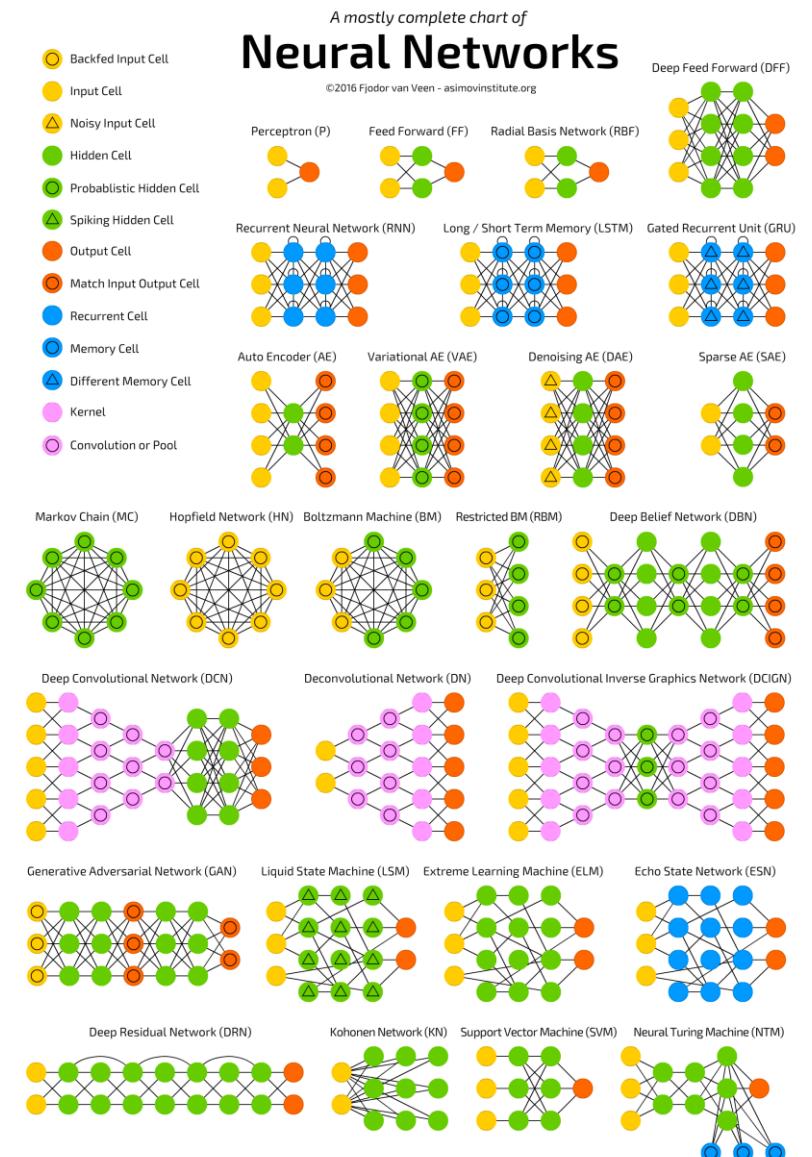
shutterstock.com - 1500306722

Tartışılan Hususlar

- ▶ Yapay Sinir Ağlarında Değiştirilebilecek / Ayarlanabilecek Çok Fazla ‘Şey’ Bulunması
 - ▶ Mimarının Kendisi
 - ▶ Her Bir Mimari İçin
 - ▶ Parametreler
 - ▶ Hiperparametreler
 - ▶ Mimari Hiperparametreleri
 - ▶ Öğrenme Süreci Hiperparametreleri
 - ▶ Stratejiler

Tartışılan Hususlar

- ▶ Yapay Sinir Ağlarında Değiştirilebilecek / Ayarlanabilecek Çok Fazla ‘Şey’ Bulunması
- ▶ Mimarının Kendisi



Kaynak: A. Tch (2017). The mostly complete chart of Neural Networks, explained.

<https://towardsdatascience.com/the-mostly-complete-chart-of-neural-networks-explained-3fb6f2367464>

Tartışılan Hususlar

- ▶ Yapay Sinir Ağlarında Değiştirilebilecek / Ayarlanabilecek Çok Fazla ‘Şey’ Bulunması
 - ▶ Her Bir Mimari İçin
 - ▶ Parametreler
 - ▶ Ağırlık Değerleri (bunların ilk değerleri)
 - ▶ Hiperparametreler
 - ▶ Mimari Hiperparametreleri
 - ▶ Gizli Katman Sayısı
 - ▶ Her Bir Katmandaki Nöron Sayısı; Dropout Oranı
 - ▶ Toplama Fonksiyonu
 - ▶ Aktivasyon Fonksiyonu

Tartışılan Hususlar

- ▶ Her Bir Mimari İçin
 - ▶ Hiperparametreler (devam)
 - ▶ Öğrenme Süreci Hiperparametreleri
 - ▶ Öğrenme Hızı
 - ▶ Aşırı küçük ise yavaş öğrenme ve Gradyant Sıfırlanması
 - ▶ Aşırı büyük ise minimumun üzerinden atlayıp kaçırma ve Gradyant Patlaması
 - ▶ Momentum
 - ▶ Kayıp fonksiyonunun minimumuna hızlı yakınsayabilmek için bir diğer hiperparametre
 - ▶ Minibatch Boyutu
 - ▶ Epoch Sayısı
 - ▶ İterasyon Sayısı (Bir epoch'u tamamlamak için gerekli minibatch sayısı)

Tartışılan Hususlar

- ▶ Her Bir Mimari İçin
- ▶ Stratejiler
 - ▶ Parametre İlklenme Stratejileri (Xavier, He vb.)
 - ▶ Veri Normalizasyon Stratejileri ($[0,1]$ arasında, $N(0,1)$ olacak şekilde, Batch Normalizasyon vb.)
 - ▶ Optimizasyon Stratejileri (Stochastic Gradient Descent, RMSProp, Adam vb.)
 - ▶ Regülarizasyon Stratejileri (Çok sayıda ağırlık değeriniz varsa, Loss fonksiyonunuza ekstra bir ceza terimi eklemek amaçlı; Lasso (L1), Ridge(L2) regülarizasyonu vb.)

Tartışılan Hususlar

- ▶ Veri Seti Kaynaklı Hususlar (Etiketsiz, Çok Etiketli, Dengesiz, Doğrulanmamış, vb.)
 - ▶ Tekrarlanabilirlik
 - ▶ Duruma Dayalı Eğitim
 - ▶ Yanlılık, Açıklanabilirlik, Şeffaflık, Hesap Verilebilirlik, Gerekçelendirilebilirlik (Hikmetten Sual Olunması 😊)
 - ▶ Şartlı Tahliye, Görüntü İşleme, İşbirlikçi Filtreleme Örnekleri
 - ▶ Kişisel Verilerin Korunması
 - ▶ Çalışma Ekonomisi Üzerine Etkiler
 - ▶ Etik ve Hukuki Konular
 - ▶ vb.
-
- ▶ İnsanları Tembelliğe Sevk Etmesi?

Klasik Avantajlar - Dezavantajlar Slaytı



- Doğrusal olmayan çok boyutlu, gürültülü, eksik bilgili ve özellikle problemin çözümünde kesin bir matematiksel modelin veya algoritmanın bulunmadığı durumlarda başarılı
- İstisnai ve anormal veri sayısı çok olan konularda iyi sonuçlar vermekte
- Adaptasyon yeteneği bulunmakta
- Bilgiler ağın tamamında saklanmakta
- Daha önce görülmemiş örnekler hakkında bilgi üretebilmekte
- ‘Kara Kutu’, verdiği sonucun açıklamasını yapamamakta
- Uygun ağ yapısının belirlenmesinde belli bir kural bulunmamakta
- Ağın parametre değerlerinin belirlenmesinde belli bir kural bulunmamakta
- Eğitim örnekleri seçiminde genel bir kural bulunmamakta
- Öğrenilecek problemin ağa gösterimi önemli bir sorun
- Ağın eğitiminin ne zaman bitirilmesi gereğine ilişkin belli bir yöntem bulunmamakta

Şeffaf, Açıklanabilir ve Hesap Verebilir Yapay Zeka

Prof. Dr. A. Egemen YILMAZ

Ankara Üniversitesi

Mühendislik Fakültesi Elektrik-Elektronik Mühendisliği Bölümü

Mühendislik Fakültesi Yazılım Mühendisliği Bölümü

Fen Bilimleri Enstitüsü Disiplinler Arası Yapay Zeka Teknolojileri Ana Bilim Dalı

Akıllı Sistemler ve Teknolojiler Uygulama ve Araştırma Merkezi (ASTAM)

Başlarken

Uygulamalar



IBM Watson

A photograph of the IBM Watson computer system competing on the game show Jeopardy!. The screen shows the names of the contestants: Ken Jennings, Watson, and Brad Rutter, along with their scores: \$200, \$4,000, and \$600 respectively. Below the screen, a bar chart displays the confidence levels of Watson's answers: 96%, 11%, and 7% for the three categories shown.

Alpha Go

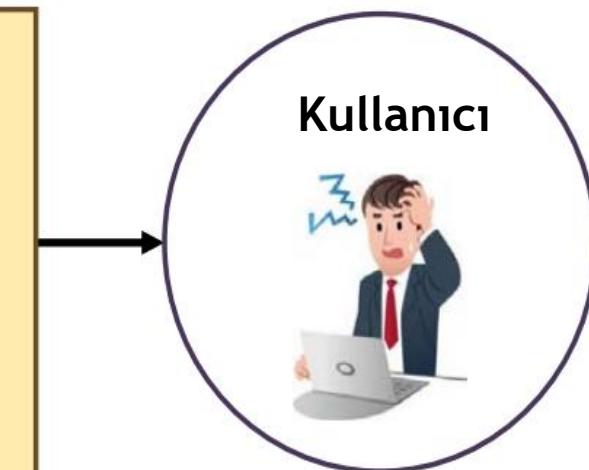
A photograph of a Go board with black and white stones arranged in a game board pattern. The caption below reads: "©Marcin Bajer/Flickr".

Ortak Sezim (Sense-Making)

A photograph of a person in a flight suit sitting at a desk with multiple computer monitors displaying flight simulation or sensor data. The caption below reads: "©NASA.gov".

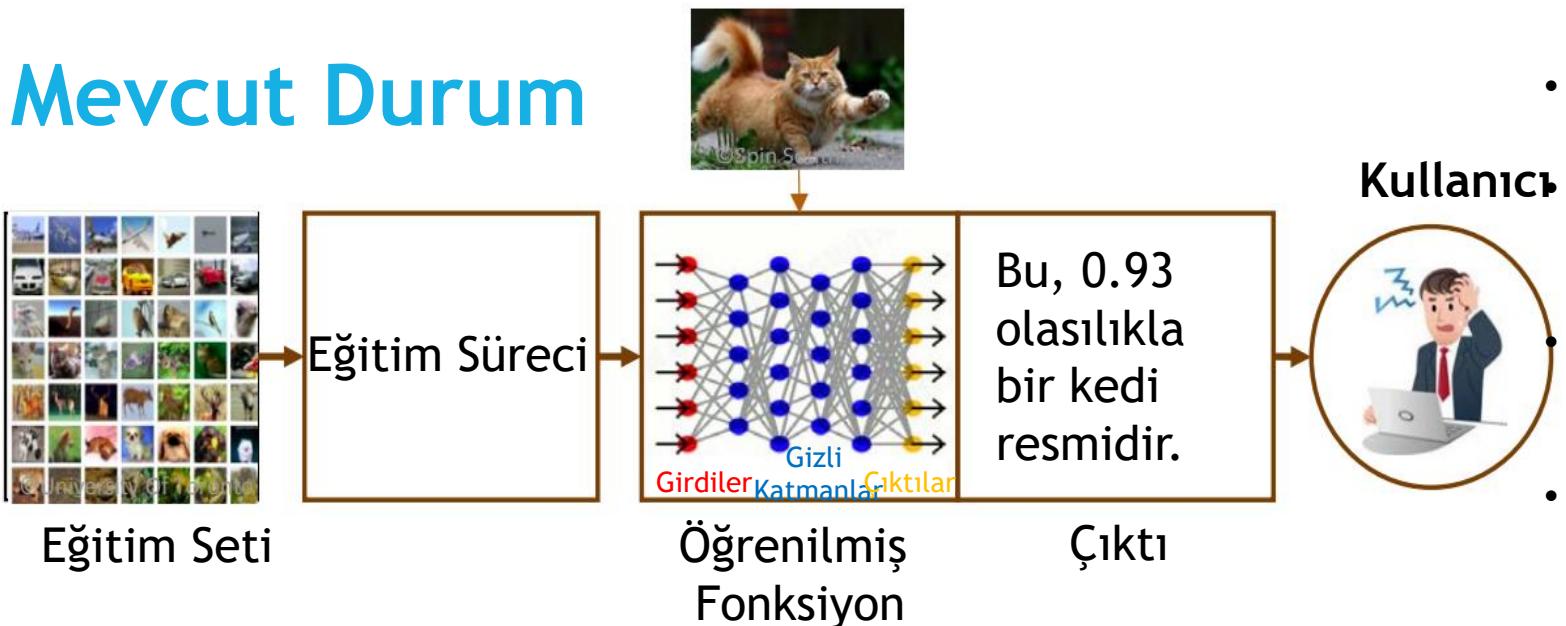
Operasyonel Uygulamalar

A photograph of a quadruped military robot standing outdoors next to a soldier in camouflage gear. The caption below reads: "DARPA, US Defense Advanced Research Projects Agency, US Marine Corps".



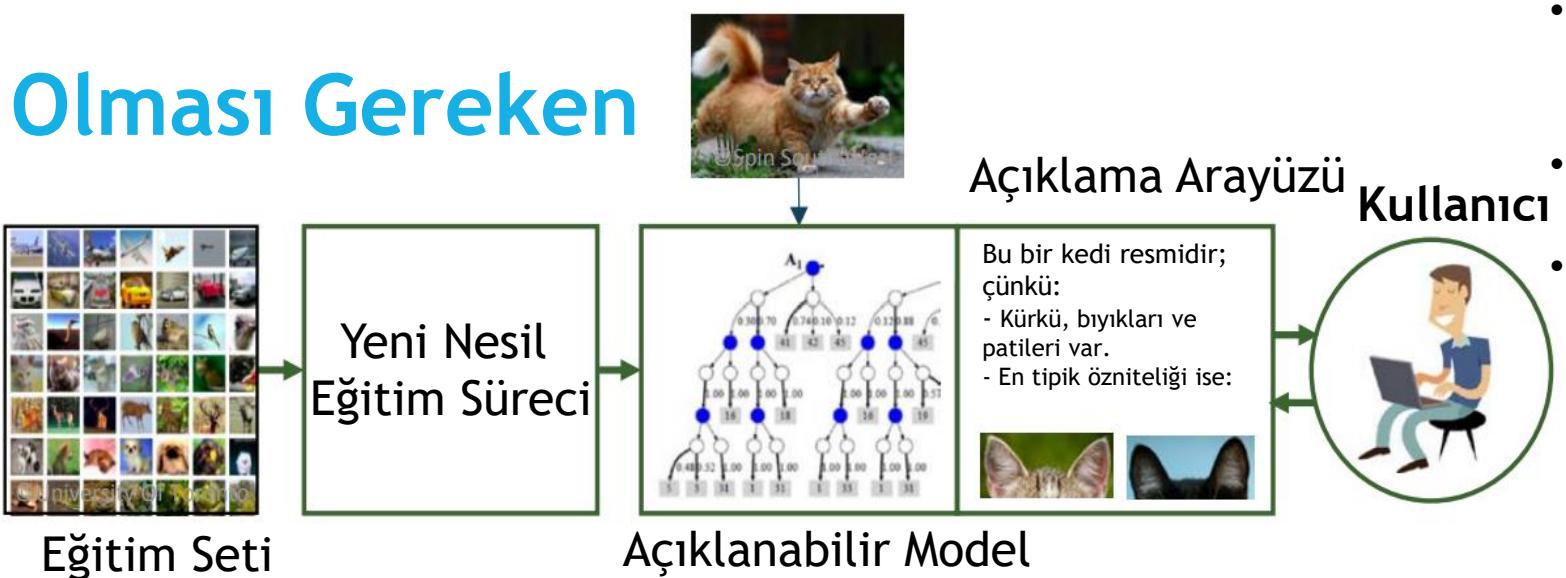
- Sistem bu kararı nasıl ve neden oluşturdu?
- Başarılı bir sonuç elde etmediğimden nasıl emin olabilirim?
- Herhangi bir hata olması durumunda nasıl müdahale edebilirim?
- vb.

Mevcut Durum



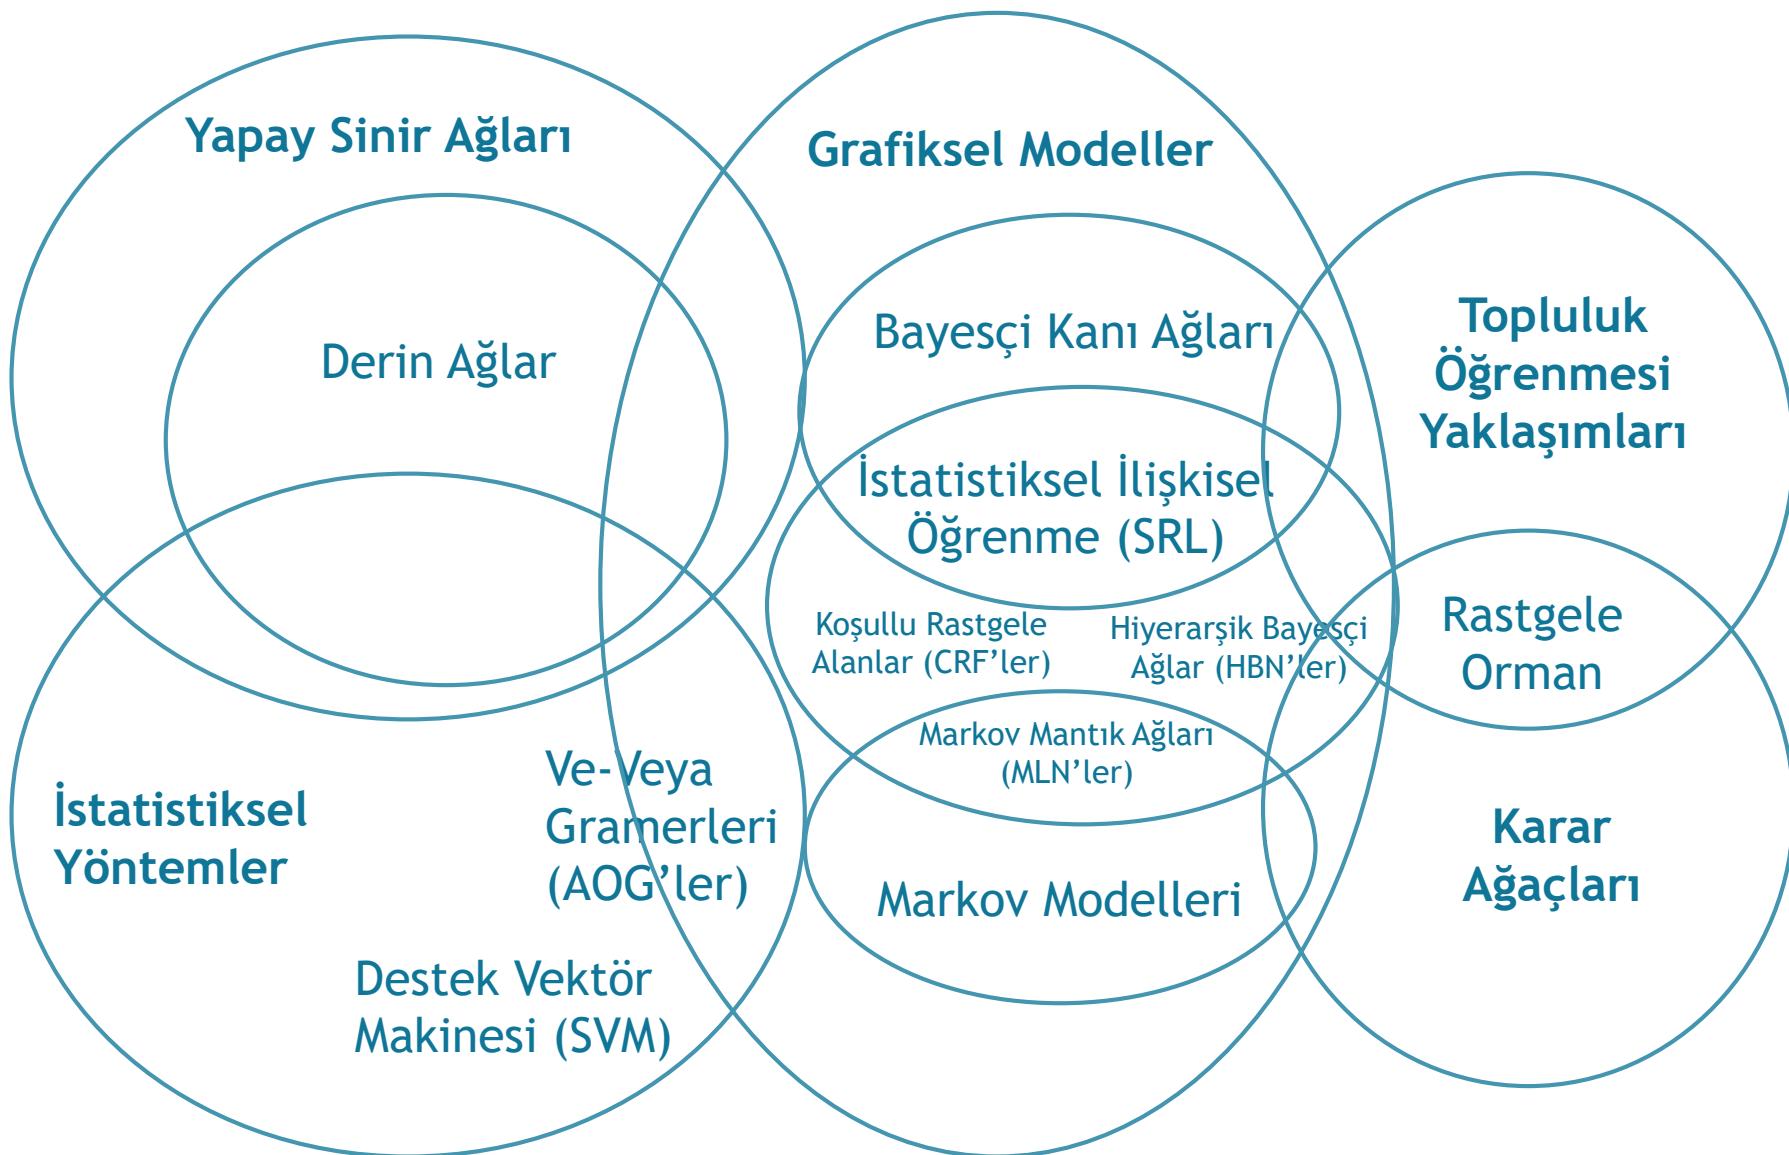
- Sistem bu kararı nasıl ve neden oluşturdu?
- Başarılı bir sonuç elde etmediğimden nasıl emin olabilirim?
- Herhangi bir hata olması durumunda nasıl müdahale edebilirim?
- vb.

Olması Gereken

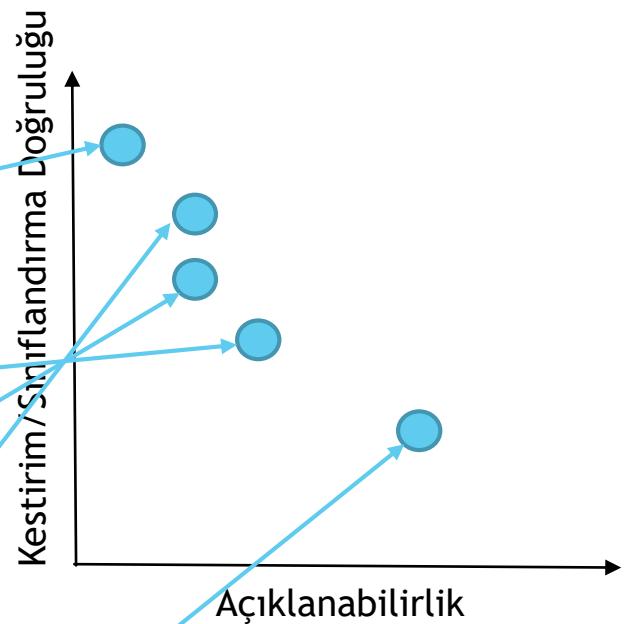
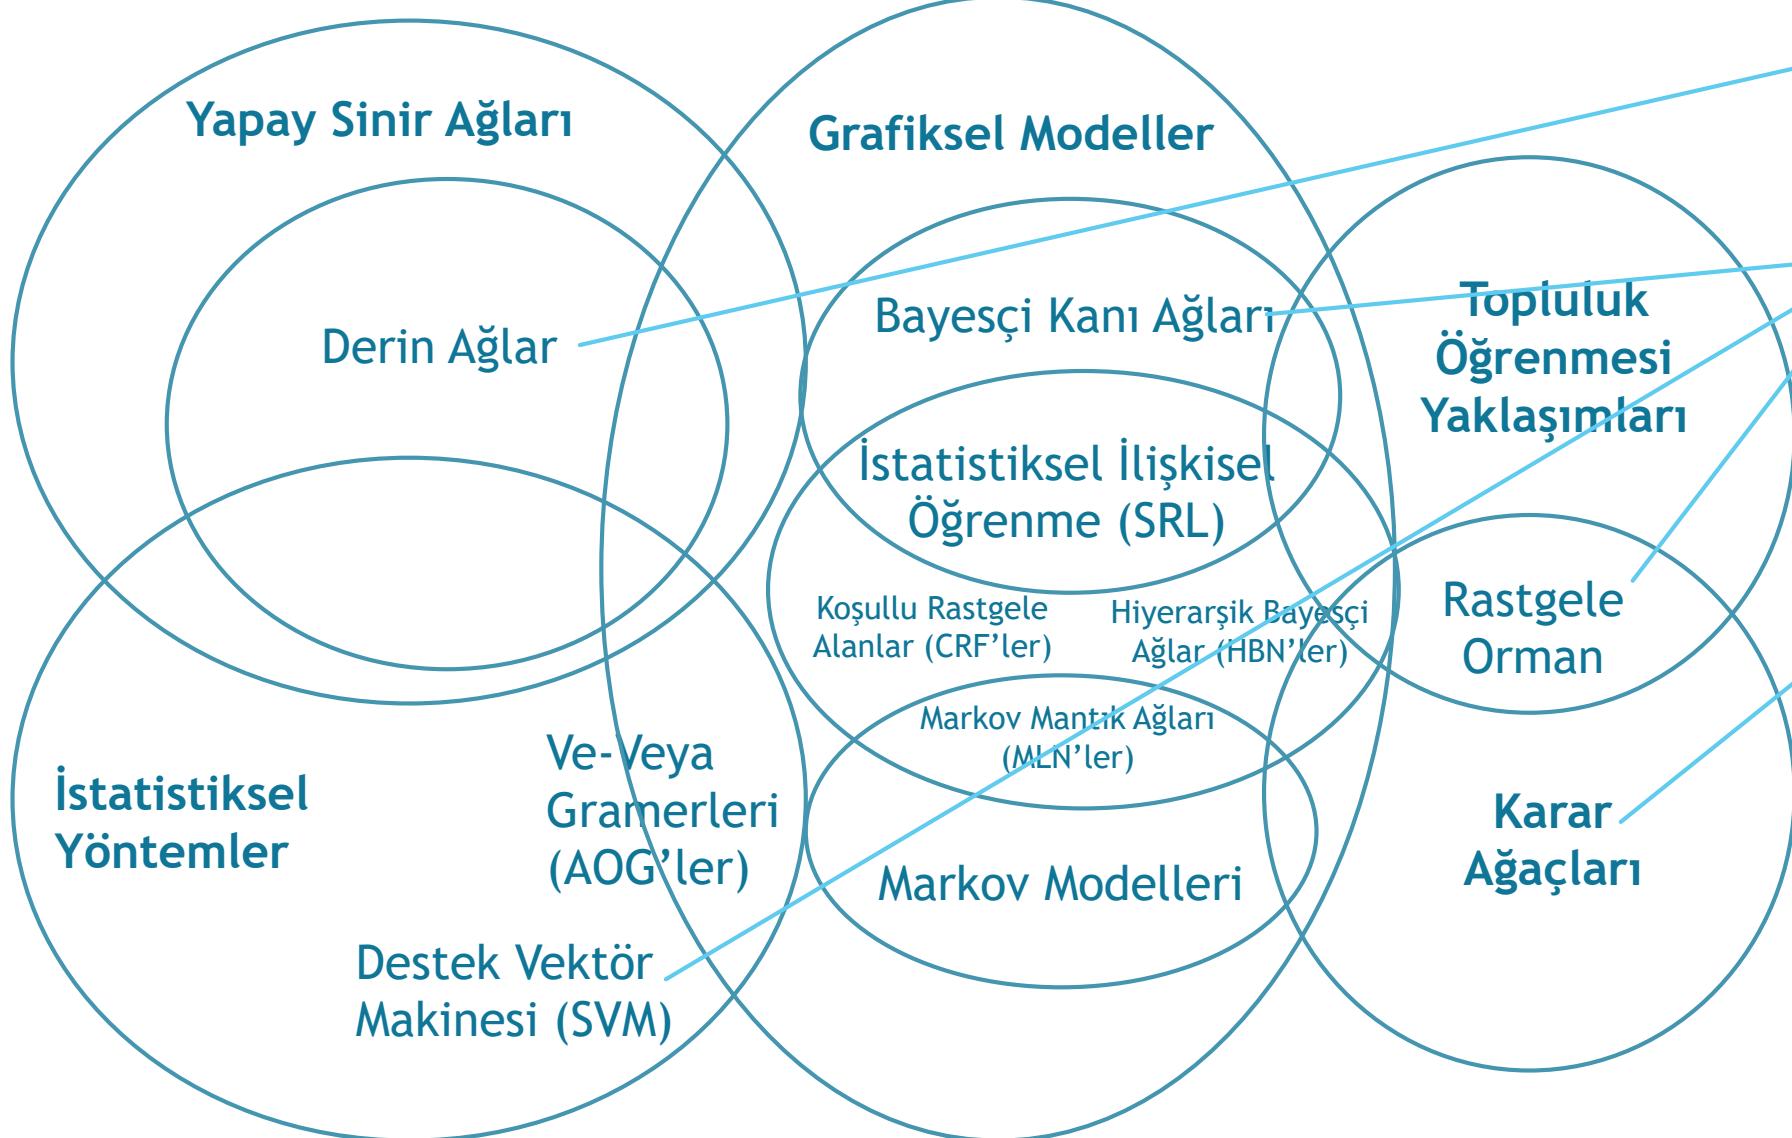


- Sistemin bu kararı nasıl ve neden oluşturduğunu biliyorum.
- Başarılı bir sonuç elde ettiğimden eminim.
- Olası bir hata durumunda nasıl müdahale edebileceğimi biliyorum.

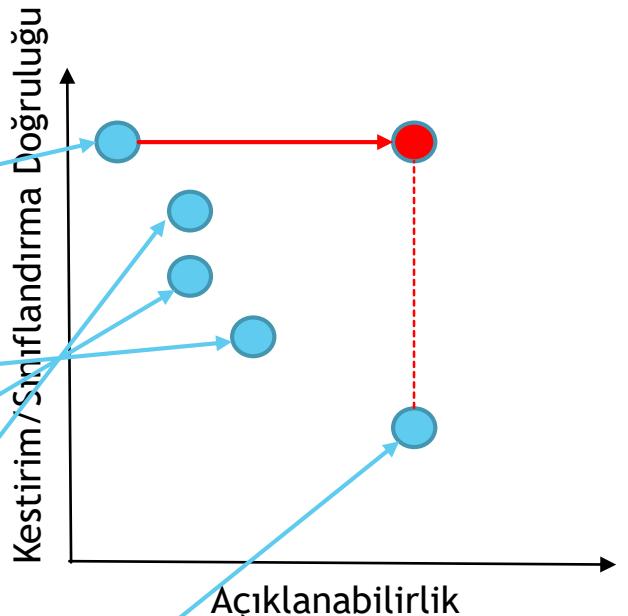
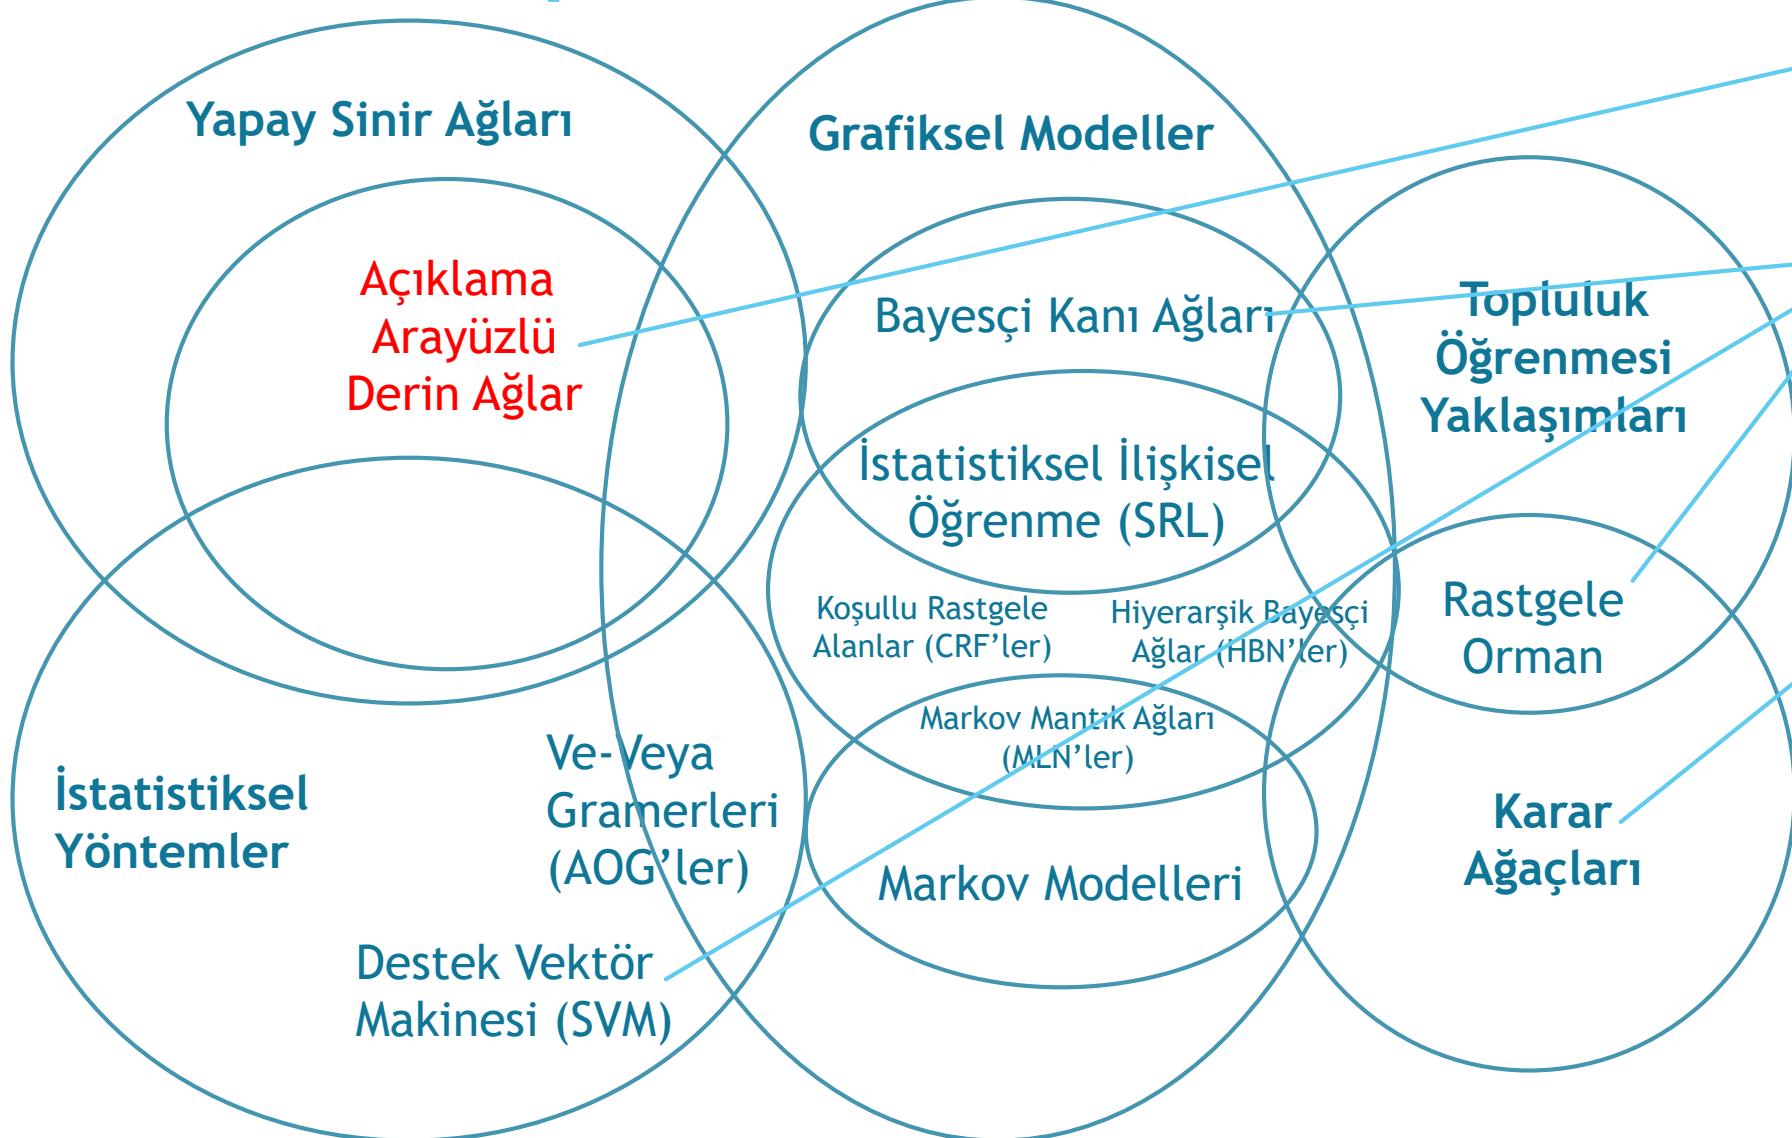
Mevcut Durum



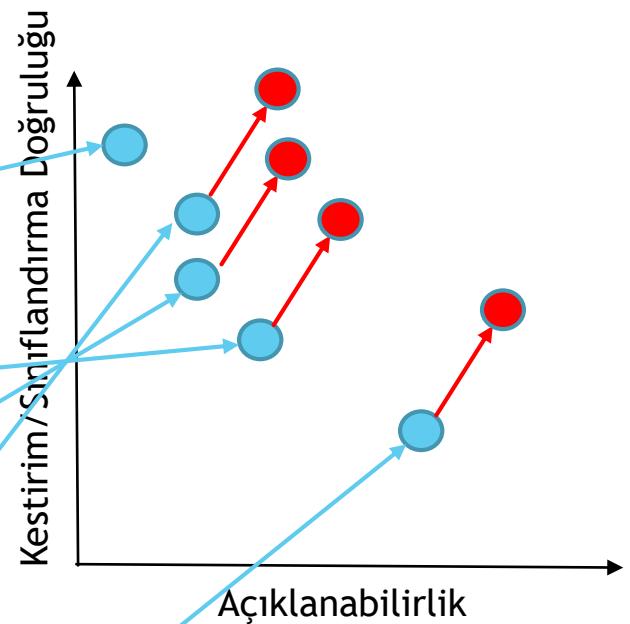
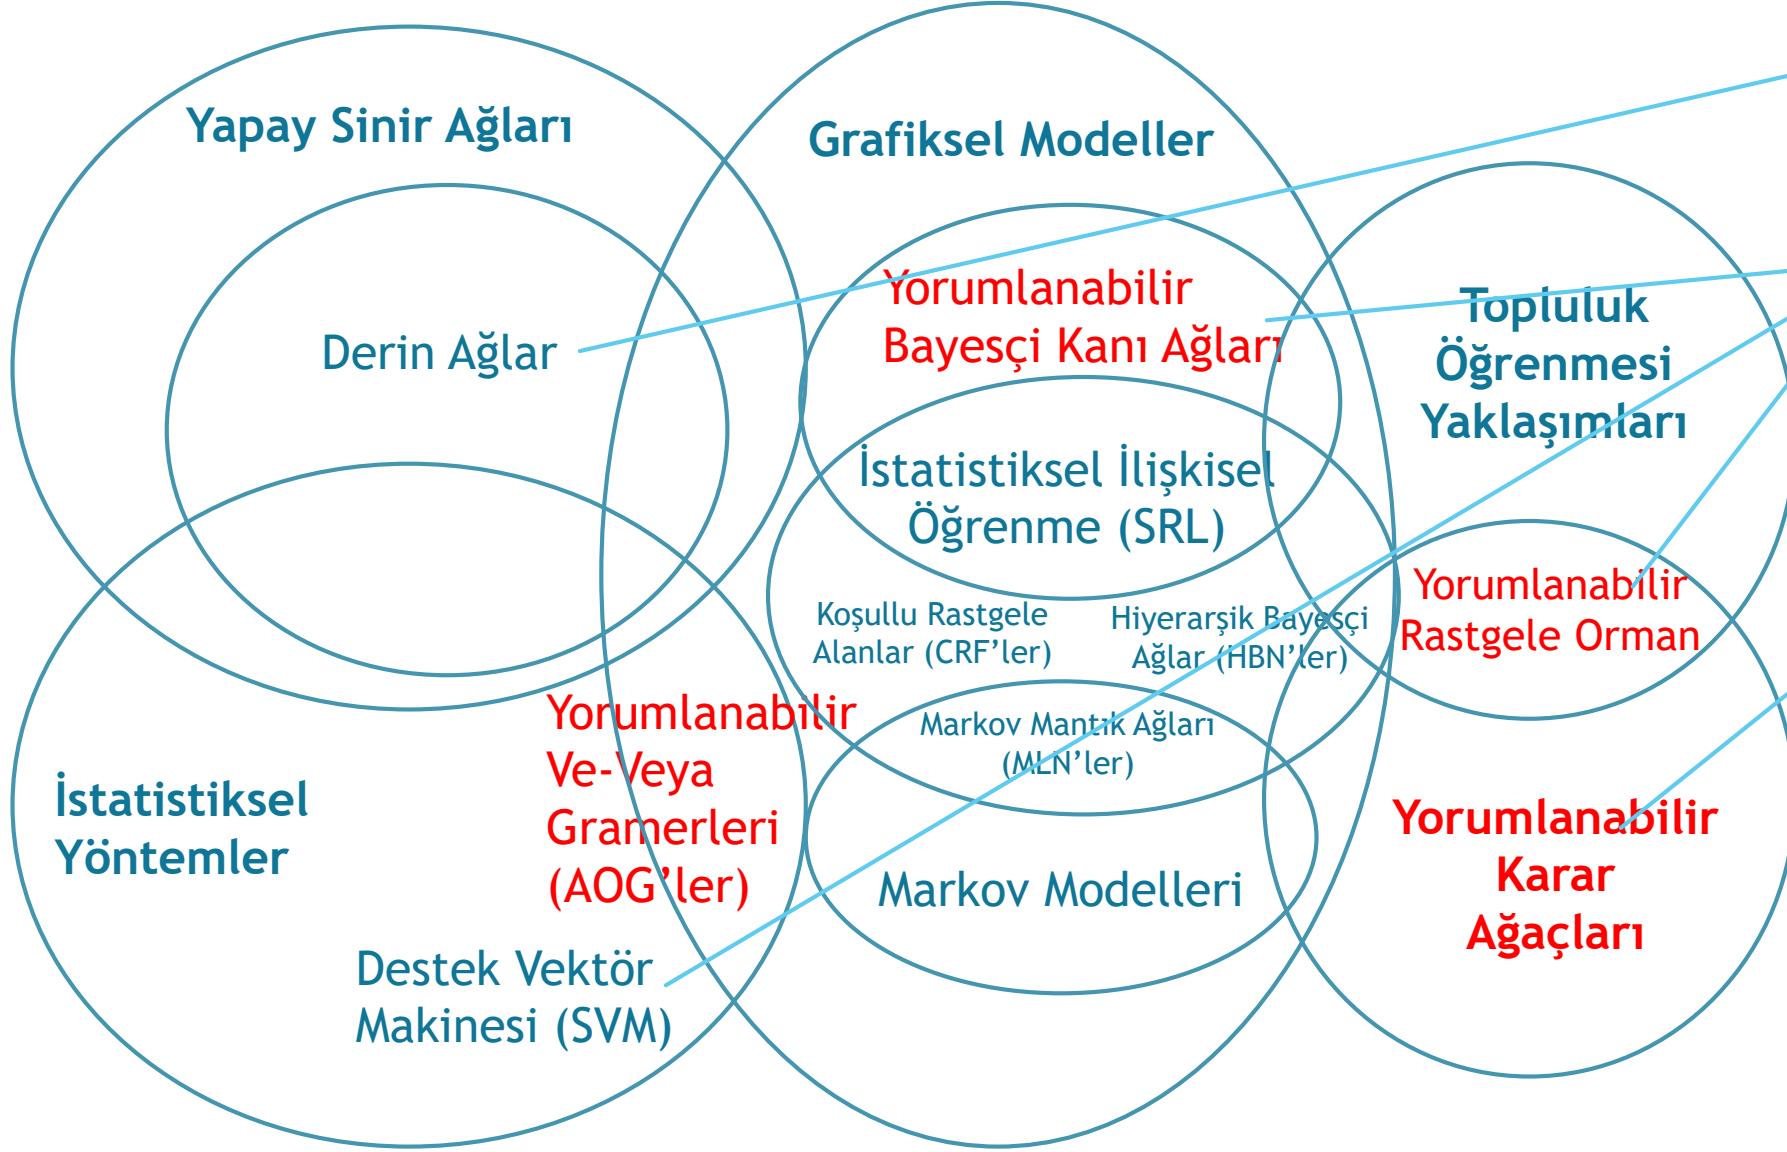
Mevcut Durum



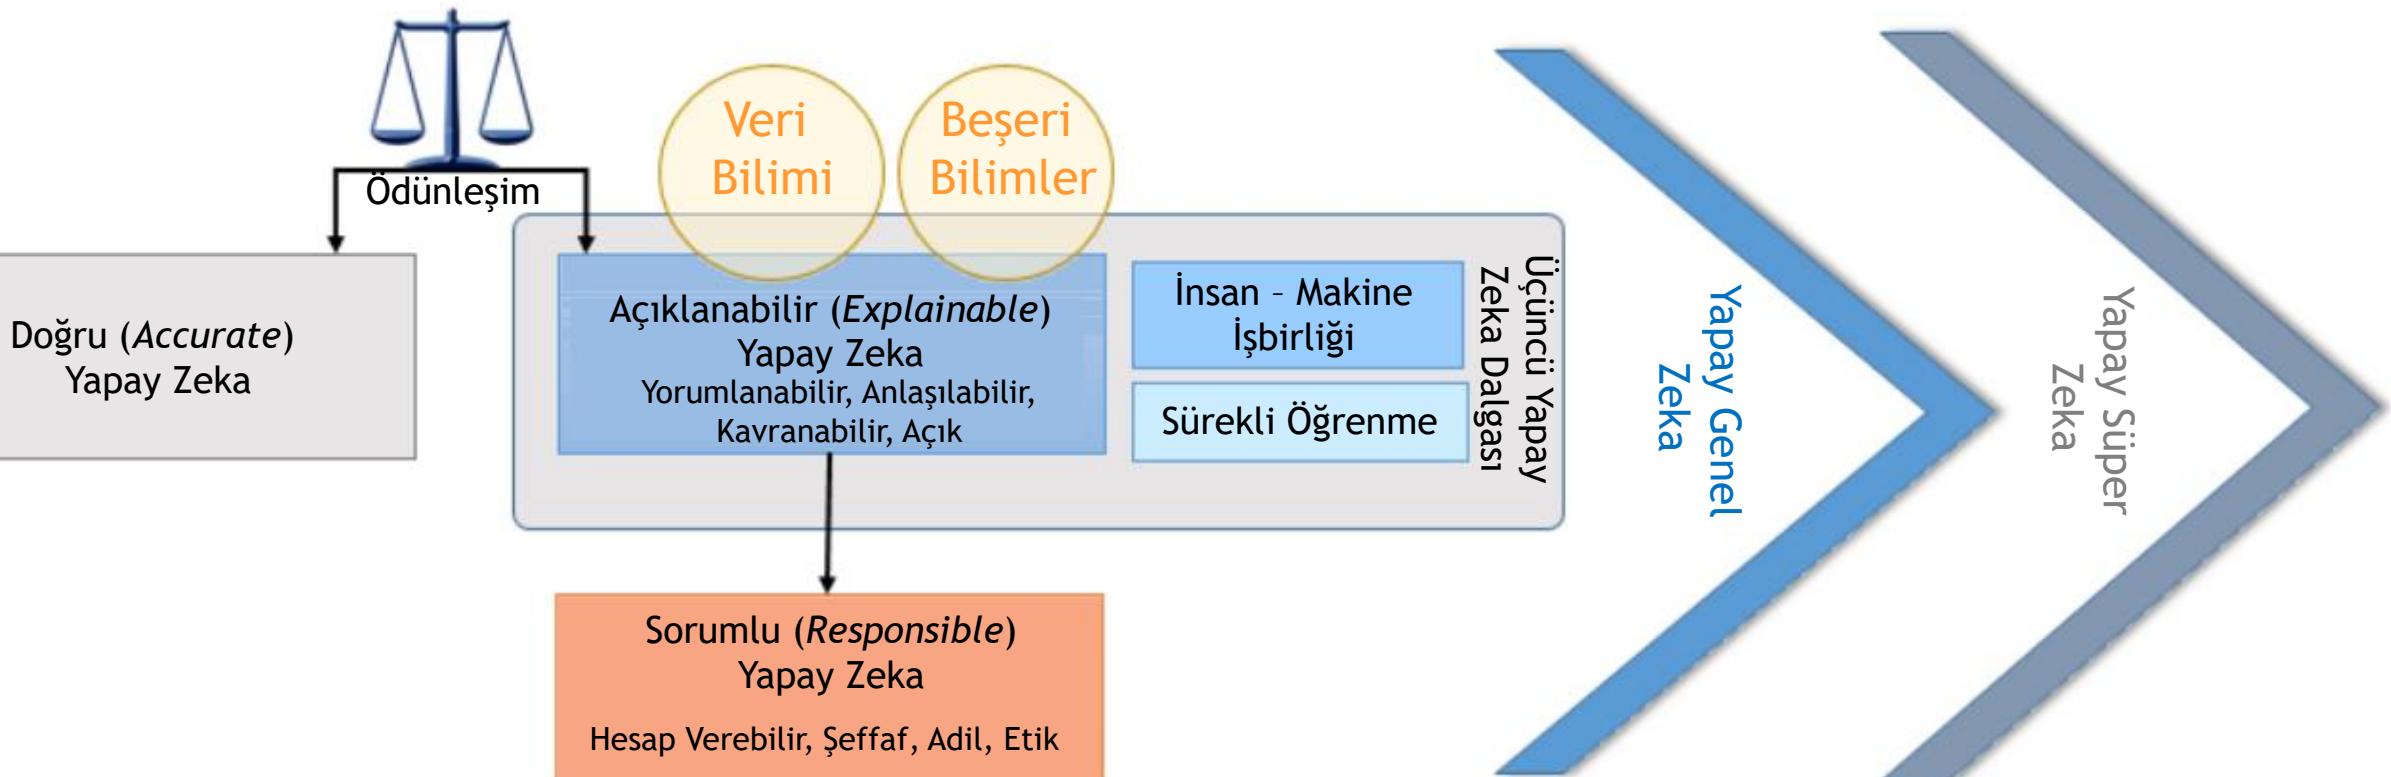
Yapılması Gereken



Yapılması Gereken (Alternatif)



Konu ile İlgili Kavramlar

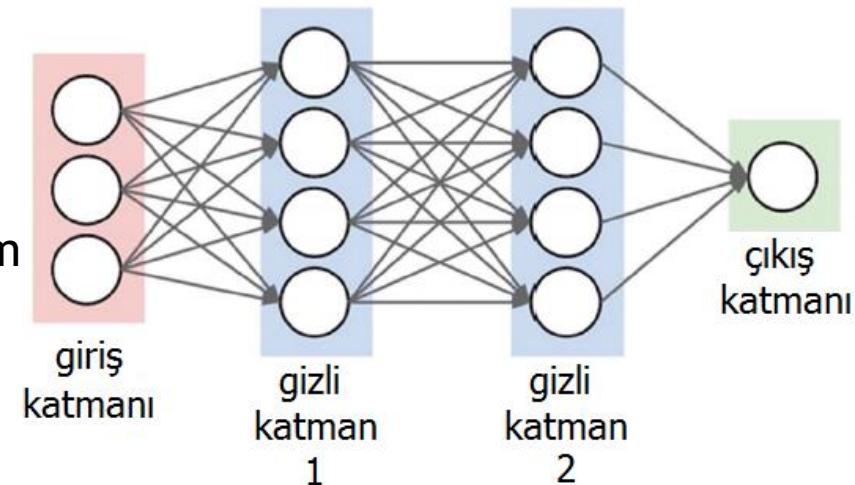


Algoritma Şeffaflığı

- Sadece ‘Yapay Zeka’ ile Sınırlı Olmamakla Birlikte:
Algoritma İçeren Yazılımların Doğrulama ve Geçerleme
Faaliyetleri
 - Algoritma Şeffaflığı (*Algorithm Transparency*)
 - Algoritma Hesap Verebilirliği (*Algorithm Accountability*)

Kör Göze Parmak Bir Örnek

- Bu yazılım (algoritma) yanlış (etik dışı, hukuk dışı, vb.) bir karar verirse:
 - Bu modeli, kim bu şekilde kurdu?
 - Katman sayısını kim belirledi?
 - Her bir katmandaki nöron sayısını kim belirledi?
 - Nöronlardaki aktivasyon fonksiyonlarını kim belirledi?
 - Bu modeli kim nasıl eğitti?
 - Eğitim setini kim belirledi?
 - Eğitim epoch'larını kim nasıl sıraladı?



Tanımlar... Tanımlar...

- Algoritmik Zarar (*Algorithmic Harm*)
- Algoritmik Ayrımcılık (*Algorithmic Discrimination*)
 - Medyaya yansıyan örnekler: Google'ın ve Tesla'nın otonom araç kazaları, çeşitli sohbet robotlarının cinsiyetçi/ırkçı tavırları, vb.
- Adillik (*Fairness*)
- Açıklanabilirlik (*Explainability*)
- Sorgulanabilirlik (*Auditability*)
- Sorumluluk (*Responsibility*)
- Doğruluk (*Accuracy*)

Şeffaflık Neden Gerekli?

- Niceliksel Girdi Etkisi (*Quantitative Input Influence - QII*)'nin Bilinmesi
- Şahıs/Kişi Bazında
 - Herhangi bir talebi (örneğin Kredi, Nitelikli Göçmenlik, Şartlı Tahliye, Tutuksuz Yargılanma, vb.) reddedilen bir kişi, talebinin hangi sebepten ötürü reddedildiğini öğrenmek isterse
- Kurum Bazında
 - Kurum, kullanmakta olduğu yazılım/algoritma tarafından verilen kararlarda hangi özniteliğin (ya da hangi girdinin) daha etkili olduğunu öğrenmek isterse

Algoritmik Ayrımcılık

Doğru Bir Yaklaşım Mı?

- Bazlarına göre etik olmadığı için kesinlikle uygun değil
- Bazlarına göre ise etik olmamasına karşın performans artırımı için gerekli
- Örnek: ABD'de birçok eyalette "polis devriye görev rotalarının oluşturulması" için kullanılan algoritma
 - Algoritmanın iki modu var
 - Bazı eyaletlerde algoritmanın kesinlikle yönsüz/yansız/nötr çalışması talep edilmiş
 - Bazı eyaletlerde ise özellikle sosyoekonomik düzeyi düşük ve azınlıkların yaşadığı mahallelere daha çok atama yapılacak şekilde çalışması talep edilmiş
 - "Sosyoekonomik düzeyi düşük ve azınlıkların yaşadığı mahalleler" kriteri mi?
 - Yoksa "Suç oranı yüksek mahalleler" kriteri mi?
 - "Zaten her ikisi de aynı kapıya çıkıyor" iddiası mı?

Peki Niye? - 1

- Yönlü/Yanlı veya Kalitesiz Veri
 - Bazı yüz tanıma algoritmalarının performansının beyaz ırk için yüksek olması; diğer ırklar için düşük olması
 - Nikon'un fotoğraf makinelerinin içindeki algoritmaların sarı ırk için çoğunlukla “kapalı göz” uyarısı vermesi
- Kötü/Yanlış Kural Tanımlamaları
 - Sosyal Kredi Skorlama Şirketleri Kreditech ve Tala Mobile’ın, bir kişinin kredibilitesini hesaplarken kişinin ödeme geçmişinden ziyade oturduğu bölge ve alışveriş yaptığı mağazaları göz önünde bulunduruyor olması

Peki Niye? - 2

- Bağlam Dışı Çalışma Hataları
 - Yüz tanıma algoritmalarının maske görünce yüz olarak algılamaları
- Geri Besleme Döngüleri
 - Performans değerlendirmede yanlış yönlendirici
- İnsan Davranışlarındaki “Bilinçaltı” Ayrımcılık Eğilimi
 - Youtube'un, belirli bir süre boyunca Stevie Wonder videosu izleyince Ray Charles videoları önermeye başlaması

Algoritmalar ve Temel İşlevleri - 1

İşlev	Tür	Örnekler
Önceliklendirme	Genel Amaçlı Arama Motorları	Google, Bing, Baidu
	Özel Amaçlı Arama Motorları	Genealogy, Image Search, Shutterstock
	Meta Arama Motorları	Info.com
	Soru/Cevap Motorları	Quora, Ask.com
	Sosyal Medya Zaman Akışları	Facebook, Twitter
Sınıflandırma	İtibar/Bilinirlik Sistemleri	Ebay, Uber, Airbnb
	Haber Değerleme Sistemleri	Reddit, Digg
	Kredi Değerleme Sistemleri	Credit Karma
	Sosyal Değerleme Sistemleri	Klout
İlişkilendirme	Öngörüsel Politika Oluşturma Sistemleri	PredPol
	Gelişim/Eğitim Öngörü Sistemleri	ScoreAhit, Music Xray, Google Flu Trends
Filtreleme	Spam Filtreleme Sistemleri	Norton
	Çocuk Koruma Filtreleri	Net Nanny
	Tavsiye Sistemleri	Spotify, Netflix
	Haber Derleme Sistemleri	Facebook News Feed

Algoritmalar ve Temel İşlevleri - 2

■ Önceliklendirme

- New York şehrinde, belirli değerin üzerinde bir yangın riski taşımakta olduğu belirlenen binalar için tahliye kararı verilmekte
- Bu değerlendirmeyi yapacak görevli sayısının kısıtlı olmasından ötürü bir önceliklendirme algoritması kullanılmaya başlanmıştır
- Kontrol sonrası tahliye karar oranı %13'ten %70'e çıkmış
- Bu bir başarı hikayesi (mi?)

Algoritmalar ve Temel İşlevleri - 3

■ Önceliklendirme

- Birçok eyalette şartlı tahliye edilenlere rehabilitasyon/danışmanlık hizmeti verilmesine yönelik bir önceliklendirme algoritması kullanılmaya başlanmıştır
- Michigan eyaletinde, yeniden suç işleme oranlarında %10 azalma sağlanmış
- Bu bir başarı hikayesi (mi?)

Algoritmalar ve Temel İşlevleri - 4

- Sınıflandırma
 - İkili Sınıflandırıcılarında: Yanlış Pozitifler, Yanlış Negatifler
 - Hangisini Daha Çok Tolere Edebiliriz/Etmeliyiz?
 - Peki Çoklu Sınıflandırıcılarında?
- İlişkilendirme
 - IBM'in InfoSphere Identity Insight yazılımı, Johnson Smith isimli bir vatandaşın "koruyucu aile/ebeveyn" olma başvurusunu, kardeşi cinayet hükümlüsü olduğu için reddetmiş
 - Bu bir başarı hikayesi (mi?)
 - Suçun şahsiliği?

Algoritmalar ve Temel İşlevleri - 5

■ Filtreleme

- Zite ve Flipboard gibi uygulamalar, haber okuma profilinize bakarak size uygun (ilginizi çekebilecek) haberleri size sunuyorlar
- Bu bir başarı hikayesi (mi?)
- Kişilerin daha yanlış/yönlü, hatta radikal olmasına sebep olmaz mı?

Şeffaflığın Önündeki Temel Engeller

- Veri Şeffaflığı
 - Algoritma Şeffaflığı'nın olmazsa olmazı
 - Ancak 'Kişisel Verilerin Güvenliği'?
 - Farksal Mahremiyet (*Differential Privacy*): Yeni Gelişen Bir Konu Daha!...
- Algoritma/yazılım geliştiricilerinin ticari gizliliği bahane ederek yazılımlarını açmaması
- Kara kutu yöntemlerinin bazen yanılması

Şeffaflığın Önündeki Temel Engeller

- Algoritma/yazılım geliştiricilerinin ticari gizliliği bahane ederek yazılımları hakkında en ufak bilgi dahi vermemesi
 - Google'ın, Otomatik Tamamlama işlevi için İngilizce'de seks çağrışımı yapan 110 adet sözcüğü algoritmasında hariç tuttuğunu açıklaması
 - Diğer kurallar?
 - Bir Alman vatandaşının, kendi ismini Google'da yazınca yanında otomatik olarak “*fraud*” sözcüğünü getirmesinden ötürü dava açması... Ardından ne oldu?
 - Diğer firmaların diğer yazılımları?

Şeffaflığın Önündeki Temel Engeller

- Kara kutu yöntemlerinin bazen yanlışması
 - Obama'nın seçim kampanyasında kullanılan ve kişiye göre özelleştirilmiş mesaj oluşturma algoritması:
 - Yapılan tersine mühendislik çalışmasına göre: Belirleyici faktör "Yaş"
 - Tasarımı yapan kuruma göre: Belirleyici faktör ""Daha Önceki Kampanyalardaki Bağış Yapma Durumu"
 - Tutuklu/tutuksuz yargılamaya karar veren Public Safety Assessment yazılımı/algoritması:
 - Yapılan tersine mühendislik çalışmasına göre skorlar ve oranlar:

1 (%10)	2 (%15)	3 (%20)	4 (%31)	5 (%35)	6 (%40)
---------	---------	---------	---------	---------	---------
 - Tasarımı yapan kuruma göre skorlar ve oranlar:

1 (%12)	2 (%16)	3 (%18)	4 (%23)	5 (%27)	6 (%30)
---------	---------	---------	---------	---------	---------

Tıpta Yapay Zekâ: Yapay Sağlık Neferleri

Prof. Dr. A. Egemen YILMAZ

Ankara Üniversitesi

Mühendislik Fakültesi Elektrik-Elektronik Mühendisliği Bölümü

Mühendislik Fakültesi Yazılım Mühendisliği Bölümü

Fen Bilimleri Enstitüsü Disiplinler Arası Yapay Zeka Teknolojileri Ana Bilim Dalı

Akıllı Sistemler ve Teknolojiler Uygulama ve Araştırma Merkezi (ASTAM)

Biraz da Bilgisayar Destekli Tıp Tarihçesi

- ▶ Nash FA. Differential Diagnosis, an apparatus to assist the logical faculties. *Lancet* 1954;266:874-5.
- ▶ Ledley RS, Lusted LB. Reasoning Foundations of Medical Diagnosis. *Science* 1959;130:9-21.
- ▶ Warner HR, Toronto AF, Veasy LG, Stephenson R. A mathematical approach to medical diagnosis. Application to congenital heart disease. *JAMA* 1961;177:177-83.
- ▶ Overall JE, Williams CM. Models for medical diagnosis. *Behav Sci* 1961;6:134-41.
- ▶ Waxman BD. Public Health Service support of biomedical computing. Proceedings 3rd IBM Medical Symposium. Endicott, NY: IBM; 1961:199-202.
- ▶ Oberhoffer G. Report on an international seminar for medical documentation and statistics. *Methods Inf Med* 1962;1:27-31.

Kaynak: Kulikowski, C. A. (2019). Beginnings of artificial intelligence in medicine (AIM): computational artifice assisting scientific inquiry and clinical art—with reflections on present aim challenges. *Yearbook of Medical Informatics*, 28(1), 249.

Biraz da Bilgisayar Destekli Tıp Tarihçesi

- ▶ Engle RL, Davis BJ. Medical Diagnosis: Past, Present and Future: III: Diagnosis in the future, including a critique on the use of electronic computers as diagnostic aids to the clinician. *Arch Int Med* 1963;112:530-43.
- ▶ Jacquez JA. The Diagnostic Process: Proceedings of a Conference at the University of Michigan; 1963.
- ▶ Feinstein AR. Boolean algebra and clinical taxonomy I. Analytical synthesis of the general spectrum of a human disease. *New Eng J Med* 1963;269:929-38.
- ▶ Collen MF, Rubin L, Neyman J, Dantzig GB, Baer RM, Siegelauf AB. Automated multiphasic screening and diagnosis. *Am J Public Health* 1964;54:741-50.
- ▶ Enslein K, editor. Data Acquisition and Processing in Biology and Medicine. New York: Pergamon; 1964.

Kaynak: Kulikowski, C. A. (2019). Beginnings of artificial intelligence in medicine (AIM): computational artifice assisting scientific inquiry and clinical art—with reflections on present aim challenges. *Yearbook of Medical Informatics*, 28(1), 249.

Biraz da Bilgisayar Destekli Tıp Tarihçesi

- ▶ Ledley RS. Use of Computers in Biology and Medicine. New York: McGraw Hill; 1965.
- ▶ Collen M. Automated multiphasic screening as a diagnostic method for preventive medicine. *Methods Inf Med* 1965;4:71-4.
- ▶ Stacy RW, Waxman BD, editors. Computers in Biomedical Research. New York: Academic Press; 1965.
- ▶ Baruch JJ, Barnett GO. Real-time shared online digital computer operations. *J Chron Dis* 1966;19:377-86.
- ▶ Gremy F, Joly Pages JC. Application des machines à traiter l'information au diagnostic médical, in *Medicine Cybernetique: Actes du IV Congrès International de Médecine Cybernétique*, Nice; 1966: 289-97.

Kaynak: Kulikowski, C. A. (2019). Beginnings of artificial intelligence in medicine (AIM): computational artifice assisting scientific inquiry and clinical art—with reflections on present aim challenges. *Yearbook of Medical Informatics*, 28(1), 249.

Biraz da Bilgisayar Destekli Tıp Tarihçesi

- ▶ Lusted LB. Introduction to Medical Decision Making. Springfield, IL: Charles C. Thomas; 1968. 20. Gorry GA, Barnett GO. Experience with a model of medical diagnosis. *Comp Biomed Res* 1968;1(5): 490-507.
- ▶ Lindberg DAB. The Computer and Medical Care. Springfield, IL: Charles C. Thomas; 1968.
- ▶ Kulikowski CA. A pattern recognition approach to medical diagnosis. *IEEE Trans Syst Science & Cybernetics* 1970;SSC-6(3):173-8.
- ▶ Buchanan BG, Sutherland G, Feigenbaum EA. Rediscovering some problems of artificial intelligence in the context of organic chemistry. In: Meltzer B, Michie D, editors. *Machine Intelligence*. Edinburgh: Edinburgh University Press; 1970.

Kaynak: Kulikowski, C. A. (2019). Beginnings of artificial intelligence in medicine (AIM): computational artifice assisting scientific inquiry and clinical art—with reflections on present aim challenges. *Yearbook of Medical Informatics*, 28(1), 249.

Biraz da Bilgisayar Destekli Tıp Tarihçesi

- ▶ 1960'ların başı: ABD'deki National Library of Medicine (NLM) tarafından MEDLARS (Medical Literature Analysis and Retrieval System)'ın geliştirilmesi
- ▶ MEDLARS → MEDLINE ve arama motoru PubMed → PubMed Central
- ▶ Bir yandan da 1980'ler itibarı ile Unified Medical Language System (UMLS)'in geliştirilmesi

Biraz da Bilgisayar Destekli Tıp Tarihçesi

- ▶ 1950'ler ve 1960'ların başı
 - ▶ Sibernetik Tıp kongrelerinin düzenlenmesi
- ▶ 1960'lar
 - ▶ Medikal verinin kaydedilmesine yönelik yazılımlar
- ▶ 1970'ler
 - ▶ Klinik Karar Destek amaçlı yazılım fikri
 - ▶ W. Schwartz, “Medicine and the Computer: The Promise and Problems of Change”, *New England Journal of Medicine*, 1970.
 - ▶ Hekimin entelektüel işlevlerinin bilgisayarlara devredilmesi

Biraz da Bilgisayar Destekli Tıp Tarihçesi

- ▶ İlk Projeler (Genelde «Uzman Sistem» Temelli):
 - ▶ Dendral (Organik Kimya - Örüntü Tanıma Temelli Molekül Tanıma Yazılımı) 1960'lar
 - ▶ Mycin (Kural Temelli Bakteri Tanıma Yazılımı - 600 kural) 1970'ler
 - ▶ Caduceus (Mycin'in genişletilmiş hali; 1000 farklı türün ayırt edilmesi) 1980'ler
 - ▶ Internist-I (Dahili Tıp Bilimleri'nde tanıların %80'ini koyma hedefi; ancak çok yavaş) 1980'ler

Günümüzde Yapay Destekli Tıp Uygulamaları

- ▶ Sınıflandırma (İkili, Çoklu)
- ▶ Gruplandırma
- ▶ Sayısal Değer Kestirimi
- ▶ vb.

- ▶ Sinyal üzerinden
- ▶ Görüntü üzerinden
- ▶ Gen dizisi üzerinden
- ▶ vb.

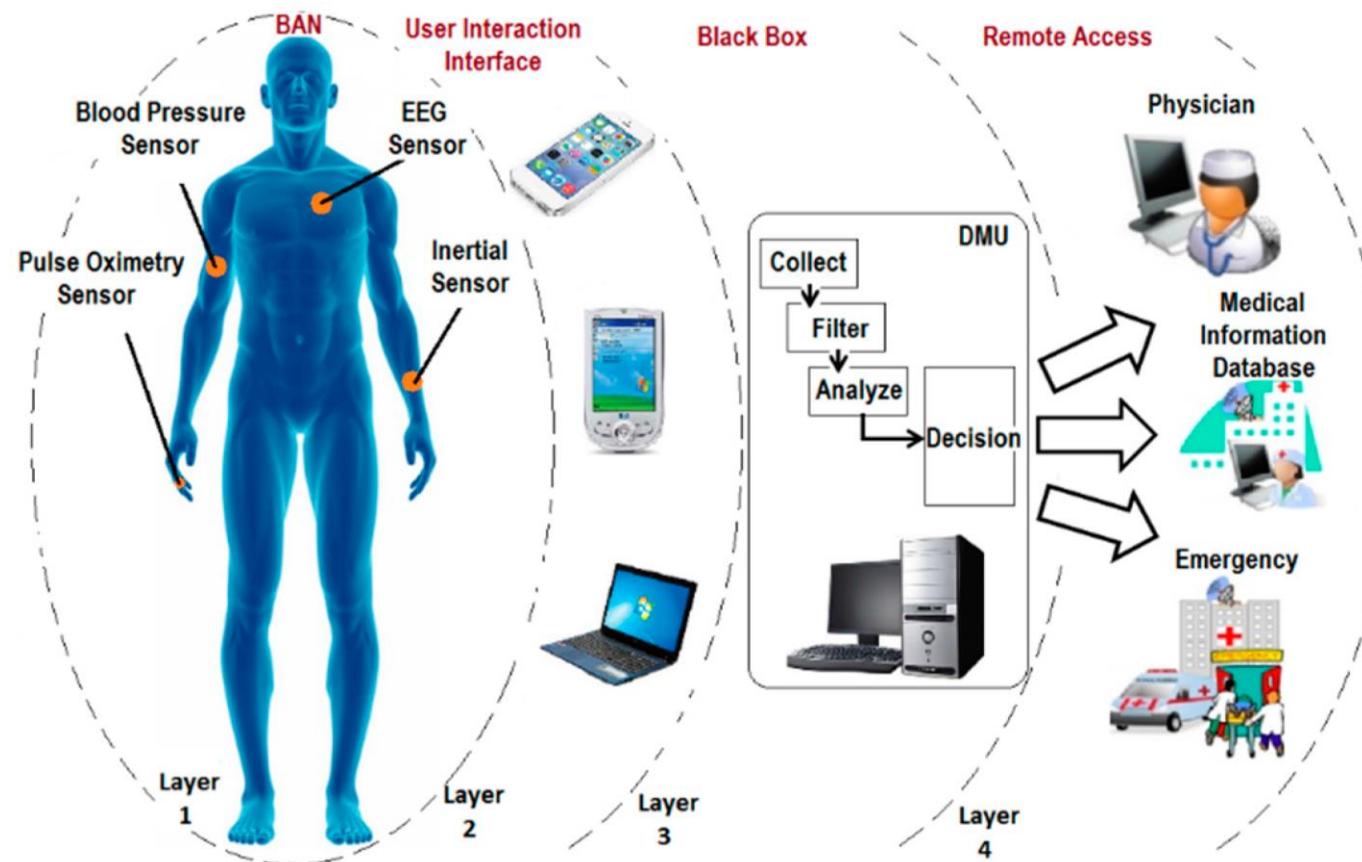
Günümüzde Yapay Destekli Tıp Uygulamaları

- ▶ Acil (örn. Triyaj)
- ▶ Kardiyoloji (örn. Aritmi Tespiti, hatta Sınıflandırması)
- ▶ Radyoloji (örn. Tümör Tespiti, hatta Sınıflandırması)
- ▶ Oftalmoloji (örn. Diyabetik Retinopati tespiti)
- ▶ Endokrinoloji (örn. Diyabet Tespiti, Glükoz Seviyesi Kestirimi)
- ▶ Nefroloji (örn. Polikistik Böbrek Hastaları'nda Glomerüler Filtrasyon Kestirimi)

Günümüzde Yapay Destekli Tıp Uygulamaları

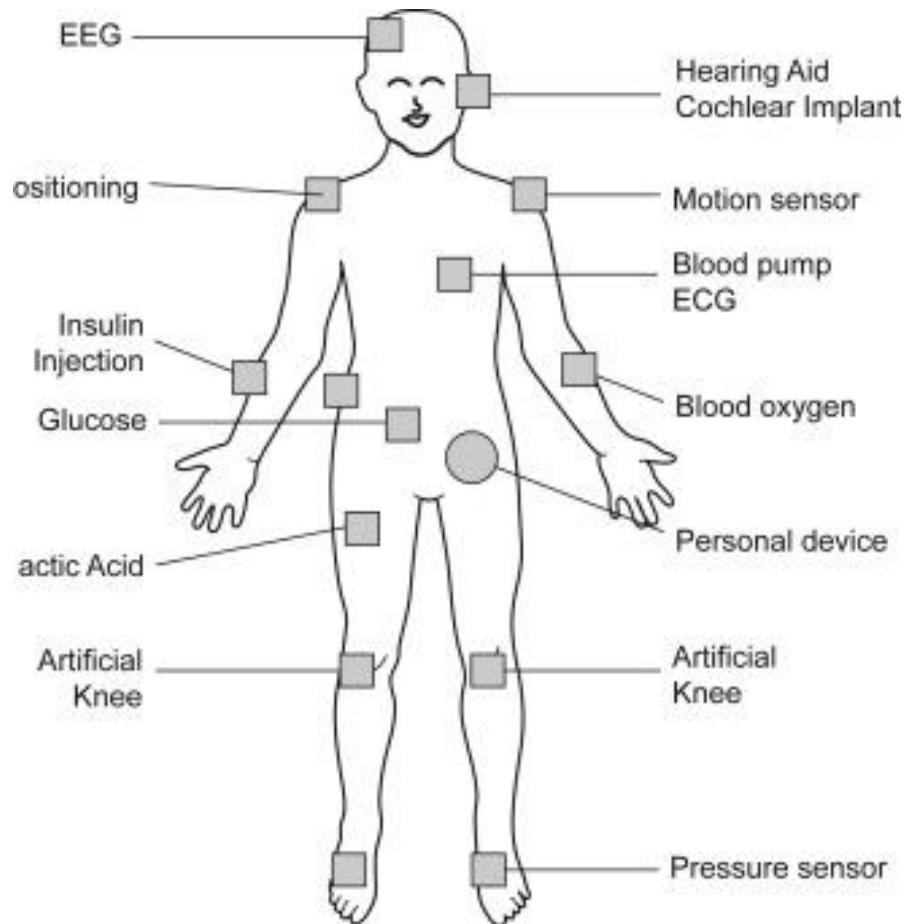
- ▶ Gastroenteroloji (örn. Polip Tespiti, Atrofik Gastrit Tespiti)
- ▶ Nöroloji (örn. Epilepsi Krizi Erken Uyarı Sistemi)
- ▶ Dermatoloji (örn. Cilt Rahatsızlıklarını Tespiti, hatta Sınıflandırması)
- ▶ Patoloji (örn. Doku Sınıflandırması)
- ▶ vb.

Sadece Yapay Zeka Mi?



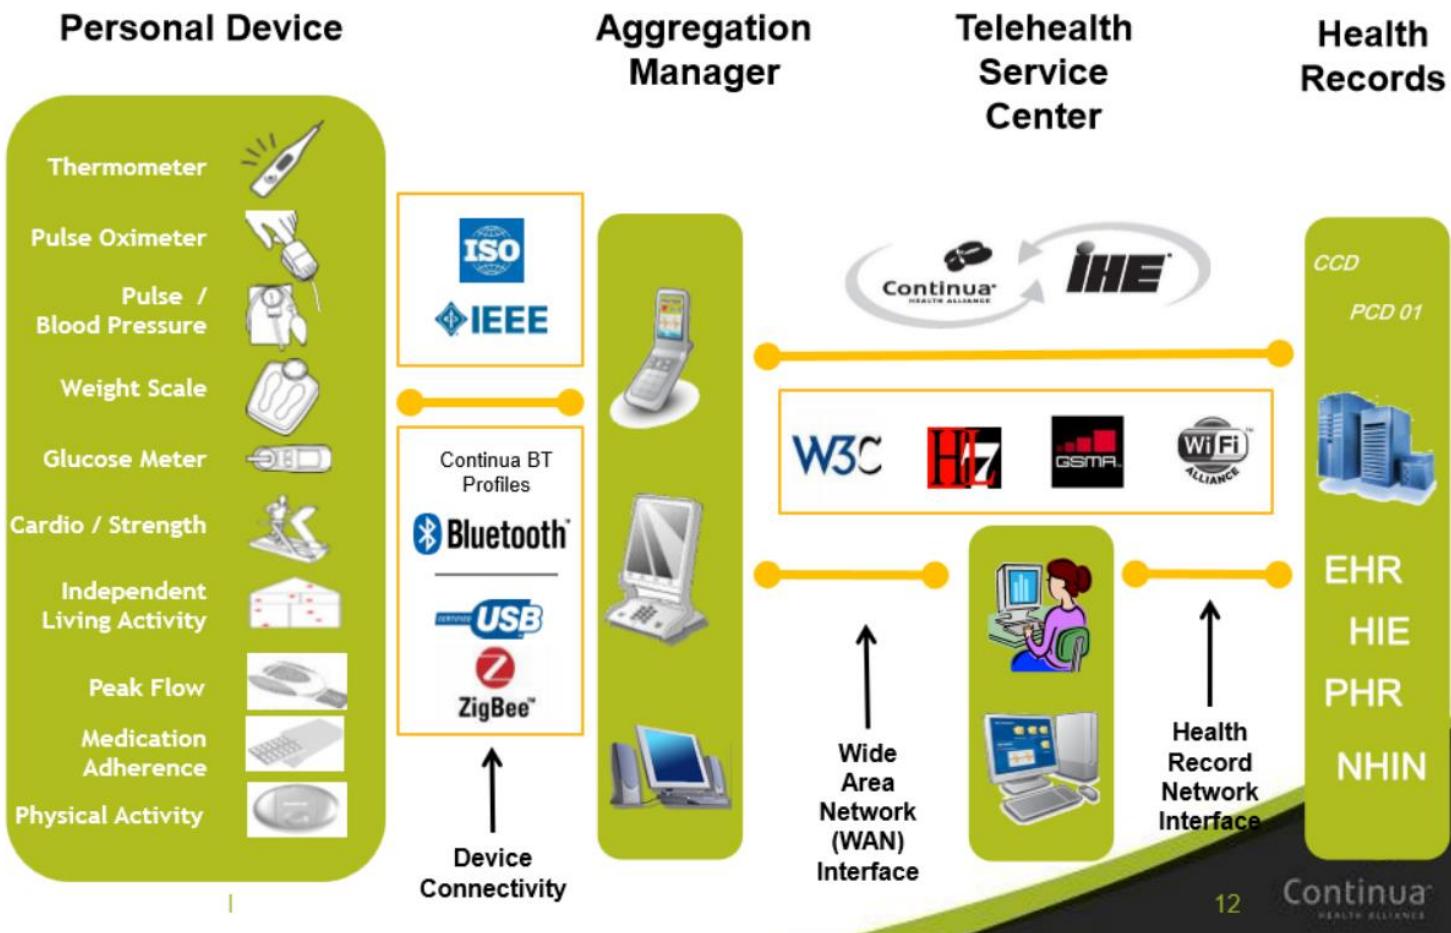
Kaynak: Ghamari, M., Janko, B., Sherratt, R. S., Harwin, W., Piechockic, R., & Soltanpur, C. (2016). A survey on wireless body area networks for ehealthcare systems in residential environments. *Sensors*, 16(6), 831.

Sadece Yapay Zeka Mi?



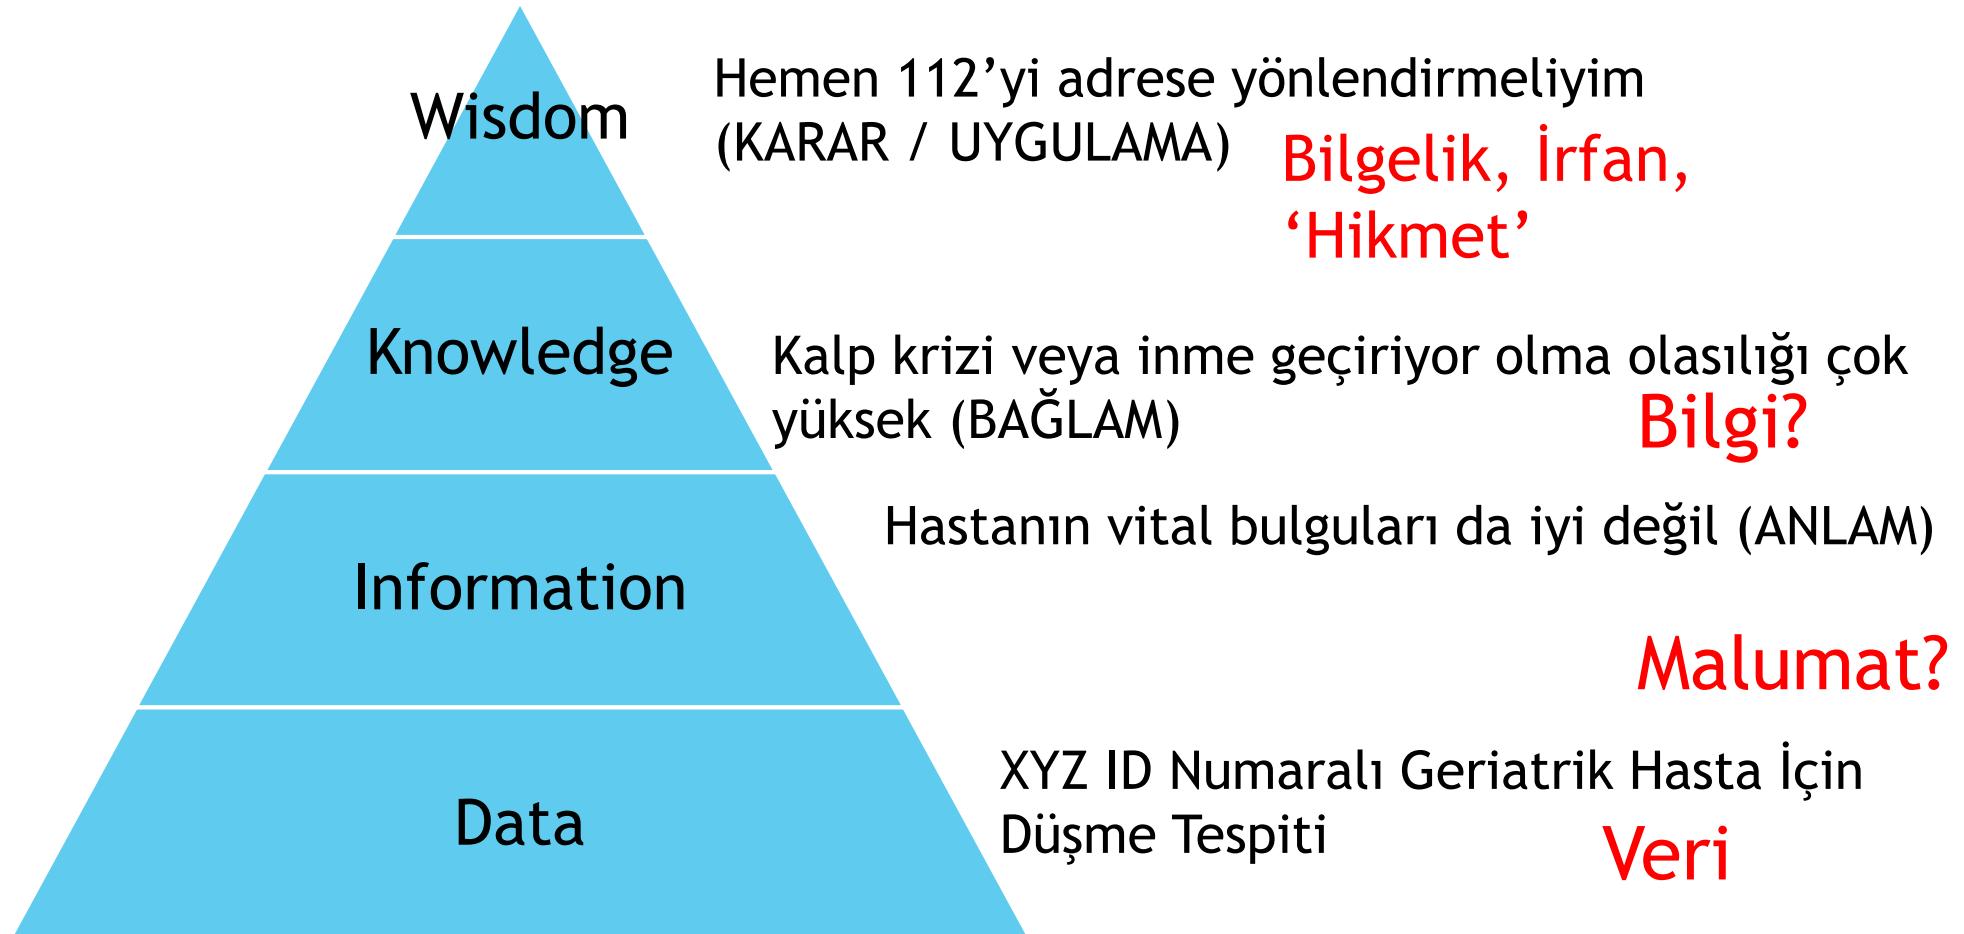
Kaynak: Pramanik, P. K. D., Nayyar, A., & Pareek, G. (2019). WBAN: Driving e-healthcare beyond telemedicine to remote health monitoring: Architecture and protocols. In *Telemedicine technologies* (pp. 89-119). Academic Press.

Sadece Yapay Zeka Mi?



Kaynak: Innovation Working Group (2019). Roadmap for Telemedicine: Key Considerations and Recommendations. IWG-Asia.

Bilgi Piramidi Üzerinden Bir Açıklama



Tıbbi Görüntüleme Teknolojilerinde Yapay Zeka Uygulamaları

Prof. Dr. A. Egemen YILMAZ

Ankara Üniversitesi

Mühendislik Fakültesi Elektrik-Elektronik Mühendisliği Bölümü

Mühendislik Fakültesi Yazılım Mühendisliği Bölümü

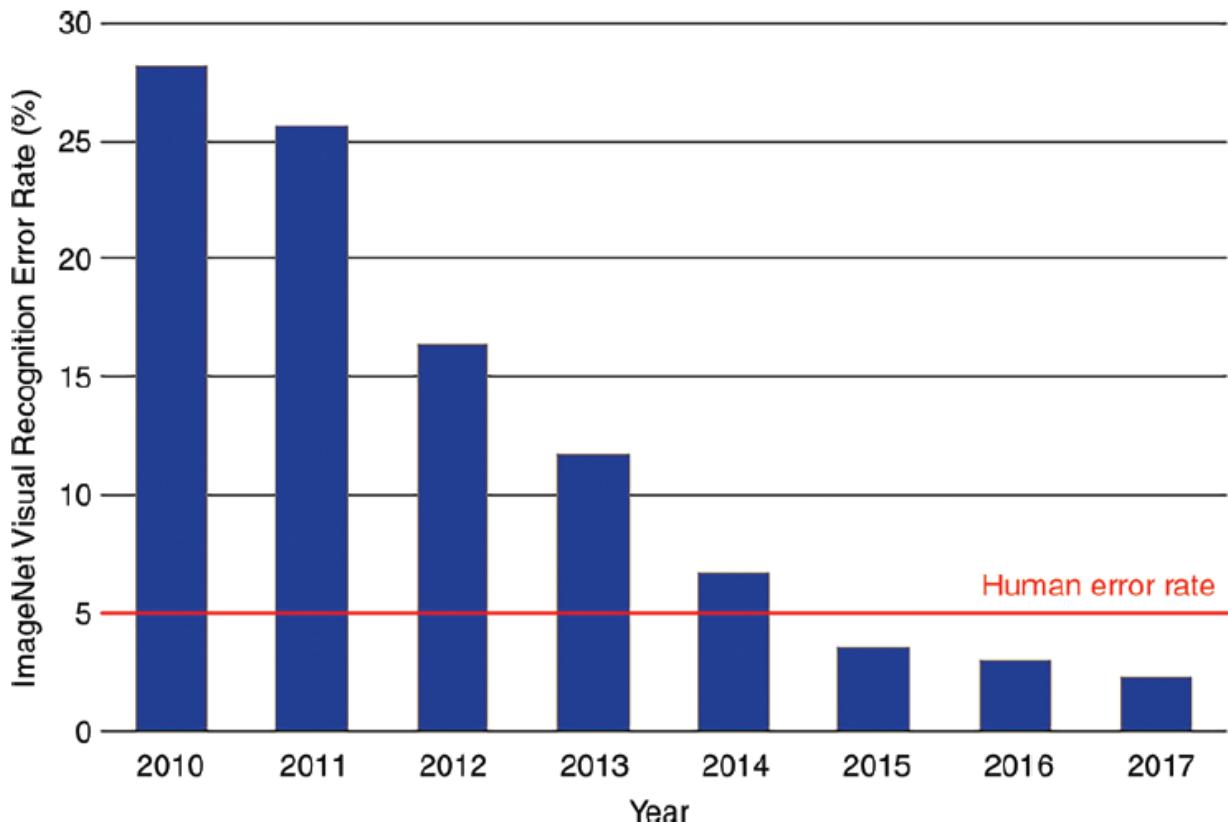
Fen Bilimleri Enstitüsü Disiplinler Arası Yapay Zeka Teknolojileri Ana Bilim Dalı

Akıllı Sistemler ve Teknolojiler Uygulama ve Araştırma Merkezi (ASTAM)

Tıbbi Görüntüleme - Giriş

- ▶ Radyografi - Röntgen
- ▶ Floroskopi
- ▶ Mamografi
- ▶ Bilgisayarlı Tomografi
- ▶ Manyetik Rezonans Görüntüleme
- ▶ Ultrasonografi
- ▶ Nükleer Tıp Görüntüleme
- ▶ Tek Foton Emisyonlu Bilgisayarlı Tomografi
- ▶ Pozitron Emisyon Tomografi

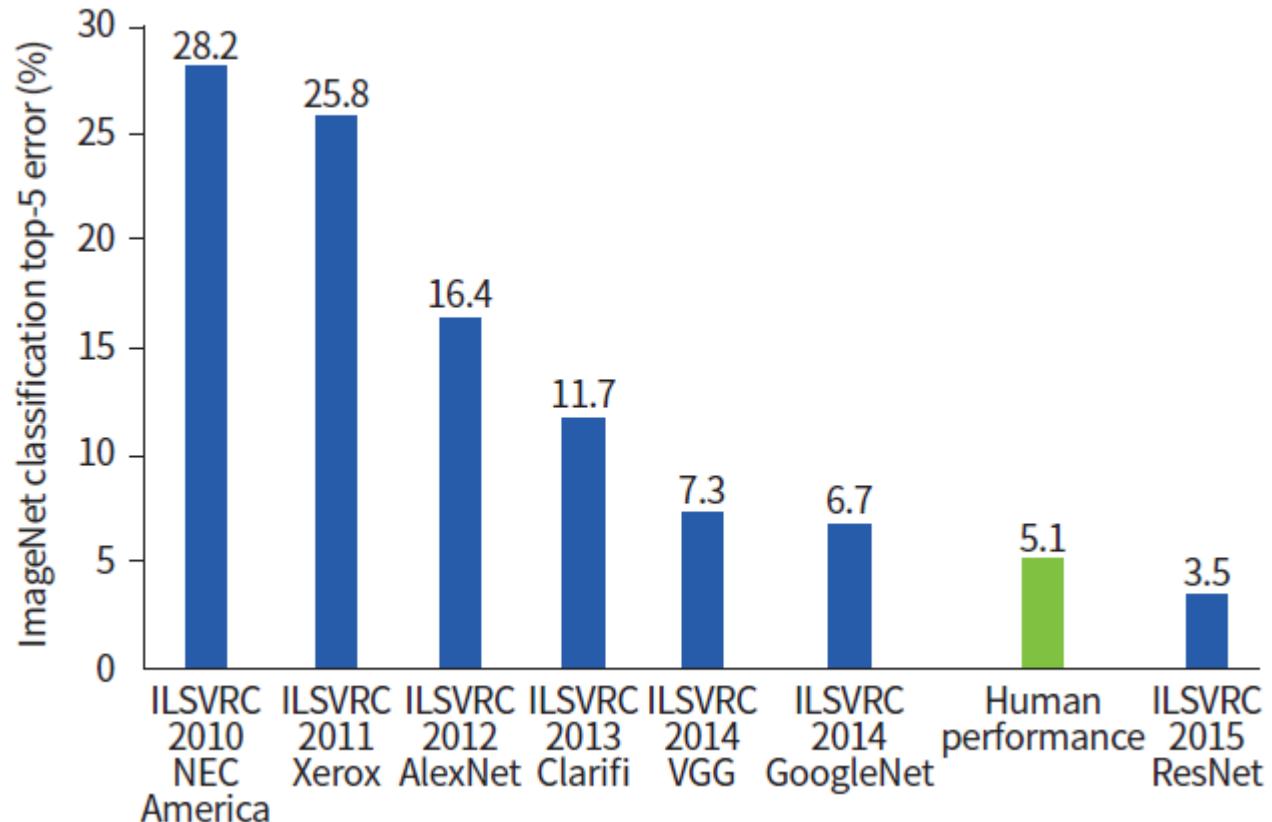
Görüntü Sınıflandırma Performansı



ImageNet Large-Scale Visual Recognition Challenge

Kaynak: Langlotz, C. P., Allen, B., Erickson, B. J., Kalpathy-Cramer, J., Bigelow, K., Cook, T. S., ... & Kandarpa, K. (2019). A roadmap for foundational research on artificial intelligence in medical imaging: from the 2018 NIH/RSNA/ACR/The Academy Workshop. *Radiology*, 291(3), 781-791.

Görüntü Sınıflandırma Performansı



ImageNet Large-Scale Visual Recognition Challenge

Kaynak: Kim, J., Hong, J., & Park, H. (2018). Prospects of deep learning for medical imaging. *Precision and Future Medicine*, 2(2), 37-52.

Yapay Zekanın Medikal Görüntülemede Olası Kullanım Aşamaları

Görüntü İşlemenin Yanı Sıra:

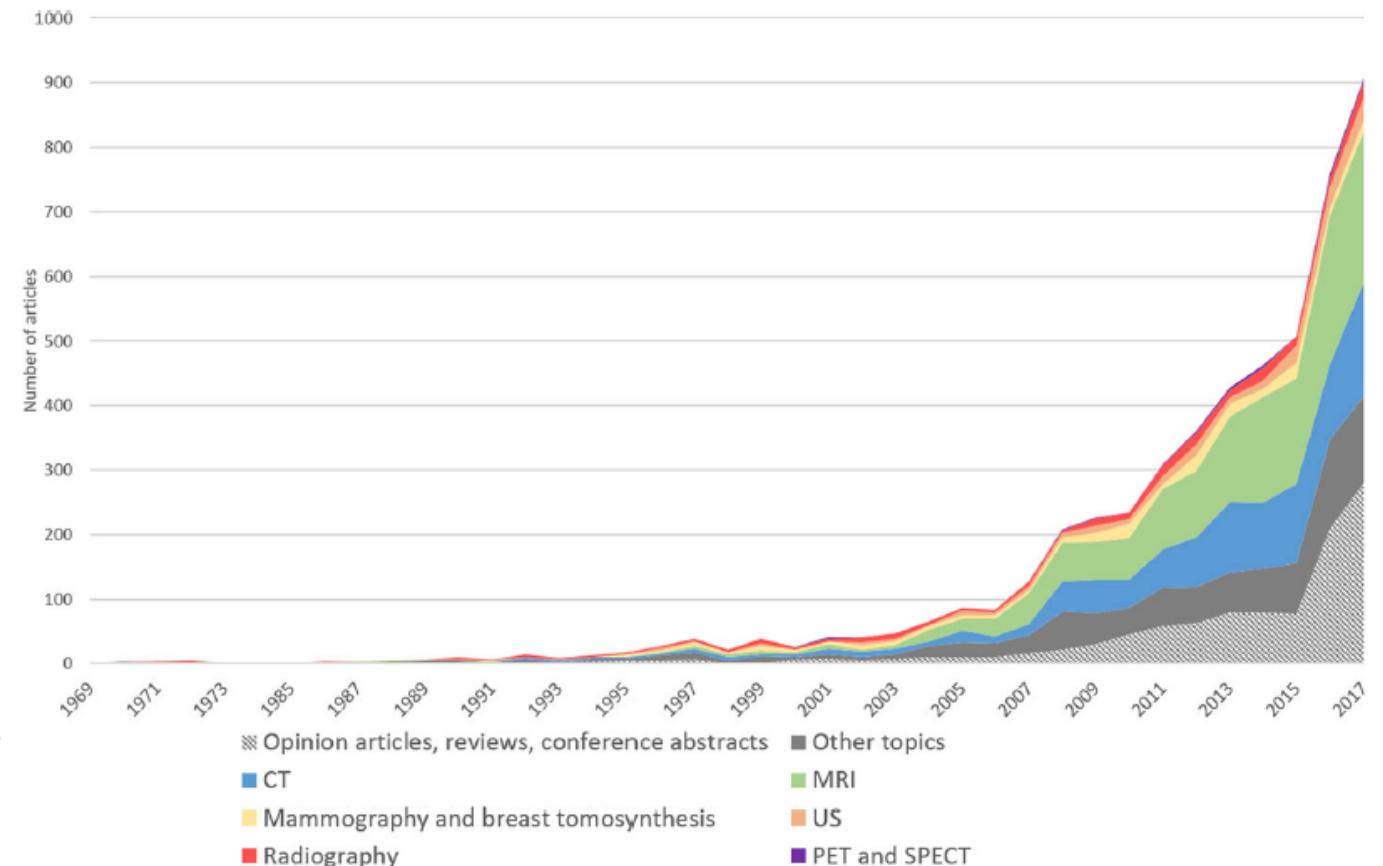
- ▶ Muayene Seviyesi: Görüntü Kabulü ve Hazırlık
- ▶ Okuma ve Raporlama Seviyesi
- ▶ Kestirim ve Tedavi Önerisi Seviyesi
- ▶ Kohort ve Toplum Analizi Seviyesi

Kaynak: Sharma, P., Suehling, M., Flohr, T., & Comaniciu, D. (2020). Artificial intelligence in diagnostic imaging: status quo, challenges, and future opportunities. *Journal of thoracic imaging*, 35, S11-S16.

Yapay Zekanın Medikal Görüntülemede Olası Kullanım Aşamaları

- ▶ 10 yıl önce: Radyolojide Yapay Zeka makalelerinin sayısı yıllık 100-150
- ▶ Şimdi: Yıllık 700-800

- ▶ Yarısından fazlası MRI ve CT üzerine çalışmalar
- ▶ 1/3'ü nöroradyoloji; diğerleri %6-9 mertebesinde



Kaynak: Pesapane, F., Codari, M., & Sardanelli, F. (2018). Artificial intelligence in medical imaging: threat or opportunity? Radiologists again at the forefront of innovation in medicine. *European radiology experimental*, 2(1), 1-10.

Yapay Zekanın Medikal Görüntülemede Olası Kullanım Aşamaları

- ▶ 10 yıl önce: Radyolojide Yapay Zeka makalelerinin sayısı yıllık 100-150
- ▶ Şimdi: Yıllık 700-800
- ▶ Yarından fazlası MRI ve CT üzerine çalışmalar
- ▶ 1/3'ü nöroradyoloji; diğerleri %6-9 mertebesinde

Kaynak: Pesapane, F., Codari, M., & Sardanelli, F. (2018). Artificial intelligence in medical imaging: threat or opportunity? Radiologists again at the forefront of innovation in medicine. *European radiology experimental*, 2(1), 1-10.

Imaging modality	2015	2016	2017
Magnetic resonance imaging	164	230	235
	38%	42%	37%
Computed tomography	123	117	177
	29%	21%	28%
Ultrasound	27	32	33
	6%	6%	5%
Radiography	14	14	26
	3%	3%	4%
Mammography and breast tomosynthesis	23	12	18
	5%	2%	3%
Positron emission tomography and single-photon emission tomography	1	7	5
	0%	1%	1%
Other	79	139	134
	18%	25%	21%
Total	431	551	628
	100%	100%	100%

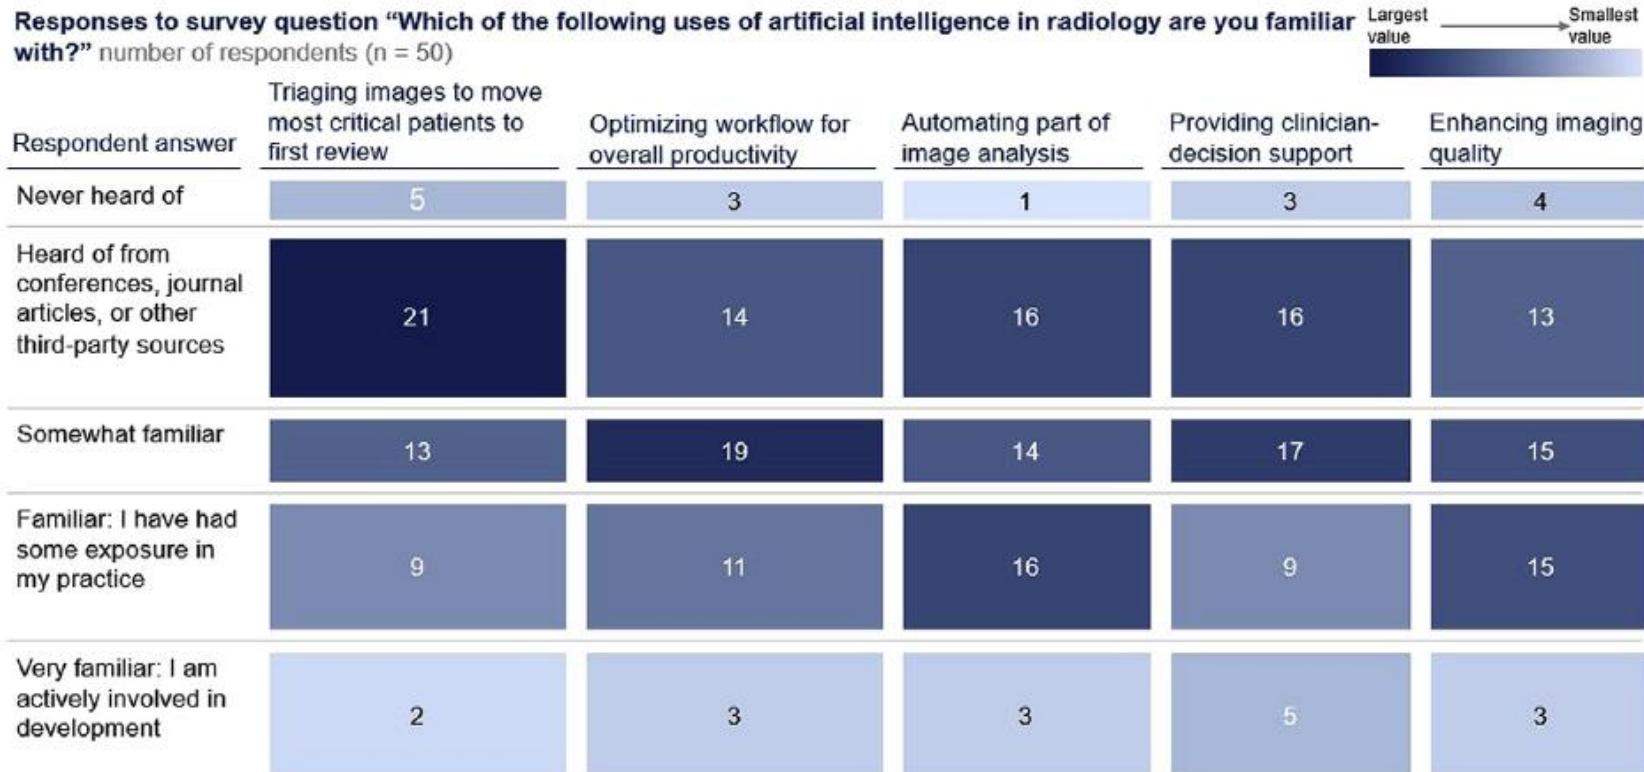
Yapay Zekanın Medikal Görüntülemede Olası Kullanım Aşamaları

- ▶ 10 yıl önce: Radyolojide Yapay Zeka makalelerinin sayısı yıllık 100-150
- ▶ Şimdi: Yıllık 700-800
- ▶ Yarısından fazlası MRI ve CT üzerine çalışmalar
- ▶ 1/3'ü nöroradyoloji; diğerleri %6-9 mertebesinde

Kaynak: Pesapane, F., Codari, M., & Sardanelli, F. (2018).
Artificial intelligence in medical imaging: threat or opportunity?
Radiologists again at the forefront of innovation in
medicine. *European radiology experimental*, 2(1), 1-10.

Body parts	2015	2016	2017
Central nervous system	163	235	211
	38%	43%	34%
Bone, spine and joints	29	37	54
	7%	7%	9%
Cardiovascular	24	32	49
	6%	6%	8%
Breast	41	39	50
	10%	7%	8%
Urogenital	40	25	52
	9%	5%	8%
Thorax and lungs	36	21	46
	8%	4%	7%
Abdomen	28	27	36
	6%	5%	6%
Other	70	135	130
	16%	25%	21%
Total	431	551	628
	100%	100%	100%

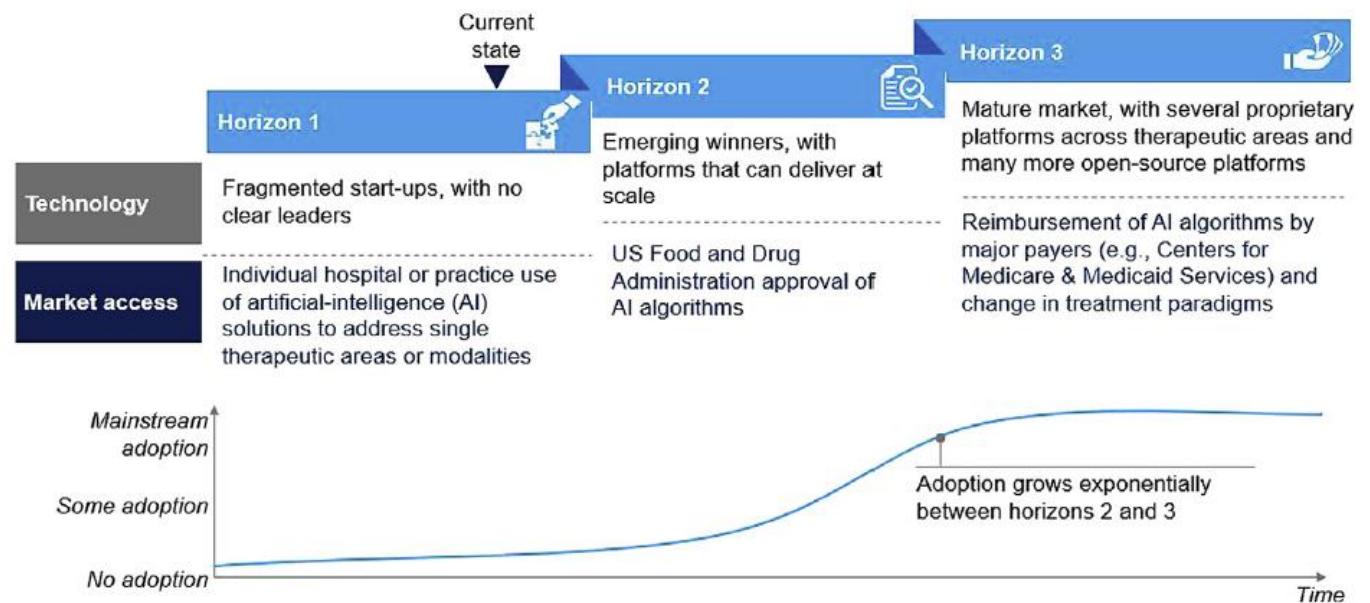
Radyologların Yapay Zekaya Bakışı



Kaynak: Alexander, A., Jiang, A., Ferreira, C., & Zurkiya, D. (2020). An intelligent future for medical imaging: a market outlook on artificial intelligence for medical imaging. *Journal of the American College of Radiology*, 17(1), 165-170.

Medikal Görüntüleme - Yapay Zeka Ekonomisi

- ▶ AI temelli medikal görüntü işleme firmaları:
 - ▶ Sayısı > 115; son 3 yılda 3 katına çıkmış
 - ▶ Yatırım miktarı > 1.17 milyar \$; son 3 yılda 2 katına çıkmış



Kaynak: Alexander, A., Jiang, A., Ferreira, C., & Zurkiya, D. (2020). An intelligent future for medical imaging: a market outlook on artificial intelligence for medical imaging. *Journal of the American College of Radiology*, 17(1), 165-170.

Medikal Görüntüleme – Derin Öğrenme

Kaynak:Sahiner, B., Pezeshk, A., Hadjiiski, L. M., Wang, X., Drukker, K., Cha, K. H., ... & Giger, M. L. (2019). Deep learning in medical imaging and radiation therapy. *Medical physics*, 46(1), e1-e36.

TABLE I. Organ and substructure segmentation summary and performance using DL.

Region	Segmentation object	Network input	Network architecture basis	Dataset (train/test)	Dice coefficient on test set
Abdomen	Skeletal muscle ⁸⁹	Whole image	FCN	250/150 patients	0.93
	Subcutaneous and visceral fat areas ⁹⁰	Image patch	Custom	20/20 patients	0.92–0.98
	Liver, spleen, kidneys ⁹¹	Whole image	Custom	140 scans fivefold CV	0.94–0.96
Bladder	Bladder ⁷⁶	Image patch	CifarNet	81/93 patients	0.86
	Anterior visual pathway ⁹²	Whole image	AE	165 patients LOO CV	0.78
Brain	Bones ⁸⁶	Whole image	U-net	16 patients LOO CV	0.94
	Striatum ⁹³	Whole image	Custom	15/18 patients	0.83
	Substructures ⁹⁴	Image patch	Custom	15/20 patients	0.86–0.95
	Substructures ⁹⁵	Image patch	Custom	20/10 patients	0.92
	Substructures ⁹⁶	Image patch	Deep Residual Network ⁹²	18 patients sixfold CV	0.69–0.83
	Substructures ⁹⁷	Whole image	FCN	150/947 patients	0.86–0.92
Breast	Dense tissue and fat ⁹⁸	Image patch	Custom	493 images fivefold CV	0.63–0.95
	Breast and fibroglandular tissue ⁸⁵	Whole image	U-net	66 patients threefold CV	0.85–0.94
Head and neck	Organs-at-risk ⁸³	Image patch	Custom	50 patients fivefold CV	0.37–0.90
	Left ventricle ⁷⁹	Whole image	AE	15/15 patients	0.93
Heart	Left ventricle ⁸²	Whole image	AE	15/15 patients	0.94
	Left ventricle ⁹⁹	Image patch	Custom	100/100 patients	0.86
	Left ventricle ¹⁰⁰	Image Patch	Custom	100/100 patients	0.88
	Fetal left ventricle ¹⁰¹	Image patch	Custom	10/41 patients	0.95
	Right ventricle ⁷⁸	Whole image	AE	16/16 patients	0.82
	Kidney ¹⁰²	Whole image	Custom	2000/400 patients	0.97
Kidney	Kidney ¹⁰³	Whole image	FCN	165/79 patients	0.86
	Femur, femoral cartilage, tibia, tibial cartilage ⁸¹	Whole image	Custom	60/40 images	–
Liver	Liver ⁸⁰	Image patch	Custom	78/40 patients	–
	Liver ¹⁰⁴	Image patch	Custom	109/32 patients	0.97
Lung	Portal vein ⁸³	Image Patch	Custom	72 scans eightfold CV	0.70
	Lung ¹⁰⁵	Whole image	HNN	62 slices/31 patients	0.96–0.97
Pancreas	Pancreas ¹⁰⁶	Image patch	Custom	80 patients sixfold CV	0.71
	Pancreas ¹⁰⁷	Image patch	Custom	82 patients fourfold CV	0.72
Prostate	Prostate ¹⁰⁸	Image patch	AE	66 patients twofold CV	0.87
	Prostate ¹⁰⁹	Image patch	Custom	30 patients LOO CV	0.87
	Prostate ¹¹⁰	Whole image	FCN	41/99 patients	0.85
	Prostate ⁸⁷	Whole image	HNN	250 patients fivefold CV	0.90
	Organs-at-risk ¹¹¹	Whole Image	VGG-16	218/60 patients	0.88–0.93
	Spine	Intervertebral disk ¹¹²	Image Patch	Custom	18/6 scans
Whole body	Multiple organs ¹¹³	Whole Image	FCN	228/12 scans	–
	Multiple organs	Liver and heart (blood pool, myocardium) ¹¹⁴	Whole Image	Custom	Liver: 20/10 patients Heart: 10/10 patients

Medikal Görüntüleme

- Derin Öğrenme

Kaynak:Sahiner, B., Pezeshk, A., Hadjiiski, L. M., Wang, X., Drukker, K., Cha, K. H., ... & Giger, M. L. (2019). Deep learning in medical imaging and radiation therapy. *Medical physics*, 46(1), e1-e36.

TABLE II. Lesion segmentation summary and performance using DL.

Region	Segmentation object	Network input	Network architecture basis	Dataset (train/test)	Dice coefficient on test set
Bladder	Bladder lesion ⁷⁷	Image patch	CifarNet	62 patients LOO CV	0.51
Breast	Breast lesion ¹¹⁸	Image patch	Custom	107 patients fourfold CV	0.93
Bone	Osteosarcoma ¹¹⁹	Whole image	ResNet-50	15/8 patients	0.89
	Osteosarcoma ¹²⁰	Whole image	FCN	1900/405 images from 23 patients	0.90
Brain	Brain lesion ¹²¹	Image patch	Custom	61 patients fivefold CV	0.65
	Brain metastases ¹²²	Image patch	Custom	225 patients fivefold CV	0.67
	Brain tumor ¹¹⁵	Image patch	AE	HGG: 150/69 patients, LGG: 20/23 patients	HGG: 0.86 LGG: 0.82
	Brain tumor ¹¹⁷	Image patch	Custom	HGG: 220, LGG: 54, fivefold CV	HGG: 0.85–0.91 LGG: 0.83–0.86
	Brain tumor ¹²³	Whole image	Custom	30/25 patients	0.88
	Brain tumor ¹²⁴	Whole image	FCN	274/110 patients	0.82
	Brain tumor ⁸⁸	Whole image	HNN	20/10 patients	0.83
	Ischemic lesions ¹²⁵	Whole image	DeConvNet	380/381 patients	0.88
	Multiple sclerosis lesion ¹²⁶	Whole image	Custom	250/77 patients	0.64
	White matter hyperintensities ¹¹⁶	Image patch	AE	100/135 patients	0.88
	White matter hyperintensities ¹²⁷	Image patch	Custom	378/50 patients	0.79
Head and neck	Nasopharyngeal cancer ¹²⁸	Whole image	VGG-16	184/46 patients	0.81–0.83
	Thyroid nodule ¹²⁹	Image patch	HNN	250 patients fivefold CV	0.92
Liver	Liver lesion ¹³⁰	Image patch	Custom	26 patients LOO CV	0.80
Lung	Lung nodule ¹³¹	Image patch	Custom	350/493 nodules	0.82
Lymph nodes	Lymph nodes ¹³²	Whole image	HNN	171 patients fourfold CV	0.82
Rectum	Rectal cancer ¹³³	Image patch	Custom	70/70 patients	0.68
Skin	Melanoma ¹³⁴	Image patch	Custom	126 images fourfold CV	–

Medikal Görüntüleme

- Derin Öğrenme

Kaynak:Sahiner, B., Pezeshk, A., Hadjiiski, L. M., Wang, X., Drukker, K., Cha, K. H., ... & Giger, M. L. (2019). Deep learning in medical imaging and radiation therapy. *Medical physics*, 46(1), e1-e36.

TABLE III. Organ and anatomical structure detection summary and performance.

Organ	Detection object	Network input	Network architecture basis	Dataset (train/test)	Error (mean \pm SD)
Bone	37 hand landmarks ¹⁴⁷	X-ray images	Custom CNN	895 images threefold CV	1.19 ± 1.14 mm
	Femur bone ¹³⁵	MR 2.5D image patches	Custom 3D CNN	40/10 volumes	4.53 ± 2.31 mm
	Vertebrae ¹⁴⁸	MR/CT image patches	Custom CNN	1150 patches/110 images	3.81 ± 2.98 mm
	Vertebrae ¹⁴⁹	US/x-ray images	U-Net	22/19 patients	F1:0.90
Vessel	Carotid artery ¹⁵⁰	CT 3D image patches	Custom 3D CNN	455 patients fourfold CV	2.64 ± 4.98 mm
	Ascending aorta ¹³⁹	3D US	Custom CNN	719/150 patients	1.04 ± 0.50 mm
Fetal anatomy	Abdominal standard scan plane ^{136,151}	US image patches	Custom CNN	11942/8718 images	F1:0.71 ¹³⁶ , 0.75 ¹⁵¹
	12 standard scan planes ¹³⁷	US images	Custom CNN	800/200 images	F1:0.42–0.93
	13 standard scan planes ¹³⁸	US images	AlexNet	5229/2339 images	Acc: 0.10–0.94
Body	Body parts ¹⁵²	CT images	AlexNet + FCN	450/49 patients	3.9 ± 4.7 voxels
	Body parts ¹⁵³	CT images	AlexNet	3438/860 images	AUC: 0.998
	Multiple Organ ¹⁵⁴	3D CT images	Custom CNN	200/200 scans	F1:0.97
	Body parts ^{141,142}	CT images	LeNet	2413/4043 images	F1:0.92
Brain	Brain landmarks ¹⁵⁵	MR images	FCN	350/350 images	2.94 ± 1.58 mm
Lung	Pathologic Lung ¹⁵⁶	CT images	FCN	929 scans fivefold CV	0.76 ± 0.53 mm
Extremities	Thigh muscle ¹⁵⁷	MR images	FCN	15/10 patients	1.4 ± 0.8 mm
Heart	Ventricle landmarks ^{143–145}	MRI images	Custom CNN + RL	801/90 images	2.9 ± 2.4 mm

Medikal Görüntüleme - Derin Öğrenme

Kaynak:Sahiner, B., Pezeshk, A., Hadjiiski, L. M., Wang, X., Drukker, K., Cha, K. H., ... & Giger, M. L. (2019). Deep learning in medical imaging and radiation therapy. *Medical physics*, 46(1), e1-e36.

TABLE IV. Lesion detection using DL.

Detection organ	Lesion type	Dataset (train/test)	Network input	Network architecture basis
Lung and thorax	Pulmonary nodule	888 patients fivefold CV ¹⁶⁸ 888 patients tenfold CV ¹⁶⁹ 303 patients tenfold CV ¹⁷³ 2400 images tenfold CV ¹⁷⁴ 104 patients fivefold CV ¹⁷⁵ 1006 patients tenfold CV ¹⁷⁶ 35,038/2,443 radiographs ¹⁷⁸ 76,000/22,000 chest x rays ¹⁸⁰ ImageNet Pretraining, 433 patients LOO CV ¹⁸¹	Image patch ^{168,169,173–177} Whole image ^{178–180}	CNN ^{168,169,173,175–180} SDAE/CNN ¹⁷⁴
Brain	Multiple pathologies	Tuberculosis Cerebral aneurism Cerebral microbleed Lacune	Image patch ¹⁸² Whole image ^{170,172}	CNN ¹⁸² FCN/CNN ^{170,172}
Breast	Solid cancer	40,000/18,000 mammographic images ⁶⁴ 161/160 breast MR images ¹⁸³ Mass	Image patch ^{17,64,183} Whole image ^{66,161}	CNN ^{17,64,66,183} FCN/CNN ¹⁶¹
Colon	Malignant mass and microcalcification	Pretraining on ~2300 mammography images, 277/47 DBT cases ¹⁷ ImageNet pretraining, 306/163 breast ultrasounds images ¹⁶¹ ImageNet Pretraining, 3476/115 FFDM images ⁶⁶		
Multiple	Polyp	394/792 CT colonography cases ¹⁶⁶ 101 CT colonography cases; tenfold CV ¹⁸⁵	Whole image, ¹⁸⁴ Image patch ^{166,185}	CNN ^{166,184,185}
Liver	Colitis	ImageNet Pretraining, 160 abdominal CT cases; fourfold CV ¹⁸⁴		
Thyroid	Lymph node	ImageNet Pretraining, 176 CT cases; threefold CV ¹⁶⁰ 69/17 abdominal CT cases ¹⁶⁶ 176 abdominal CT cases; threefold CV ¹⁸⁶	Image patch ^{160,166,186}	CNN ^{160,166,186}
Prostate	Tumor	NA/37 ¹⁸⁷	Image patch ¹⁸⁷	CNN ¹⁸⁷
Pericardium	Nodule	21,523 ultrasound images; tenfold CV ¹⁸⁸	Image patch ¹⁸⁸	CNN ¹⁸⁸
Vascular	Cancer	196 MR cases; tenfold CV ¹⁸⁹	Whole image ¹⁸⁹	FCN ¹⁸⁹
	Effusion	20/5 CT cases ¹⁹⁰	Whole image ¹⁹⁰	FCN ¹⁹⁰
	Calcification	ImageNet pretraining; 84/28 ¹⁹¹	Image patch ¹⁹¹	FCN ¹⁹¹

Medikal Görüntüleme – Derin Öğrenme

Kaynak:Sahiner, B., Pezeshk, A., Hadjiiski, L. M., Wang, X., Drukker, K., Cha, K. H., ... & Giger, M. L. (2019). Deep learning in medical imaging and radiation therapy. *Medical physics*, 46(1), e1-e36.

TABLE V. Characterization using DL.

Anatomic site	Object or task	Network input	Network architecture	Dataset (train/test)
Breast	Cancer risk assessment ¹⁹²	Mammograms	Pretrained Alexnet followed by SVM	456 patients LOO CV
	Cancer risk assessment ¹⁹³	Mammograms	Modified AlexNet	14,000/1850 images randomly selected 20 times
	Cancer risk assessment ¹⁹⁴	Mammograms	Custom DCNN	478/183 mammograms
	Cancer risk assessment ¹⁹⁵	Mammograms	Fine-tuned a pretrained VGG16Net	513/91 women
	Diagnosis ¹⁹⁶	Mammograms	Pretrained AlexNet followed by SVM	607 cases fivefold CV
	Diagnosis ¹⁹⁷	Mammograms, MRI, US	Pretrained VGG19Net followed by SVM	690 MRI, 245 FFDM 1125 US, LOO CV
	Diagnosis ¹⁹⁸	Breast tomosynthesis	Pretrained Alexnet followed by evolutionary pruning	2682/89 masses
	Diagnosis ¹⁹⁹	Mammograms	Pretrained AlexNet	1545/909 masses
	Diagnosis ²⁰⁰	MRI MIP	Pretrained VGG19Net followed by SVM	690 cases with fivefold CV
	Diagnosis ²⁰¹	DCE-MRI	LSTM	562/141 cases
Chest — lung	Solitary cyst diagnosis ²⁰²	Mammograms	Modified VGG Net	1600 lesions eightfold CV
	Prognosis ²⁰³	Mammograms	VGG16Net followed by logistic regression classifier	79/20 cases randomly selected 100 times
	Pulmonary nodule classification ²⁰⁴	CT patches	ResNet	665/166 nodules
	Tissue classification ²⁰⁵	CT patches	Restricted Boltzmann machines	Training 50/100/150/200; testing 20,000/1000/20,000/20,000 image patches
	Interstitial disease ²⁰⁶	CT patches	Modified AlexNet	100/20 patients
	Interstitial disease ²⁰⁷	CT patches	Modified VGG	Public: 71/23 scans Local: 20/6 scans
	Interstitial disease ²⁰⁸	CT patches	Custom	480/(120 and 240)
	Interstitial disease ²⁰⁹	CT patches	Custom	36,106/1050 patches
	Pulmonary nodule staging ²¹⁰	CT	DFCNet	11/7 patients
	Prognosis ²¹¹	CT	Custom	7983/(1000 and 2164) subjects
Chest — cardiac	Calcium scoring ²¹²	CT	Custom	1181/506 scans
	Ventricle quantification ²¹³	MR	Custom (CNN + RNN + Bayesian multitask)	145 cases, fivefold CV
Abdomen	Tissue classification ²¹⁴	Ultrasound	CaffeNet and VGGNet	136/49 Studies
	Liver tumor classification ²¹⁵	Portal Phase 2D CT	GAN	182 cases, threefold CV
	Liver Fibrosis ²¹⁶	DCE-CT	Custom CNN	460/100 scans
	Fatty liver disease ²¹⁷	US	Invariant scattering convolution network	650 patients, five- and tenfold CV
Brain	Survival ²¹⁸	Multiparametric MR	Transfer learning as feature extractor, CNN-S	75/37 patients
Skeletal	Maturity ²¹⁹	Hand radiographs	Deep residual network	14,036/(200 and 913) examinations

Medikal Görüntüleme – Derin Öğrenme

Kaynak:Sahiner, B., Pezeshk, A., Hadjiiski, L. M., Wang, X., Drukker, K., Cha, K. H., ... & Giger, M. L. (2019). Deep learning in medical imaging and radiation therapy. *Medical physics*, 46(1), e1-e36.

TABLE VI. Image processing and reconstruction with DL.

Task	Imaging modality	Performance measure	Network output	Network architecture basis
Filtering	CT, ²³⁴ Chest x ray, ²³⁵ x ray fluoro ²³⁶	MSE ²³⁴ , CAD performance, ²³⁴ PSNR, ^{235,236} SSIM, ^{235,236} Runtime ²³⁶	Likelihood of nodule, ²³⁴ Bone image, ²³⁵ CLAHE filtering ²³⁶	Custom CNN, ^{234,235} Residual CNN, ²³⁶ Residual AE ²³⁶
Noise reduction	CT, ²³⁷⁻²⁴⁰ PET ²⁴¹	PSNR, ²³⁷⁻²⁴¹ RMSE, ^{237,238} SSIM, ^{237,238,240} NRMSE, ²³⁹ NMSE ²⁴¹	Noise-reduced image ²³⁷⁻²⁴¹	Custom CNN, ²³⁷⁻²³⁹ Residual AE, ^{237,238} Concatenated CNNs, ²⁴¹ U-net ²⁴⁰
Artifact reduction	CT, ^{242,243} MRI ²⁴⁴	SNR, ^{242,243} NMSE, ²⁴⁴ Qualitative, ²⁴³ Runtime ²⁴⁴	Sparse-view recon, ^{242,244} Metal artifact reduced image ²⁴³	U-net, ^{242,244} Custom CNN ²⁴³
Recons	MRI ²⁴⁵⁻²⁴⁸	RMSE, ^{245,248} runtime, ²⁴⁵ MSE, ^{246,247} NRMSE, ²⁴⁶ SSIM, ²⁴⁶ SNR ²⁴⁸	Image of scalar measures, ²⁴⁵ MR reconstruction ²⁴⁶⁻²⁴⁸	Custom CNN, ^{245,248} Custom NN, ²⁴⁶ Cascade of CNNs ²⁴⁷
Registration	MRI ²⁴⁹⁻²⁵² x-ray to 3D ^{253,254}	DICE, ^{249,250} Runtime, ²⁵⁰ Target Overlap, ²⁵¹ SNR, ²⁵² TRE, ²⁵⁴ Image and vessel sharpness, ²⁵² mTREproj ²⁵³	Deformable registration, ²⁴⁹⁻²⁵² Rigid body 3D transformation ^{253,254}	Custom CNN, ^{249,251-254} SAE ²⁵⁰
Synthesis of one modality from another	CT from MRI, ²⁵⁵⁻²⁵⁹ MRI from PET, ²⁶⁰ PET from CT ²⁶¹	MAE, ^{255,256} PSNR, ^{255,259} ME, ²⁵⁶ MSE, ²⁵⁶ Pearson correl, ²⁵⁶ PET image Quality, ^{257,258} SSIM, ²⁶⁰ SUVR of MR-less methods, ²⁶⁰ Tumor detection by radiologist ²⁶¹	Synthetic CT, ²⁵⁵⁻²⁵⁸ Synthetic MRI, ²⁶⁰ Synthetic PET ²⁶¹	Custom 3D FCN, ²⁵⁵ GAN, ²⁵⁹⁻²⁶¹ U-net, ^{256,257} AE ²⁵⁸
Image quality assessment	US, ²⁶² CT, ^{263,264} MRI ²⁶⁵	AUC, ^{262,264} IOU, ²⁶² Correlation between TRE estimation and ground truth, ²⁶³ Concordance with readers ²⁶⁵	ROI localization and classification, ²⁶² TRE estimation, ²⁶³ Estimate of image diagnostic value ^{264,265}	Custom CNN, ^{262,265} Custom NN, ²⁶³ VGG19 ²⁶⁴

Medikal Görüntüleme - Derin Öğrenme

Kaynak:Sahiner, B., Pezeshk, A., Hadjiiski, L. M., Wang, X., Drukker, K., Cha, K. H., ... & Giger, M. L. (2019). Deep learning in medical imaging and radiation therapy. *Medical physics*, 46(1), e1-e36.

TABLE VII. Radiotherapy and assessment of response to treatment with DL.

Anatomic site	Object or task	Network input	Network architecture	Dataset (train/test)
Bladder	Treatment response assessment ²⁶⁸	CT	CifarNet	82/41 patients
Brain	Glioblastoma multi forme treatment options and survival prediction ²¹⁸	MRI	Custom	75/37 patients
	Assessment of treatment effect in acute ischemic stroke ²⁶⁹	MRI	CNN based on SegNet	158/29 patients
Breast	Response to neoadjuvant chemotherapy ²⁷⁰	MRI	Pretrained VGGNet followed by LDA	561 examinations from 64 subjects LOO CV
	Response to neoadjuvant chemotherapy ²⁷¹	MRI	Custom	133/33 patients
	Segmentation of clinical target volume ²⁷²	CT	Deep dilated residual network	800 patients fivefold CV
Cancer cell lines	Prediction of drug effectiveness in cancer cell lines ²⁷³	Multiple omics data from cancer cells (gene expression data, copy number variation data, mutation data, and cell line annotations)	Deep autoencoder	520/104 cell lines
Head and Neck	Organ segmentation ²⁷⁴	CT	U-Net based with shape retention model	22/10 scans
Kidney	Renal segmentation ²⁷⁵	CT	Custom	89/24 patients
	Early detection of acute renal transplant rejection ²⁷⁶	DWI-MRI	Stacked autoencoders	100 patients fourfold, tenfold and LOO CV
Liver	Hepatobiliary toxicity prediction after liver SBRT ²⁷⁷	CT and patient demographics, clinical information	Custom CNN trained on other organs, fine-tuned on liver SBRT	125 patients 20-fold CV
Lung	Estimation of dose protocols in Radiotherapy ²⁷⁸	FDG-PET/CT, clinical, genetic, imaging radiomics features, tumor and lung dosimetric variables, treatment plans	Deep Q-Network	114 real train/4000 synthesized test cases
Prostate	Dynamic tracking during therapy ²⁷⁹	DRRs from 4D CT	DenseNet	1/9 volumes
	Prediction of dose from patient image contours ²⁸⁰	IMRT	U-net	80/8 patients
	Prediction of dosimetric eligibility of prostate cancer patients undergoing IMRT ²⁸¹	CT	Fine-tuned AlexNet	60 patients fivefold CV
Pelvis	Generating synthetic CTs from MR-only radiotherapy ²⁸²	MRI	CGAN	123/59 patients
	Assessment of toxicity to normal organs and tissue ²⁸³	Rectum surface dose maps	Fine-tuned VGG-16	42 patients tenfold and LOO CV
Rectum	Segmentation of rectal tumors on T2-MRI and clinical target volume segmentation on CT ²⁷²	T2-MRI or CT	Novel CNN involving cascaded atrous convolution and spatial pyramid pooling	70 T2-MR and 100 CT fivefold CV
	Prediction of pathologic complete response after chemoradiation ²⁸⁴	CT	DNN classifier custom estimator	95 patients fivefold CV

Yapay Zeka ile Tıbbi Verilerle İlgili Temel Hususlar

- ▶ Anonimleştirilmiş veri (mahremiyet) gereksinimi
- ▶ Etiketlenmiş veri gereksinimi
- ▶ «Doğru» etiketlenmiş veri gereksinimi; doğrulama
- ▶ Özellikle derin öğrenmeye yönelik bol veri gereksinimi

- ▶ İnsidansı az olan hastalıklar için dengesiz veri seti sıkıntıları
- ▶ İrk, yaş, özel nitelik vb. bazlı farklılıklardan kaynaklı olarak veri setinin global ol(a)maması olasılığı

Yapay Zeka ile Tıbbi Görüntülerle İlgili Temel Hususlar

- ▶ Sadece sınıflandırma değil
 - ▶ Image Deidentification
 - ▶ Image Reconstruction
 - ▶ Image Segmentation
 - ▶ Image Registrationgereksinimleri
- ▶ Farklı tekniklerle alınmış görüntüler için özel ve farklı ön işleme gereksinimleri
- ▶ Genel modeller jenerik ve düşük çözünürlüklü görüntülerle eğitilmiş durumda; medikal görüntülere, 3D/4D görüntülere vb. özel modeller ve eğitimler gerekmekte

Kaynak: Prevedello, L. M., Halabi, S. S., Shih, G., Wu, C. C., Kohli, M. D., Chokshi, F. H., ... & Flanders, A. E. (2019). Challenges related to artificial intelligence research in medical imaging and the importance of image analysis competitions. *Radiology: Artificial Intelligence*, 1(1), e180031.

Yapay Zeka ile Tıbbi Görüntülerle İlgili Temel Hususlar

- ▶ Çok fazla olası tanı ve sınıf bulunmakta:
 - ▶ Radiology Gamuts Ontology'ye göre 12878 semptom, 4662 hastalık
- ▶ «Automation Risk» hususunun akademik/bilimsel olarak irdelenmesi ve analiz edilmesi lazım!...

- ▶ Kaynak: Budovec, J. J., Lam, C. A., & Kahn Jr, C. E. (2014). Informatics in radiology: radiology gamuts ontology: differential diagnosis for the Semantic Web. *Radiographics*, 34(1), 254-264.

Yapay Zeka ile Tıbbi Görüntülerle İlgili Temel Hususlar

- ▶ Bu tarz çalışmaların sistematigi konusunda bir kılavuz/standart ihtiyacı:
 - ▶ Hem çalışmaları yürütenler, hem değerlendirciler için

Kaynak: Mongan, J., Moy, L., & Kahn Jr, C. E. (2020). Checklist for artificial intelligence in medical imaging (CLAIM): a guide for authors and reviewers.

Prof. Dr. A. Egemen YILMAZ
Ankara Üniversitesi

Checklist for Artificial Intelligence in Medical Imaging (CLAIM)		
Section/Topic	No.	Item
TITLE OR ABSTRACT	1	Identification as a study of AI methodology, specifying the category of technology used (eg, deep learning)
ABSTRACT	2	Structured summary of study design, methods, results, and conclusions
INTRODUCTION	3	Scientific and clinical background, including the intended use and clinical role of the AI approach
	4	Study objectives and hypotheses
METHODS		
Study Design	5	Prospective or retrospective study
	6	Study goal, such as model creation, exploratory study, feasibility study, noninferiority trial
Data	7	Data sources
	8	Eligibility criteria: how, where, and when potentially eligible participants or studies were identified (eg, symptoms, results from previous tests, inclusion in registry, patient-care setting, location, dates)
	9	Data preprocessing steps
	10	Selection of data subsets, if applicable
	11	Definitions of data elements, with references to common data elements
	12	De-identification methods
	13	How missing data were handled
Ground Truth	14	Definition of ground truth reference standard, in sufficient detail to allow replication
	15	Rationale for choosing the reference standard (if alternatives exist)
	16	Source of ground truth annotations; qualifications and preparation of annotators
	17	Annotation tools
	18	Measurement of inter- and intrarater variability; methods to mitigate variability and/or resolve discrepancies
Data Partitions	19	Intended sample size and how it was determined
	20	How data were assigned to partitions; specify proportions
	21	Level at which partitions are disjoint (eg, image, study, patient, institution)
Model	22	Detailed description of model, including inputs, outputs, all intermediate layers and connections
	23	Software libraries, frameworks, and packages
	24	Initialization of model parameters (eg, randomization, transfer learning)
Training	25	Details of training approach, including data augmentation, hyperparameters, number of models trained
	26	Method of selecting the final model
	27	Ensembling techniques, if applicable
Evaluation	28	Metrics of model performance
	29	Statistical measures of significance and uncertainty (eg, confidence intervals)
	30	Robustness or sensitivity analysis
	31	Methods for explainability or interpretability (eg, saliency maps) and how they were validated
	32	Validation or testing on external data
RESULTS		
Data	33	Flow of participants or cases, using a diagram to indicate inclusion and exclusion
	34	Demographic and clinical characteristics of cases in each partition
Model performance	35	Performance metrics for optimal model(s) on all data partitions
	36	Estimates of diagnostic accuracy and their precision (such as 95% confidence intervals)
	37	Failure analysis of incorrectly classified cases
DISCUSSION	38	Study limitations, including potential bias, statistical uncertainty, and generalizability
	39	Implications for practice, including the intended use and/or clinical role
OTHER INFORMATION	40	Registration number and name of registry
	41	Where the full study protocol can be accessed
	42	Sources of funding and other support; role of funders

Kaynaklar

- ▶ Langlotz, C. P., Allen, B., Erickson, B. J., Kalpathy-Cramer, J., Bigelow, K., Cook, T. S., ... & Kandarpa, K. (2019). A roadmap for foundational research on artificial intelligence in medical imaging: from the 2018 NIH/RSNA/ACR/The Academy Workshop. *Radiology*, 291(3), 781-791.
- ▶ Sharma, P., Suehling, M., Flohr, T., & Comaniciu, D. (2020). Artificial intelligence in diagnostic imaging: status quo, challenges, and future opportunities. *Journal of thoracic imaging*, 35, S11-S16.
- ▶ Pesapane, F., Codari, M., & Sardanelli, F. (2018). Artificial intelligence in medical imaging: threat or opportunity? Radiologists again at the forefront of innovation in medicine. *European radiology experimental*, 2(1), 1-10.
- ▶ Alexander, A., Jiang, A., Ferreira, C., & Zurkiya, D. (2020). An intelligent future for medical imaging: a market outlook on artificial intelligence for medical imaging. *Journal of the American College of Radiology*, 17(1), 165-170.
- ▶ Prevedello, L. M., Halabi, S. S., Shih, G., Wu, C. C., Kohli, M. D., Chokshi, F. H., ... & Flanders, A. E. (2019). Challenges related to artificial intelligence research in medical imaging and the importance of image analysis competitions. *Radiology: Artificial Intelligence*, 1(1), e180031.
- ▶ Mongan, J., Moy, L., & Kahn Jr, C. E. (2020). Checklist for artificial intelligence in medical imaging (CLAIM): a guide for authors and reviewers.
- ▶ Zhou, S. K., Greenspan, H., Davatzikos, C., Duncan, J. S., Van Ginneken, B., Madabhushi, A., ... & Summers, R. M. (2021). A review of deep learning in medical imaging: Imaging traits, technology trends, case studies with progress highlights, and future promises. *Proceedings of the IEEE*.
- ▶ Zhu, G., Jiang, B., Tong, L., Xie, Y., Zaharchuk, G., & Wintermark, M. (2019). Applications of deep learning to neuro-imaging techniques. *Frontiers in neurology*, 10, 869.

Kaynaklar

- ▶ Greenspan, H., Van Ginneken, B., & Summers, R. M. (2016). Guest editorial deep learning in medical imaging: Overview and future promise of an exciting new technique. *IEEE transactions on medical imaging*, 35(5), 1153-1159.
- ▶ Sahiner, B., Pezeshk, A., Hadjiiski, L. M., Wang, X., Drukker, K., Cha, K. H., ... & Giger, M. L. (2019). Deep learning in medical imaging and radiation therapy. *Medical physics*, 46(1), e1-e36.
- ▶ Kim, M., Yun, J., Cho, Y., Shin, K., Jang, R., Bae, H. J., & Kim, N. (2019). Deep learning in medical imaging. *Neurospine*, 16(4), 657.
- ▶ Kim, J., Hong, J., & Park, H. (2018). Prospects of deep learning for medical imaging. *Precision and Future Medicine*, 2(2), 37-52.
- ▶ Lee, J. G., Jun, S., Cho, Y. W., Lee, H., Kim, G. B., Seo, J. B., & Kim, N. (2017). Deep learning in medical imaging: general overview. *Korean journal of radiology*, 18(4), 570-584.
- ▶ Suzuki, K. (2017). Overview of deep learning in medical imaging. *Radiological physics and technology*, 10(3), 257-273.
- ▶ Lakhani, P., Gray, D. L., Pett, C. R., Nagy, P., & Shih, G. (2018). Hello world deep learning in medical imaging. *Journal of digital imaging*, 31(3), 283-289.
- ▶ Currie, G., Hawk, K. E., Rohren, E., Vial, A., & Klein, R. (2019). Machine learning and deep learning in medical imaging: intelligent imaging. *Journal of medical imaging and radiation sciences*, 50(4), 477-487.

Tıp Eğitiminde Yapay Zekâ

Prof. Dr. A. Egemen YILMAZ

Ankara Üniversitesi

Mühendislik Fakültesi Elektrik-Elektronik Mühendisliği Bölümü

Mühendislik Fakültesi Yazılım Mühendisliği Bölümü

Fen Bilimleri Enstitüsü Disiplinler Arası Yapay Zeka Teknolojileri Ana Bilim Dalı

Akıllı Sistemler ve Teknolojiler Uygulama ve Araştırma Merkezi (ASTAM)

Yapay Zekanın Eğitimde Kullanımı

- ▶ Müfredat ve Eğitim Materyali Oluşturma
- ▶ Eğitim İcrası - Kişiiselleştirilmiş Eğitim
- ▶ Bireysel/Grup Bazında Ölçme ve Değerlendirme

Yapay Zekanın Tıp Eğitiminde Kullanımına Dair

- ▶ Clancey ve Stanford Üniversiteleri - GUIDON (1983): Enfeksiyon hastalıklarına ilişkin tanı eğitim yazılımı
- ▶ Papa *et al.* - İsimsiz Yazılım (1992): Tanı yardım yazılımı
- ▶ Eliot ve Woolf - The Cardiac Tutor (1995): Kardiyak resüsitasyon eğitim simülatörü
- ▶ Billinghurst *et al.* - Prototype Sinus Surgery (1996): Cerrahi eğitim simülatörü
- ▶ Bourlas *et al.* - CARDIO-LOGOS (1996): EKG örüntülerini öğreten eğitim simülatörü
- ▶ Voss *et al.* - LAHYSTOTRAIN (2000): Laparoskopi ve histeroskopi eğitim simülatörü
- ▶ Stasiu *et al.* - CARDILOG (2001): EKG örüntülerini öğreten eğitim simülatörü
- ▶ Caudell *et al.* - Project TOUCH (2003): Hasta muayenesine yönelik Sanal Gerçeklik simülatörü
- ▶ Crowley ve Medvedeva - SlideTutor (2003): Dermatopatoloji tanı/sınıflandırma eğitim simülatörü

Kaynak: Chan, K. S., & Zary, N. (2019). Applications and challenges of implementing artificial intelligence in medical education: integrative review. *JMIR medical education*, 5(1), e13930.

Yapay Zekanın Tıp Eğitiminde Kullanımına Dair

- ▶ Michael *et al.* - CIRCSIM-Tutor (2003): Baroreseptör refleks eğitim uygulaması
- ▶ Weidenbach *et al.* - EchoComJ (2004): Ekokardiyografi eğitim uygulaması
- ▶ Kabanza *et al.* - TeachMed (2006): Klinik gerekçelendirme (sebep-sonuç) eğitim uygulaması
- ▶ Suebnukarn ve Haddawy - COMET (2006): Klinik gerekçelendirme eğitim uygulaması
- ▶ Woo *et al.* - CIRCSIM-Tutor (2006): Fizyolojik nitel nedensel gerekçelendirme eğitim uygulaması
- ▶ Kazi *et al.* - COMET (2009): Diyabet, pnömoni, miyokard enfarktüsü vb. problem temelli medikal eğitim sistemi
- ▶ Association for Institutional Research (2010): Tıp Eğitimi Müfredatı oluşturma/değerlendirme sistemi
- ▶ Chieu *et al.* - TELEOS (2010): Sakroiliak Vida Fiksasyonu eğitim simülatörü

Kaynak: Chan, K. S., & Zary, N. (2019). Applications and challenges of implementing artificial intelligence in medical education: integrative review. *JMIR medical education*, 5(1), e13930.

Yapay Zekanın Tıp Eğitiminde Kullanımına Dair

- ▶ EBSCO Host, Medline (Ovid) ve Web of Science'ta 37 makale
 - ▶ Müfredat oluşturma / değerlendirme (1 adet)
 - ▶ Eğitim destek (1 adet)
 - ▶ Eğitim değerlendirme (1 adet)
- ▶ 37 makalenin çoğu (25 adedi) lisans eğitimi; 14 adedi uzmanlık eğitimi; 8 adedi sürekli/mesleki eğitime yönelik
- ▶ 16'sında model oluşturmanın zorluğundan söz edilmiş
- ▶ 10'unda uzmanlık bilgisinin gerekliliğinden söz edilmiş
- ▶ 4'ünde hekimler-mühendisler arasındaki uçurumdan söz edilmiş
- ▶ 2'sinde genel mimari yapı oluşturmanın imkansızlığından söz edilmiş

Kaynak: Chan, K. S., & Zary, N. (2019). Applications and challenges of implementing artificial intelligence in medical education: integrative review. *JMIR medical education*, 5(1), e13930.

Yapay Zekanın Tıp Eğitiminde Kullanımına Dair

- ▶ 14'ünde Yapay Zeka performansının/verimliliğinin değerlendirmesinin zorluğu
- ▶ 6'sında ölçeklenebilirlik sorunu
- ▶ 4'ünde 'Aceleci Genelleme' sıkıntısı
- ▶ 3'ünde Yapay Zekanın hataları

- ▶ Öğrenme/eğitim destek amaçlı makalelerde:
 - ▶ Öğrenmede/eğitimde geri besleme; süreç performansının düzenli izlenmesi: 21 adet
 - ▶ Maliyet düşürme: 8 adet
 - ▶ Hastaları riske atmama: 6 adet
 - ▶ Eğitmen ihtiyacını azaltma: 3 adet

Kaynak: Chan, K. S., & Zary, N. (2019). Applications and challenges of implementing artificial intelligence in medical education: integrative review. *JMIR medical education*, 5(1), e13930.

Yapay Zekanın Tıp Eğitiminde Kullanımına Dair

- ▶ Öğrenme/öğretim başarım değerlendirme amaçlı makalelerde:
 - ▶ Hızlı değerlendirme: 4 adet
 - ▶ Nesnel değerlendirme: 3 adet
 - ▶ Değerlendirmenin performansı: 2 adet
 - ▶ Maliyet azaltma: 1 adet

Kaynak: Chan, K. S., & Zary, N. (2019). Applications and challenges of implementing artificial intelligence in medical education: integrative review. *JMIR medical education*, 5(1), e13930.

Yapay Zekanın Tıp Eğitiminde Kullanımına Dair

- ▶ Rol değişimi
 - ▶ Hekimlerin Yapay Zeka tasarım faaliyetlerinde daha proaktif olması
 - ▶ Hekimlerin Yapay Zeka destekli sistemlerle daha çok çalışması gerekliliği
 - ▶ Hekimlerin Yapay Zeka destekli sistemlerle etkileşim gerekliliği
 - ▶ Hekimlerin Yeni Yapay Zeka destekli sistemleri öğretmesi/öğrenmesi gerekliliği
- ▶ Birçok husus
 - ▶ Simülasyon, AR/VR/XR ve robotik ile birlikte çalışabilirlik
 - ▶ Veri; jeneriklik; açıklanabilirlik ve doğruluk ödünleşimi; semptom/sendrom/hastalık miktarı; vb.

Kaynak: Masters, K. (2019). Artificial intelligence in medical education. *Medical Teacher*, 41(9), 976-980.

Bilgisayar Mimarileri ve İnsan Beyni

Prof. Dr. A. Egemen YILMAZ

Ankara Üniversitesi

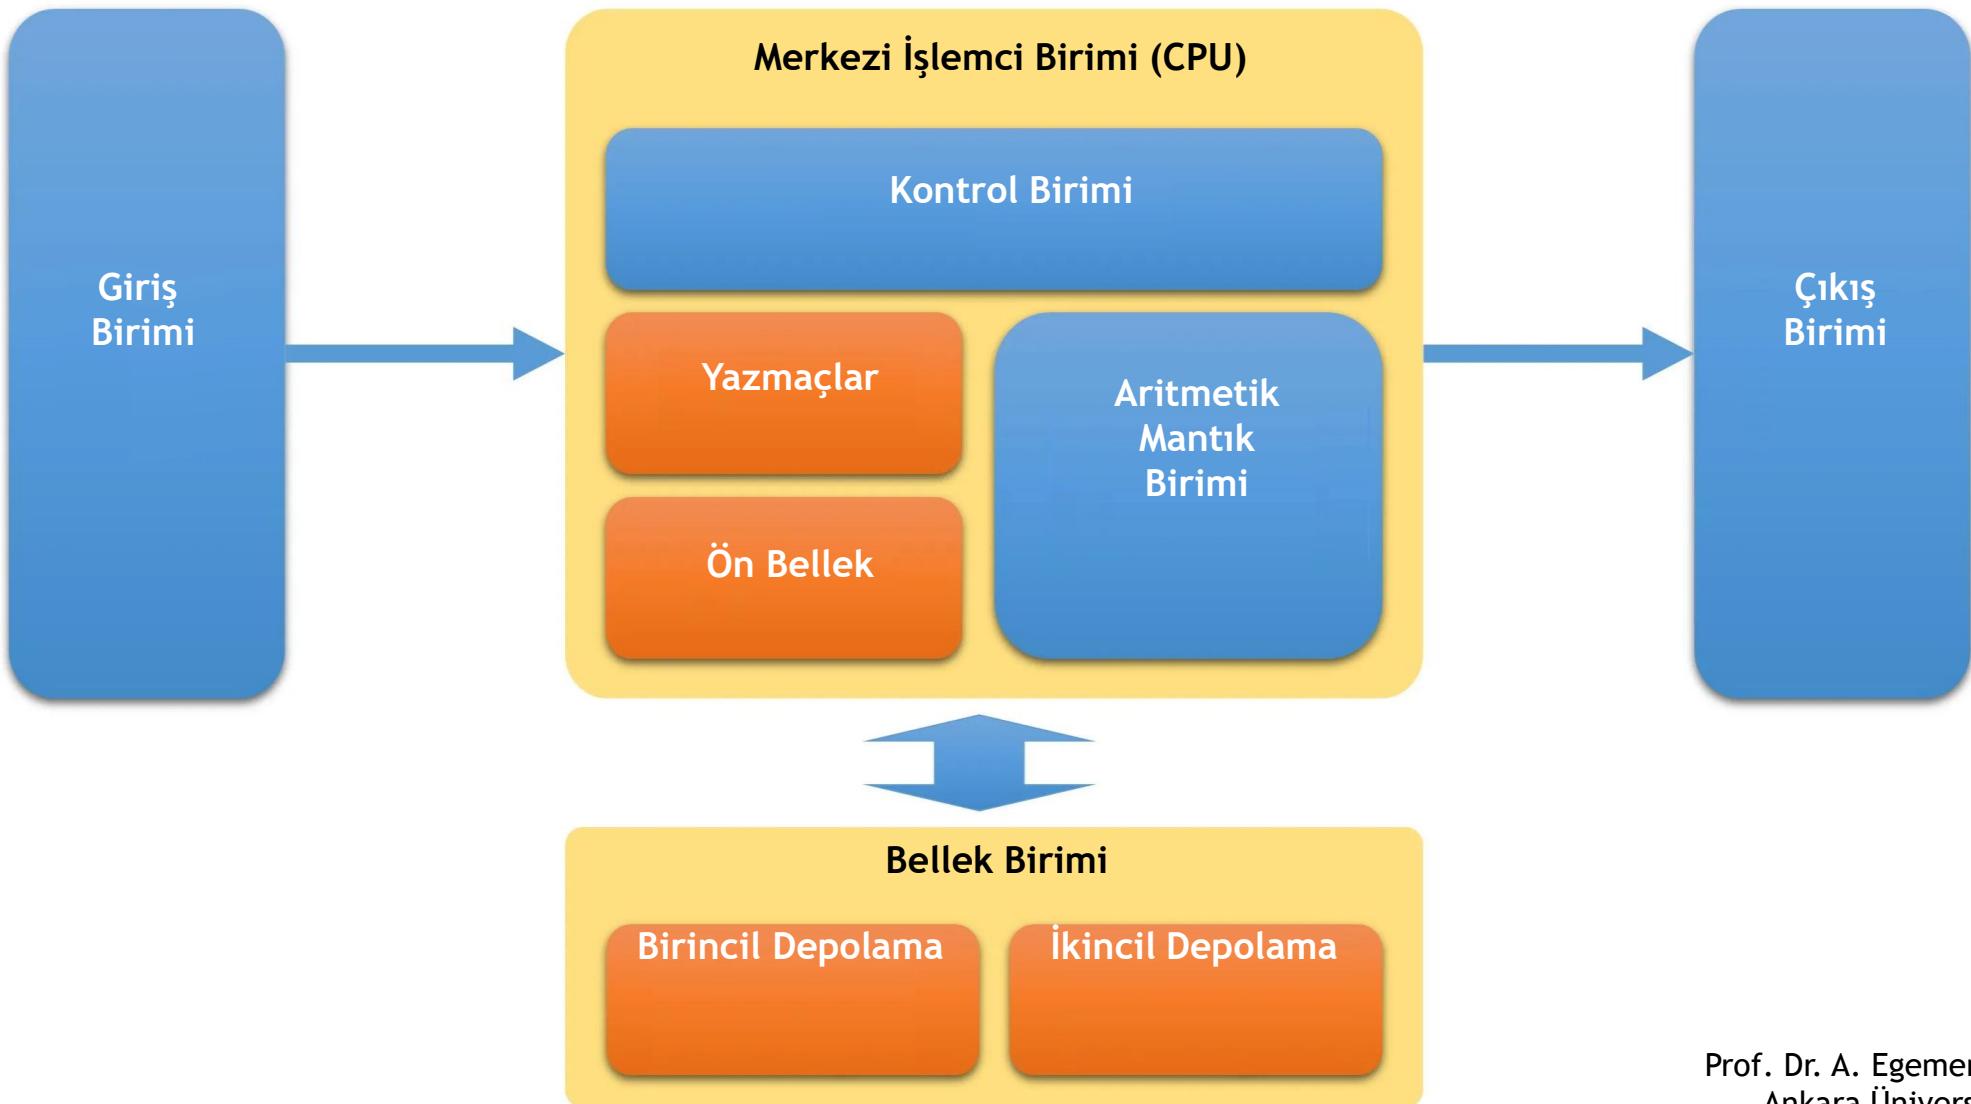
Mühendislik Fakültesi Elektrik-Elektronik Mühendisliği Bölümü

Mühendislik Fakültesi Yazılım Mühendisliği Bölümü

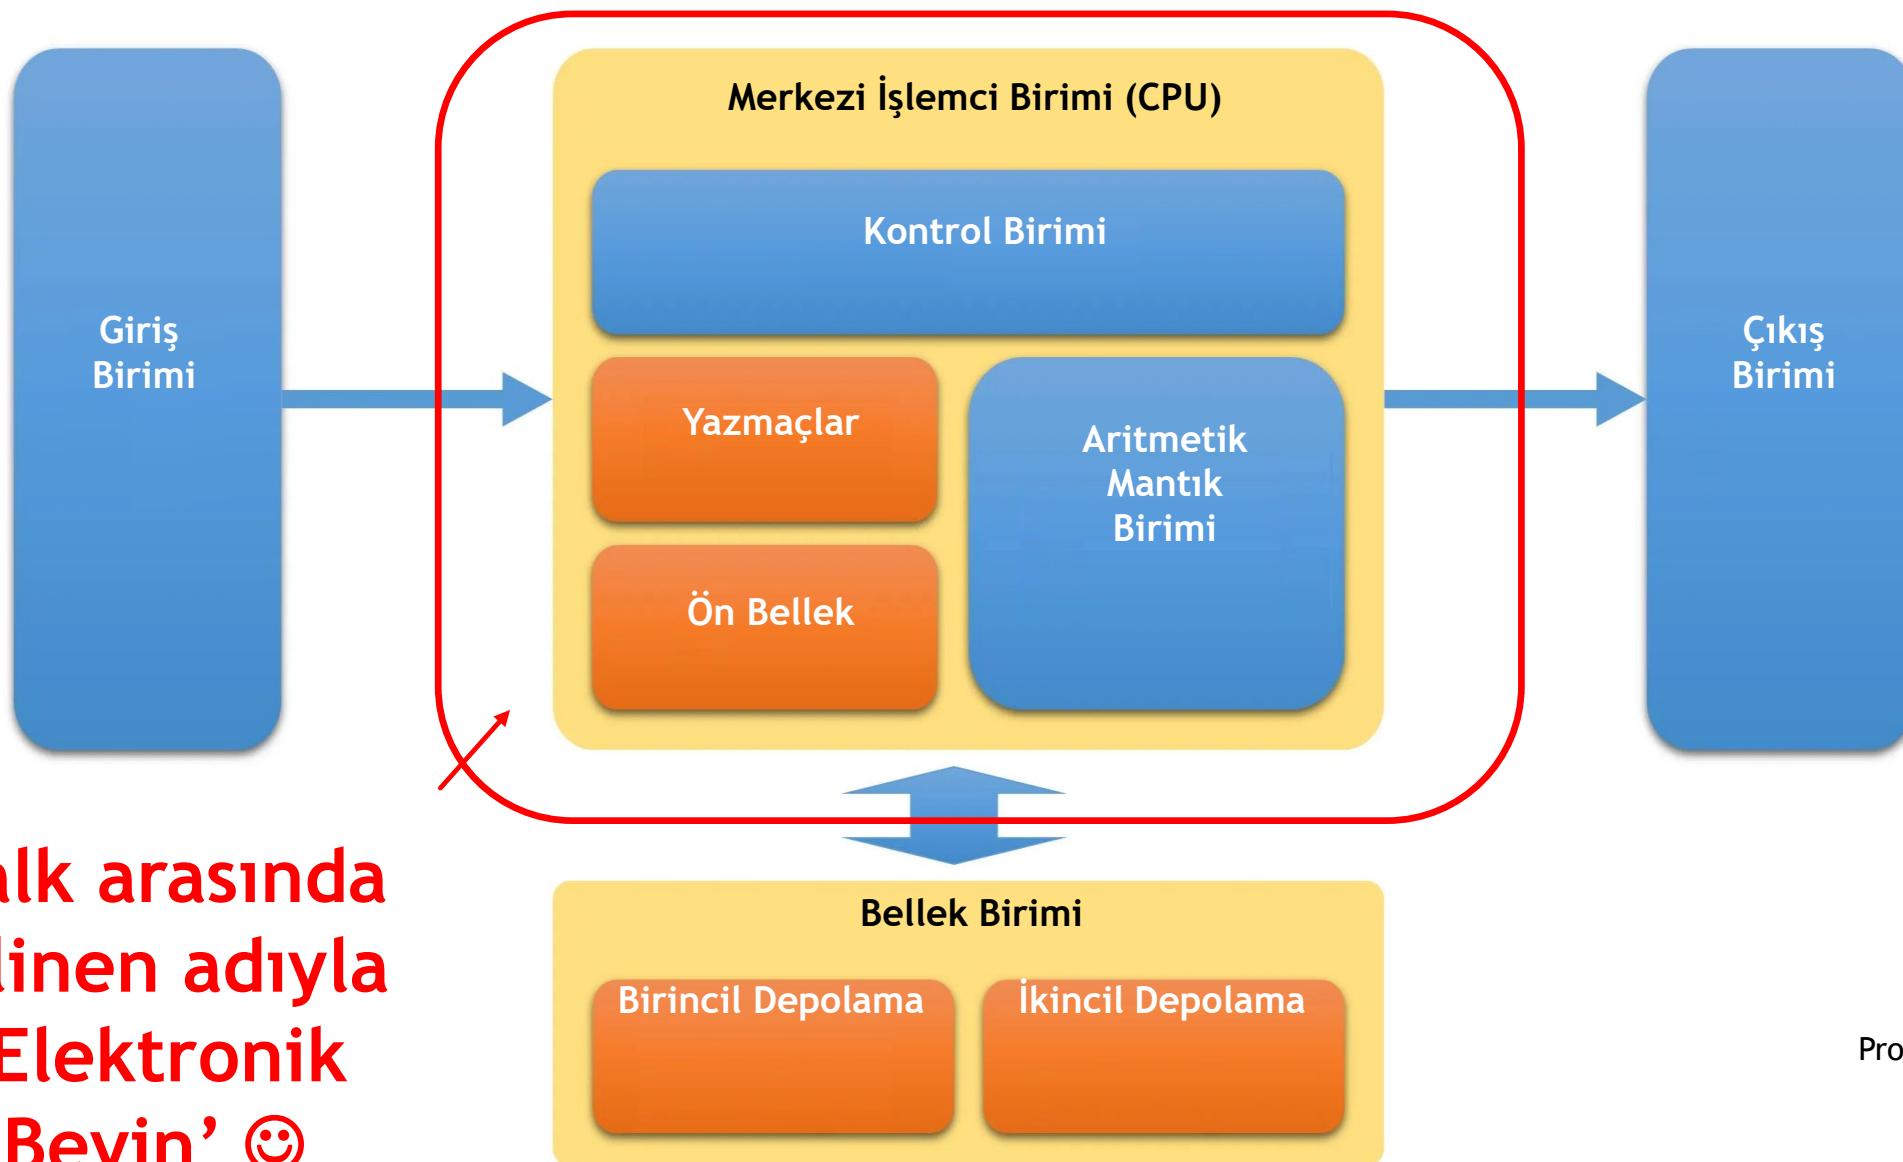
Fen Bilimleri Enstitüsü Disiplinler Arası Yapay Zeka Teknolojileri Ana Bilim Dalı

Akıllı Sistemler ve Teknolojiler Uygulama ve Araştırma Merkezi (ASTAM)

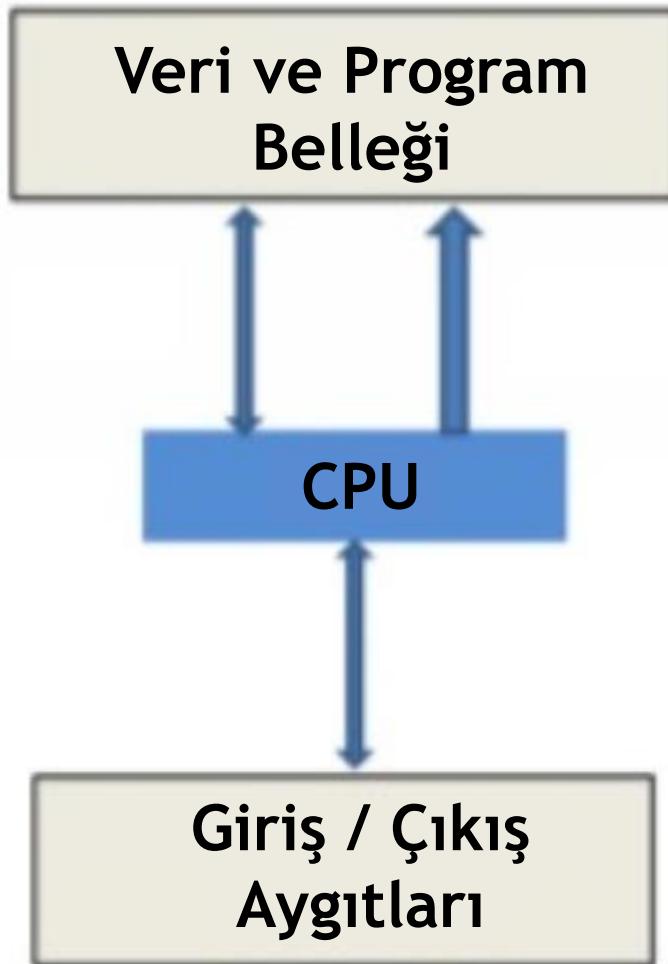
Bilgisayar Mimarisi



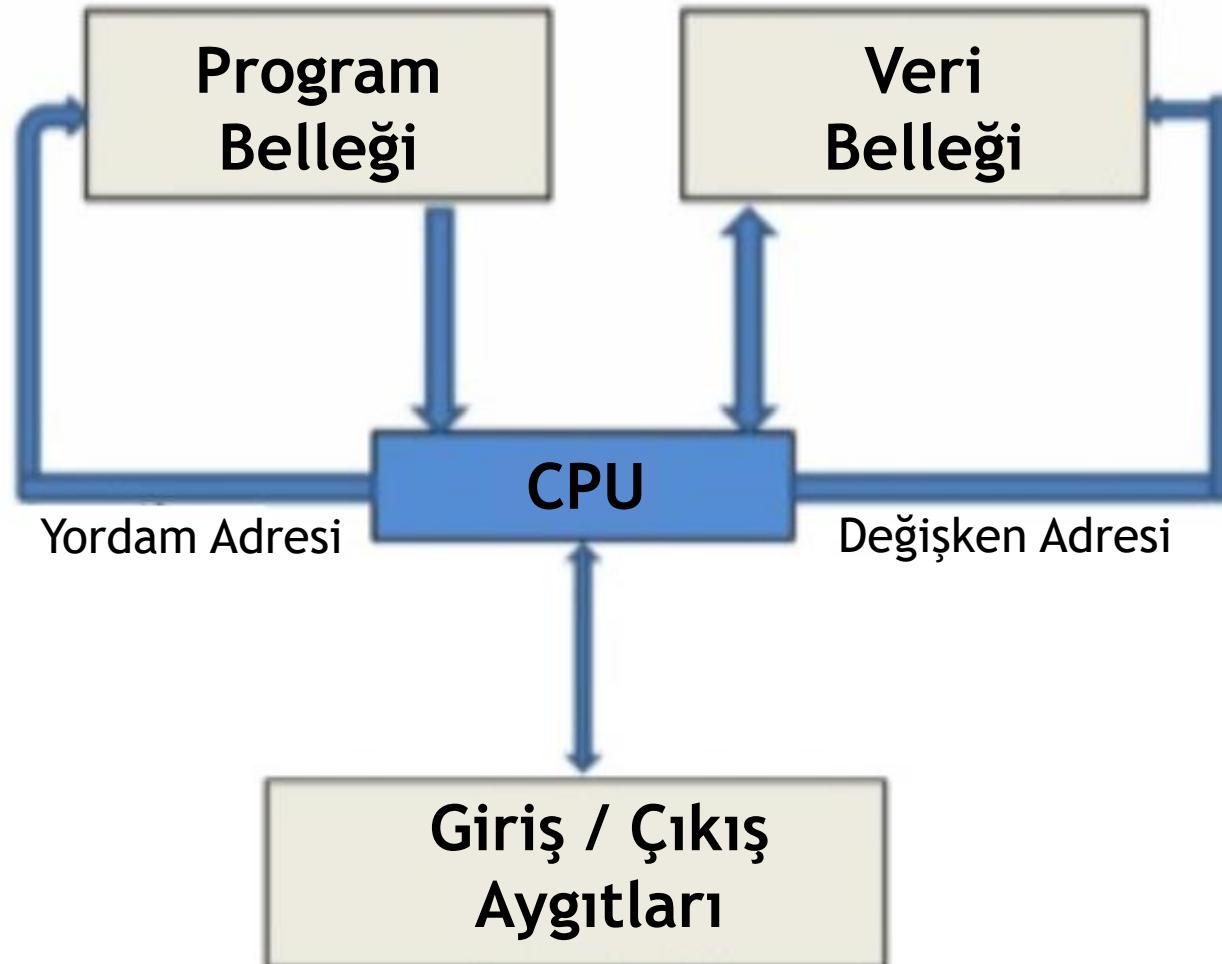
Bilgisayar Mimarisi



Bilgisayar Mimarisi

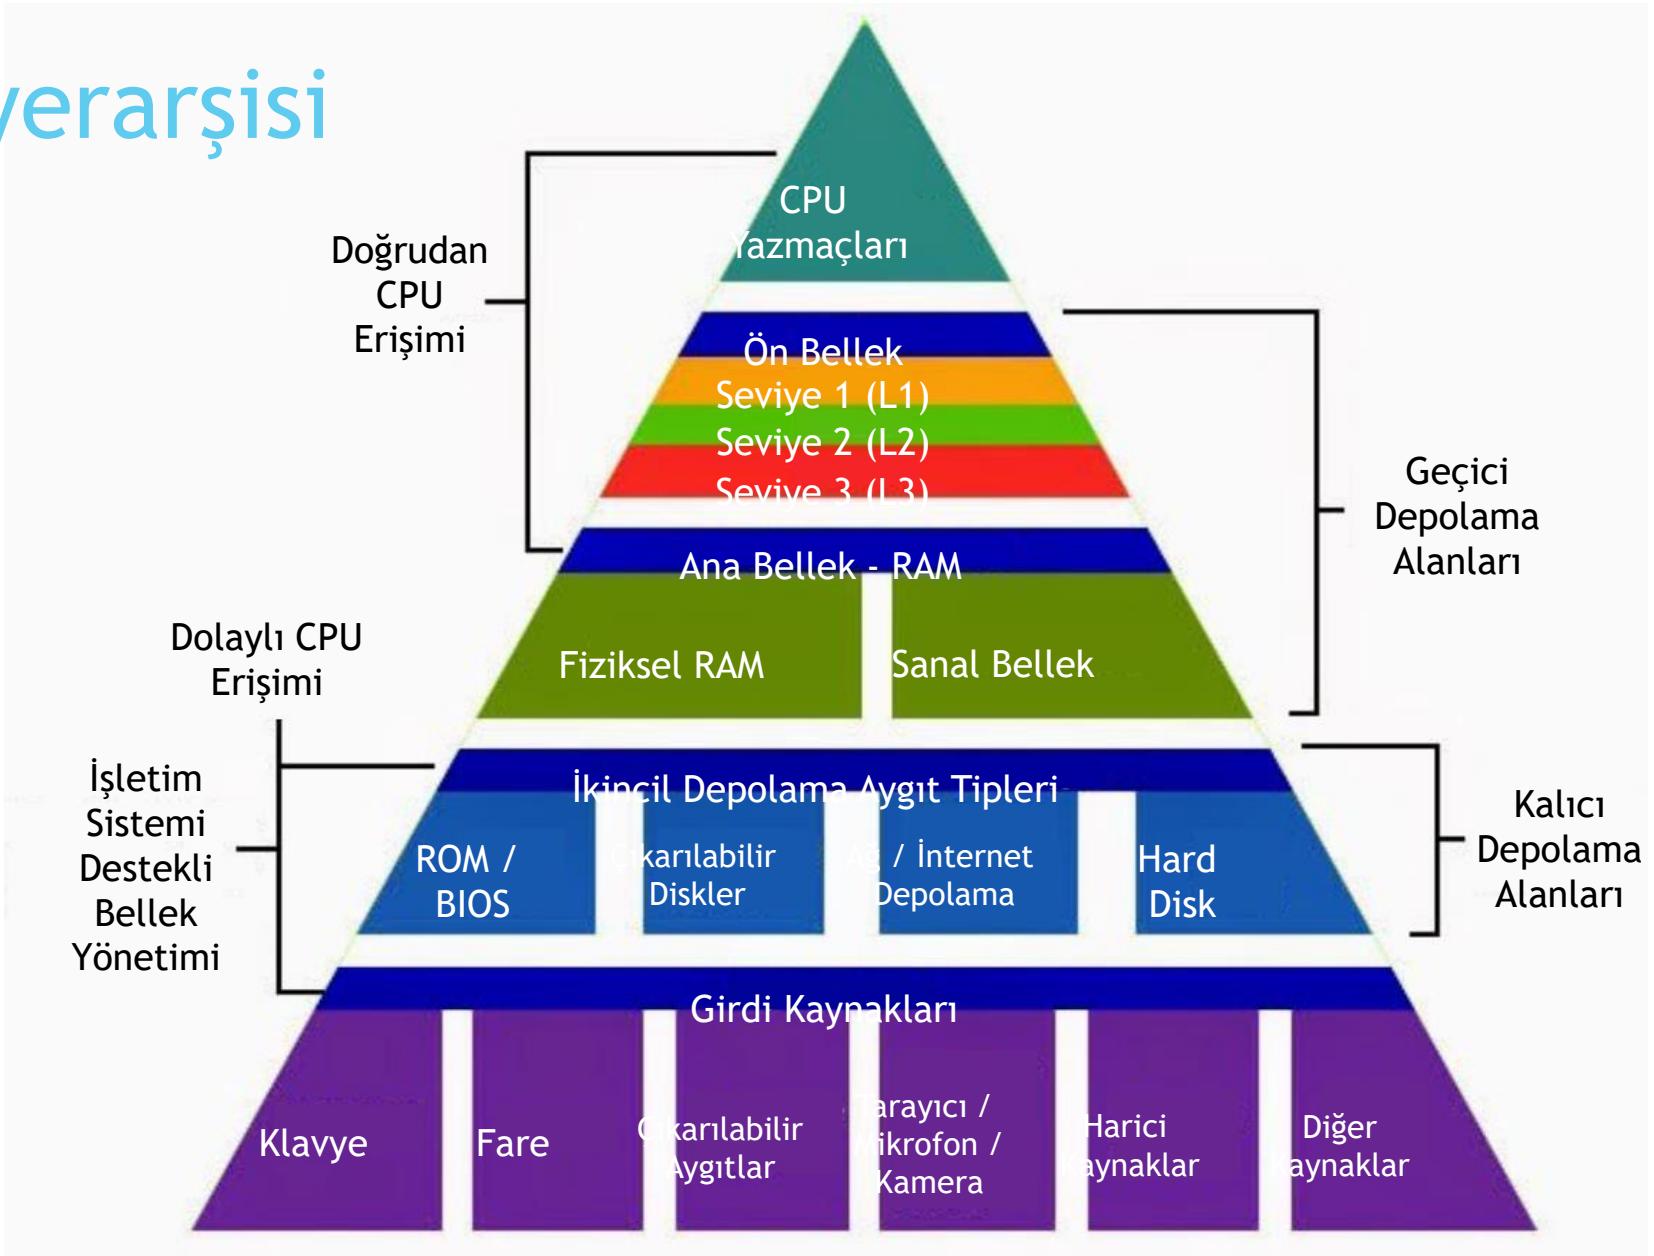


**von Neumann
Mimarisi**

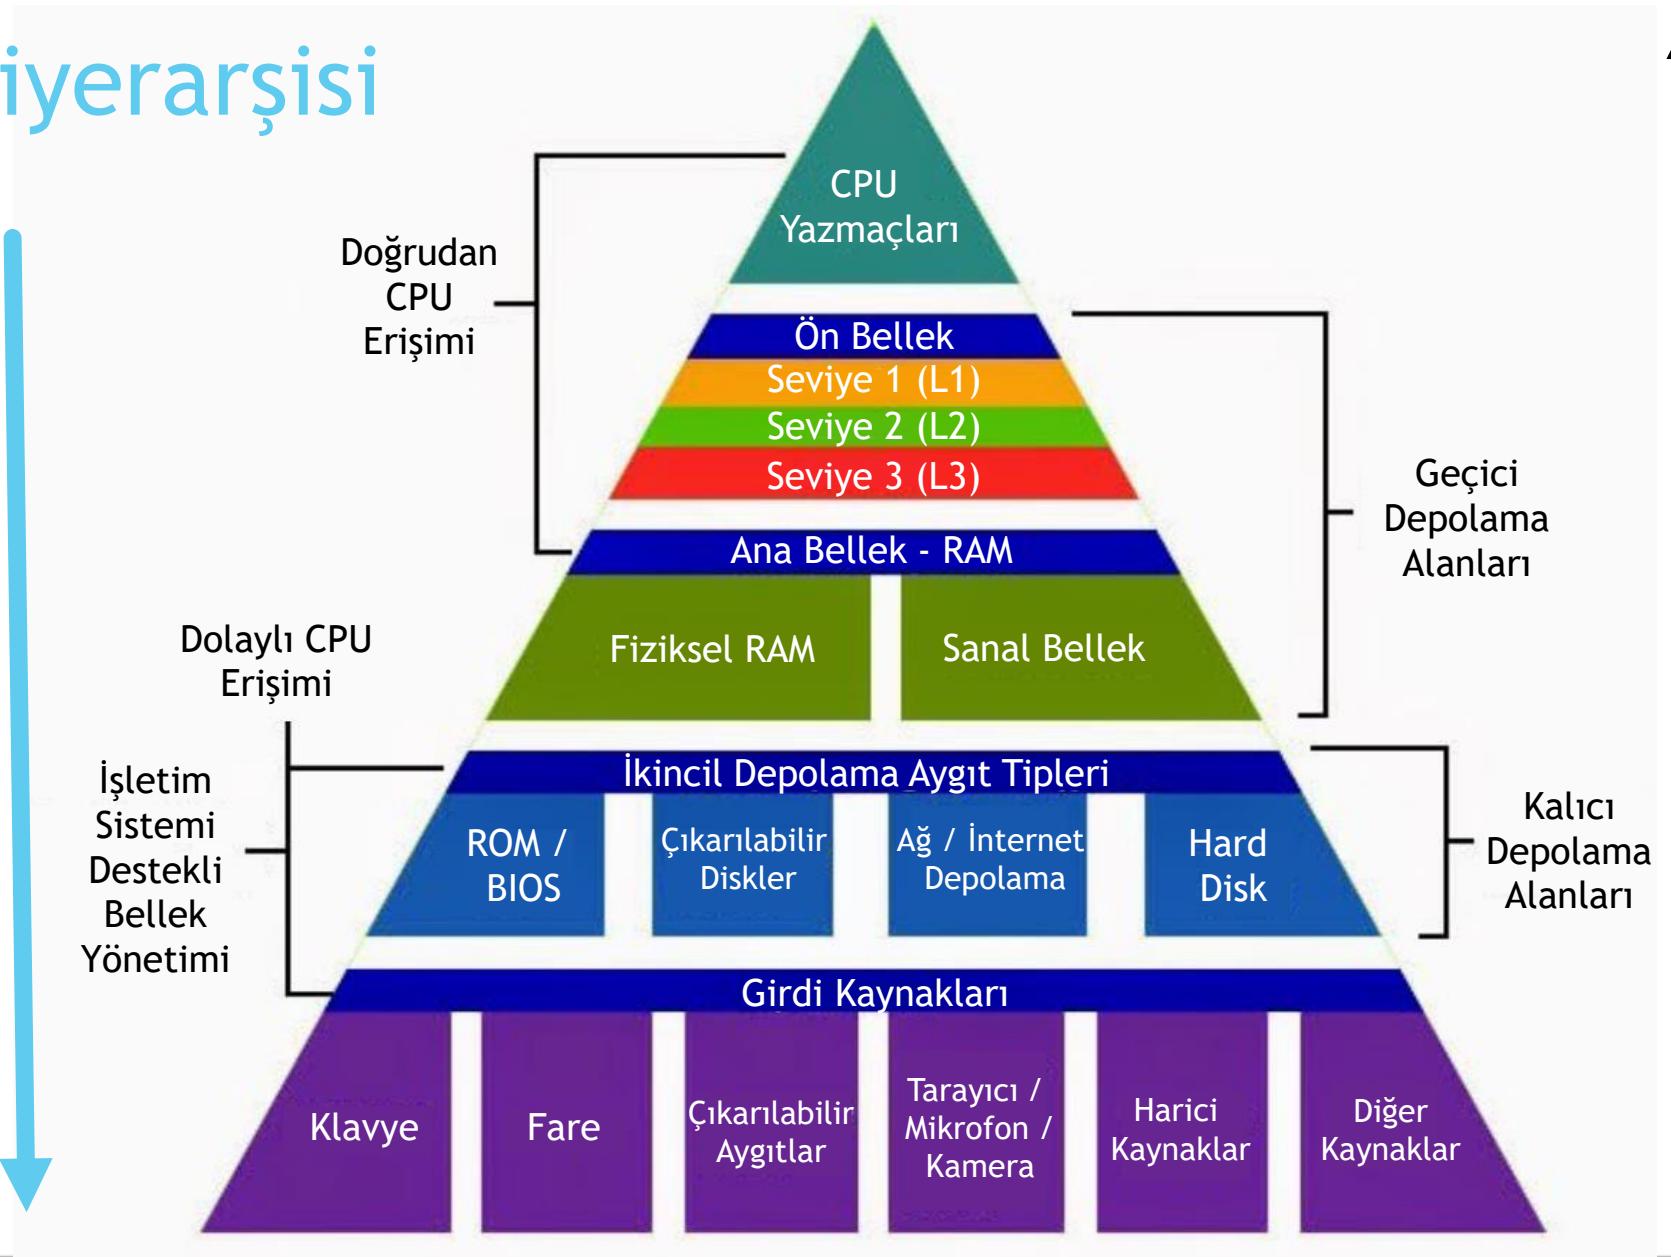


**Harvard
Mimarisi**

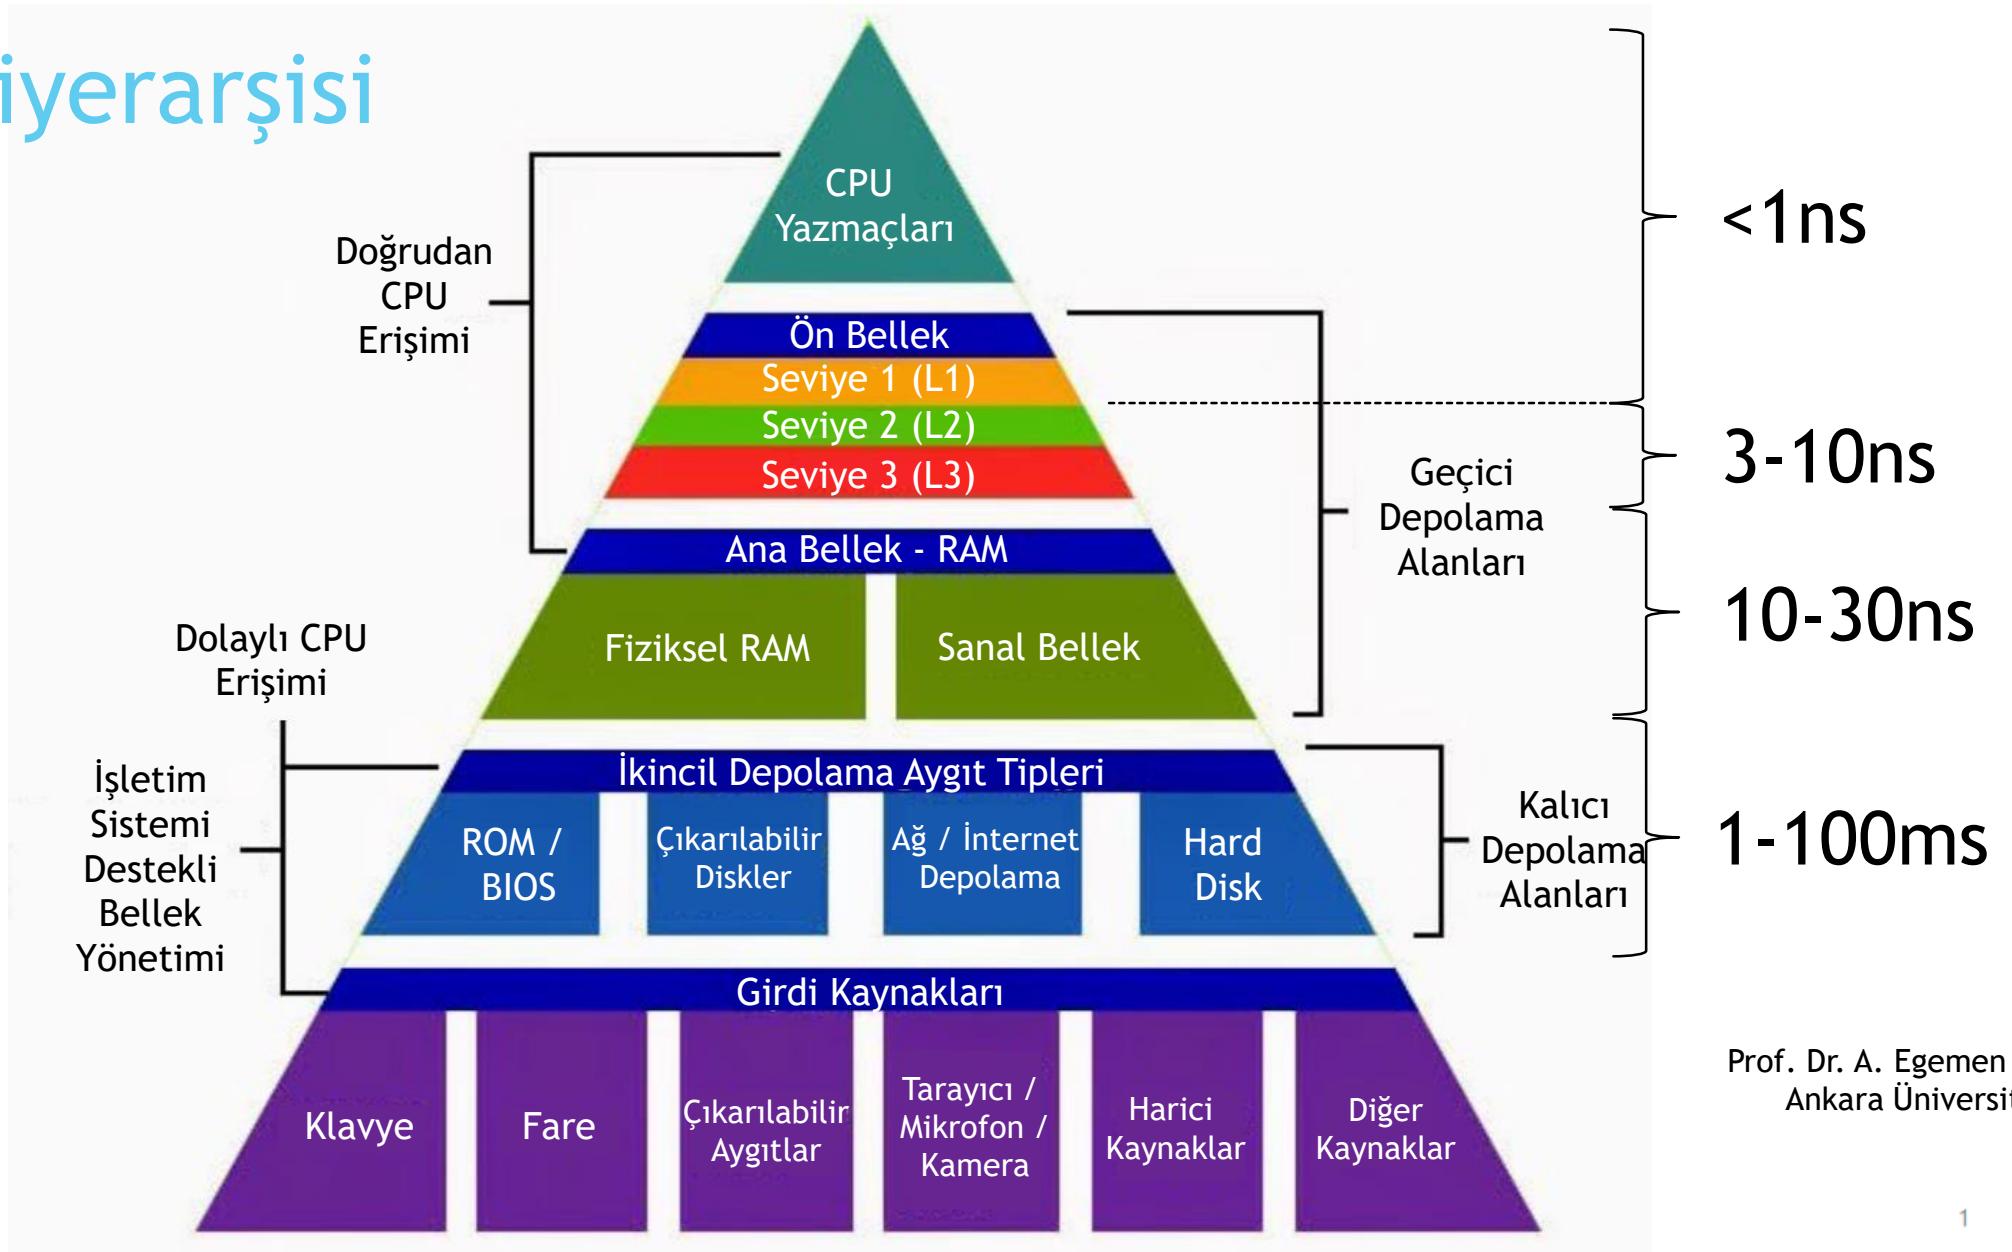
Bellek Hiyerarşisi



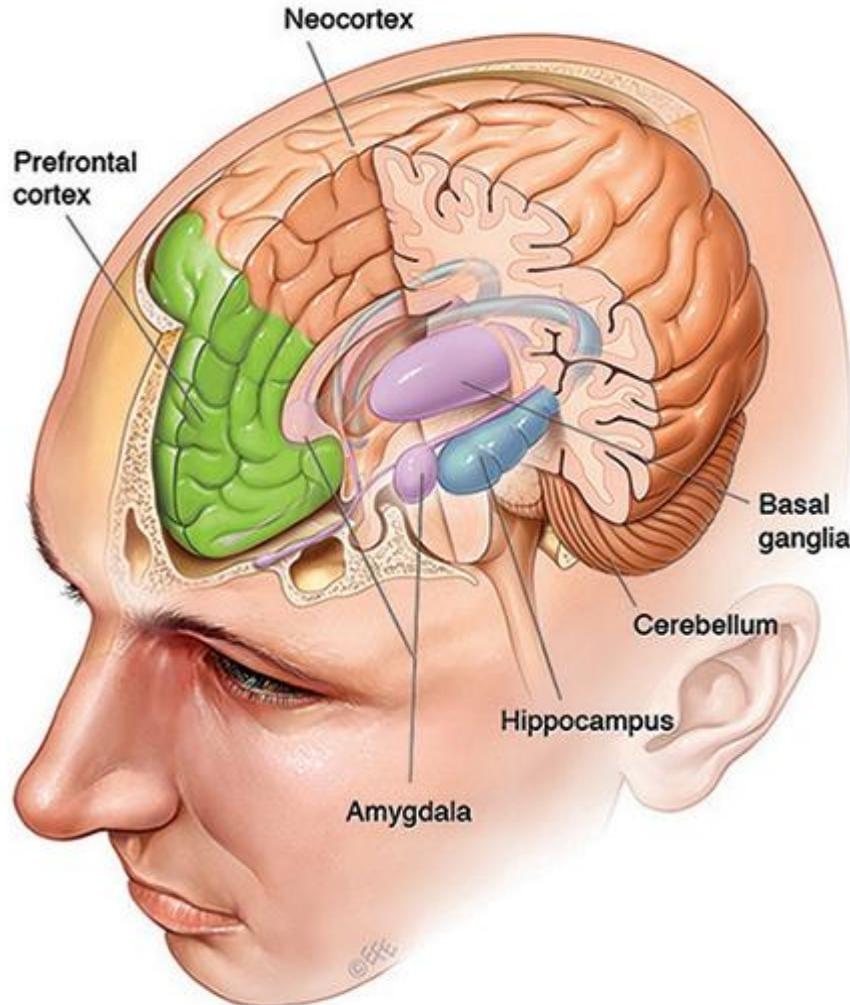
Bellek Hiyerarşisi



Bellek Hiyerarşisi



İnsan Beyninde Bellek İşlevleri



Aleni (*Explicit*) Bellek:

- Başımızdan geçenlere ilişkin anılar (*Episodic*)
- Gerçekle ve genel bilgiler (*Semantic*)

Bunlara ilişkin 3 bölge:

- Hippocampus
- Neocortex
- Amygdala

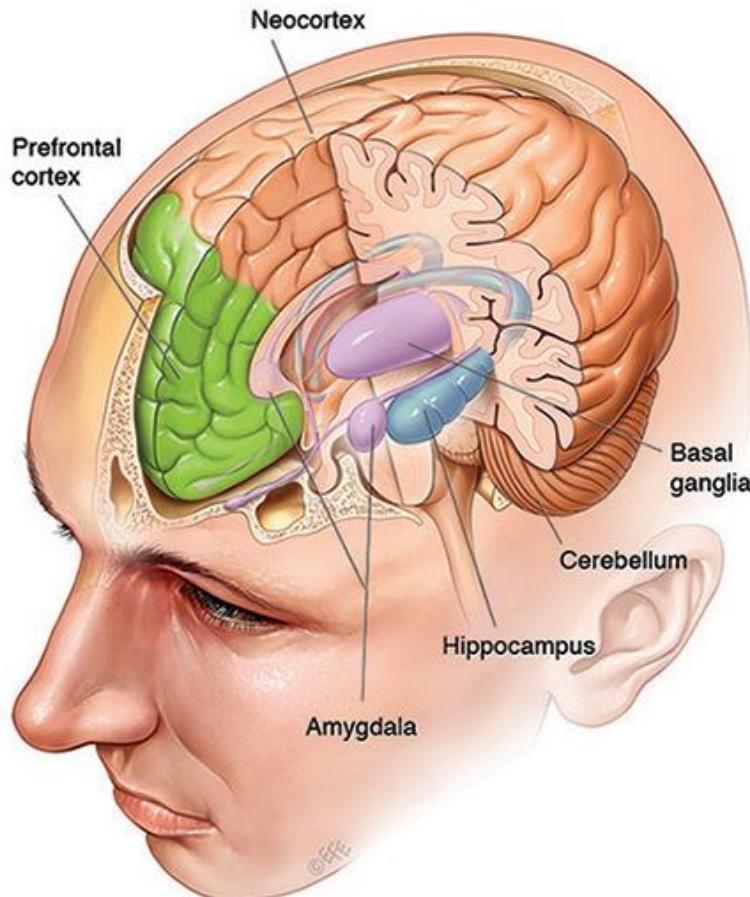
İnsan Beyninde Bellek İşlevleri

Örtülü (*Implicit*) Bellek:

- Motor bellek

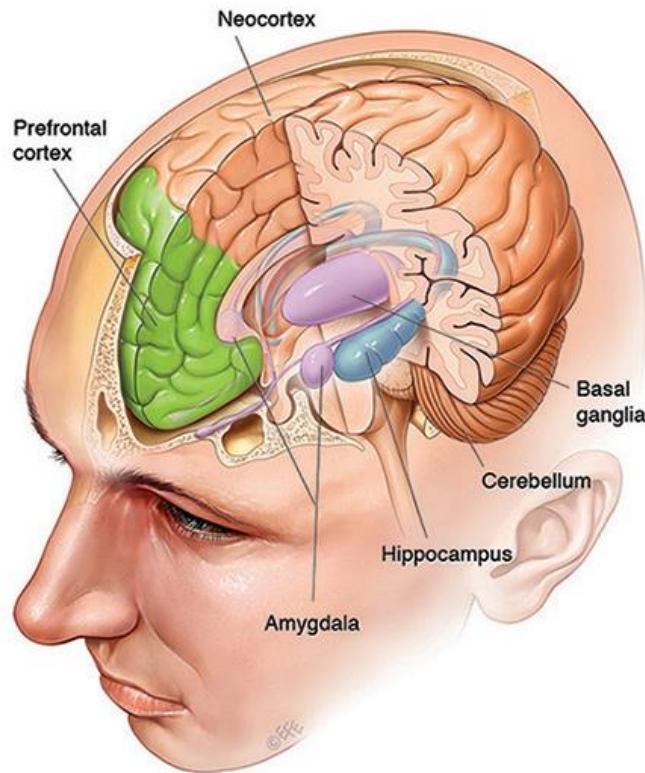
Bunlara ilişkin 2 bölge:

- Basal Ganglia
- Cerebellum



İnsan Beyninde Bellek İşlevleri

Kısa Süreli İşleyen (*Working*) Bellek

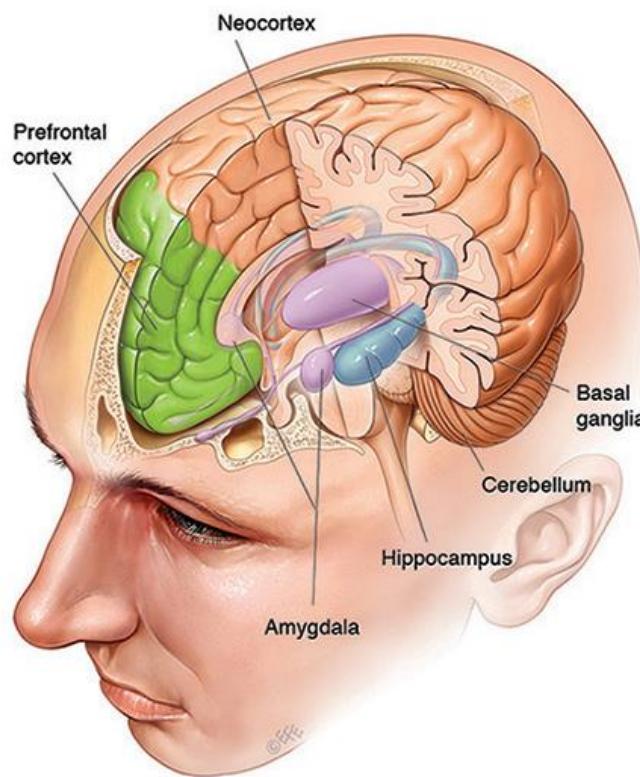


Buna ilişkin tek alan:

- Prefrontal Cortex

İnsan Beyninde Bellek İşlevleri

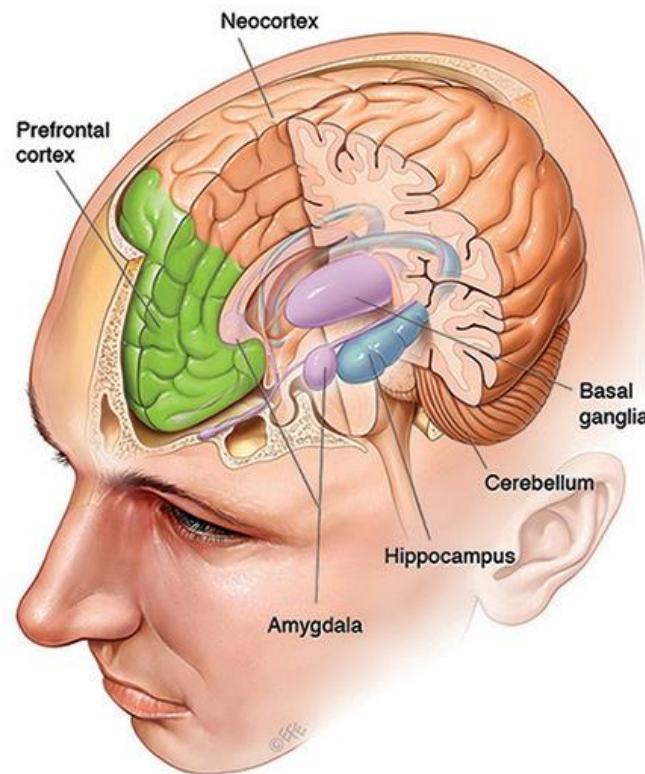
Aleni (*Explicit*) Bellek:



- Başımızdan geçenlere ilişkin anılar (*Episodic*)
- Gerçekle ve genel bilgiler (*Semantic*)

- Hippocampus'te *Episodic* anılar depolanır ve indekslenir (Henry Molaison vakası)
- *Semantic* bilgiler uyku esnasında (?) Hippocampus'ten Neocortex'e aktarılır
- Amygdala, anılarla ilintili duyguların depolanmasında rol oynar; özellikle de korkularla ilgili olanların!...

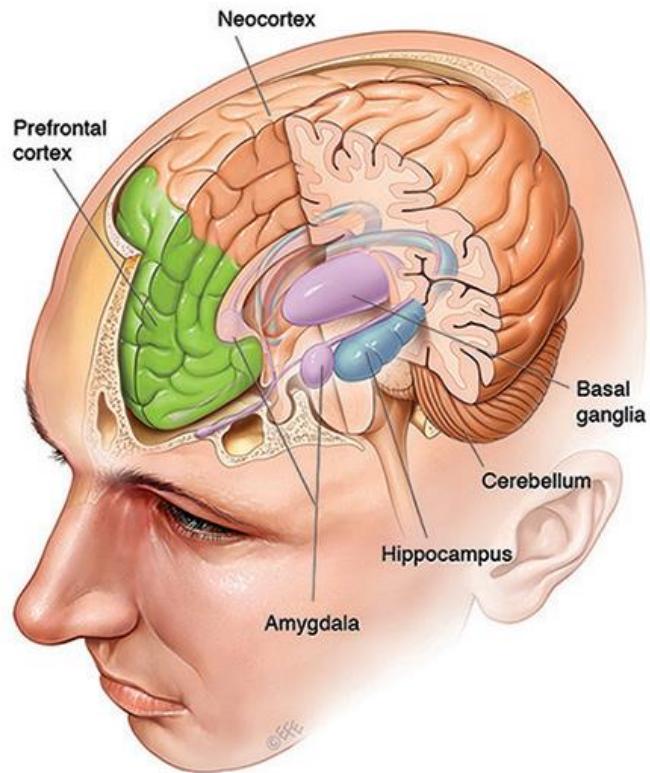
İnsan Beyninde Bellek İşlevleri



Örtülü (*Implicit*) Bellek:

- Motor bellek
- Basal Ganglia, hareketler, alışkanlıklar ve öğrenme ile ilgili bellek bölgesidir. Enstrüman çalma, dans vb hususlarda etkilidir. Parkinson'da en çok etkilenen yerdir.
- Cerebellum, ince motor kontrolde önemlidir.

İnsan Beyninde Bellek İşlevleri



Kısa Süreli İşleyen (*Working*) Bellek

Prefrontal Cortex, memeli hayvanların beyinlerindeki en yeni eklentidir.

Bilişsel işlevlerimizin çoğunu üstlenir.

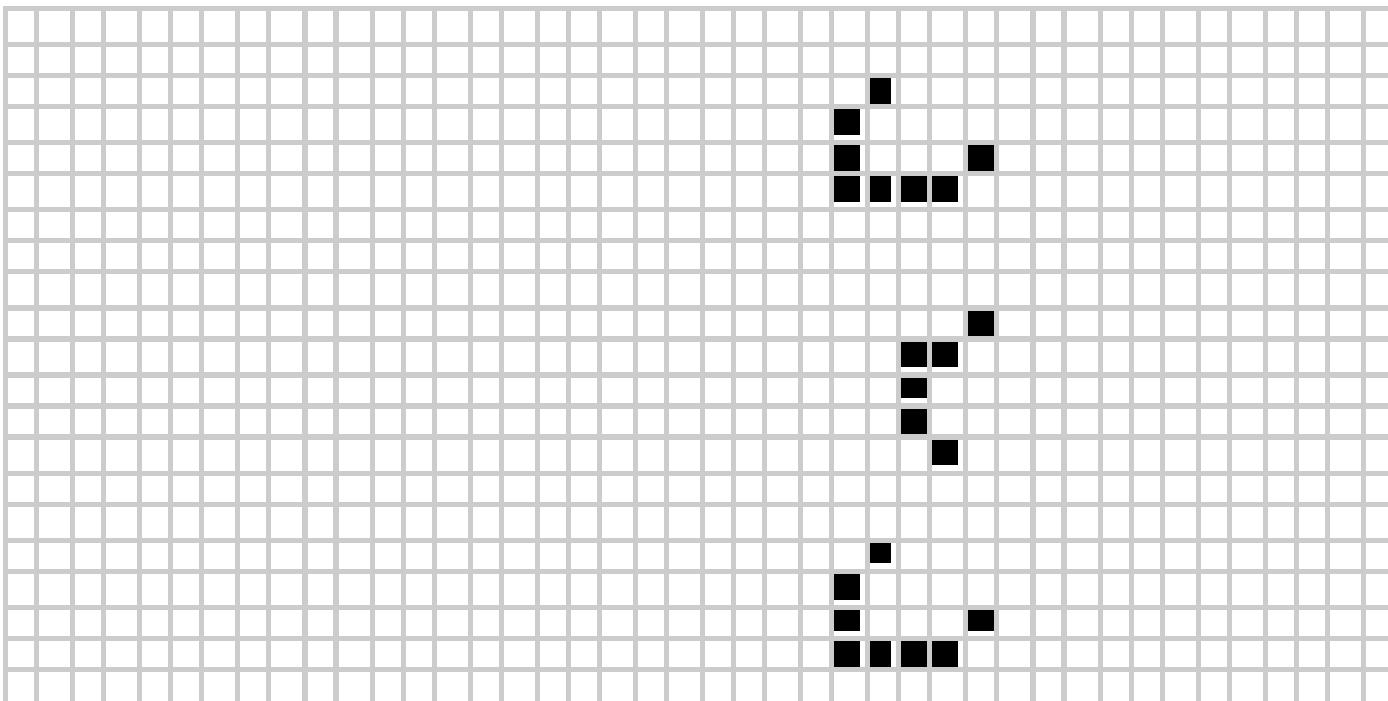
Kısa vadeli bellek gerektiren işlevlerde aktif olduğu MRI sayesinde belirlenmiştir. Sol taraf sözel; sağ taraf ise uzamsal işleyen bellektir

İnsan Beyni - Bilgisayar Karşılaştırması

	Beyin	Bilgisayar
Genel Yapı	Nöronlar ve Sinapslar	Entegre devreler, transistörler, diyonlar, vb.
Bilgi Depolama	Elektrokimyasal ve elektriksel darbeler aracılığıyla 23 farklı şekilde	Yarı iletken birimlerde sinyal seviyeleri ile 2 farklı şekilde (0 ve 1)
Kapasite	86 milyar nöron, 125 trilyon sinaps, 1500cm^3 hacim, 1.4kg ağırlık 100 trilyon FLOP/saniye işlem kapasitesi 1 petabyte (1 katrilyon byte) bellek kapasitesi	Eldeki sisteme göre değişmekte
Enerji ve Kaynak Sarfiyatı	12-20 Watt Oksijenimizin %20'si; Kardiyak girdinin %15'i	GigaWatt mertebesinde

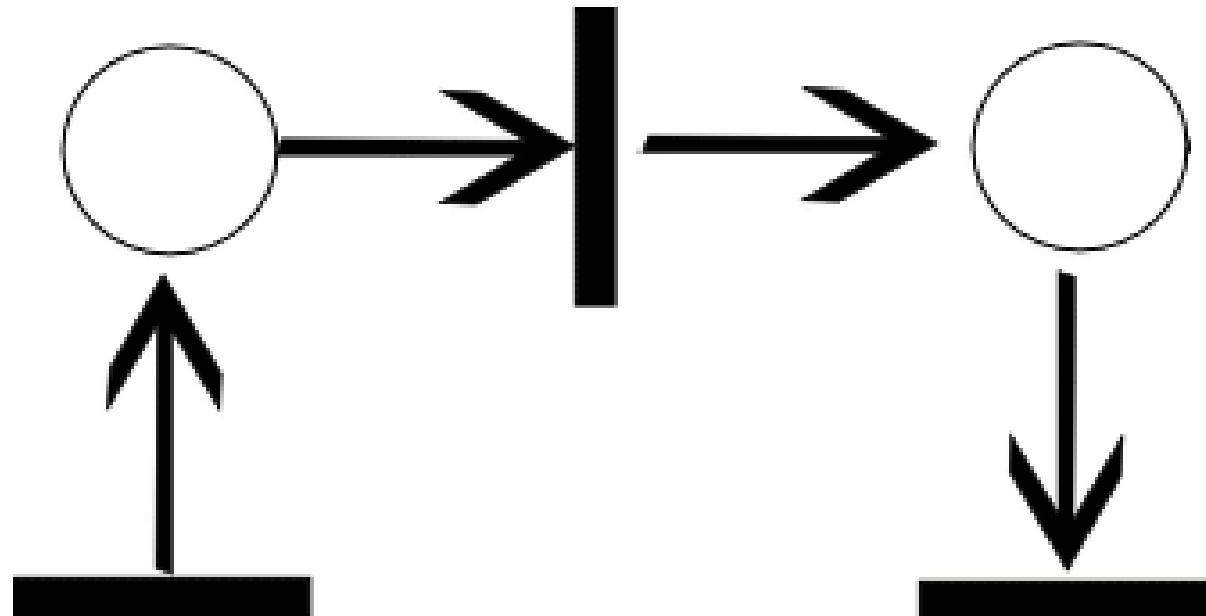
İnsan Beyni Modelleme Çalışmaları

- ▶ 1990'larda Japonya'da ATR'ın CAM-Brain Projesi
- ▶ Cellular Automata, Neurite Network ve Genetik Programlama ile Robot Kedi'nin 1000 davranışını kontrol edebilecek bir Yapay Beyin geliştirme çalışması



İnsan Beyni Modelleme Çalışmaları

- ▶ EPFL Brain Mind Institute'da 2005'te başlayan Blue Brain projesi
- ▶ Petri-Net'lerle Beyindeki Sinyal Akışı'nı Modelleme Çalışmaları



İnsan Beyni Modelleme Çalışmaları

- ▶ Daha yakın tarihte Büyük Ölçekli Beyin Ağları
 - ▶ Çekirdek ağlar
 - ▶ Medial frontoparietal (Default)
 - ▶ Midcingulo-Insular (Salience)
 - ▶ Dorsal frontoparietal (Attention)
 - ▶ Lateral frontoparietal (Control)
 - ▶ Pericentral (Somatomotor)
 - ▶ Occipital (Visual)
 - ▶ Diğer ağlar
 - ▶ Limbic, Auditory, Right/left executive, Cerebellar, Spatial attention, Language, Lateral visual, Temporal, Visual perception/imagery